

※ 한국연구재단 평가에 참여하는 평가위원은 평가에서 알게 된 비밀을 다른 사람에게 누설하거나 직무상 목적 외 용도로 이용하여서는 안됩니다.(국가연구개발혁신법 제40조)

2022년 선정 중견연구자지원사업 결 과 보 고 서

사업명	2022년 선정 중견연구자지원사업		
과제번호	2022S1A5A2A 01043689	연구과제명	인과추론 및 인과머신러닝을 활용한 코로나19가 관광수요에 미치는 영향 분석
연구기간	2022. 07. 01. ~ 2023. 06. 30. (1년)		
연구책임자 성명	양원석	주관기관	한남대학교

목 차

I. 연구목적 및 방법	3
1. 당초 연구의 목적, 필요성 및 연구목표	3
2. 당초 연구 내용, 범위 및 방법	4
II. 연구수행 내용 및 결과	5
III. 연구결과 활용계획	12
1. 연구결과 활용계획	12
2. 연구성과	13
IV. 참고문헌	13

I. 연구 목적 및 방법

1. 당초 연구의 목적, 필요성 및 연구목표

코로나19의 발생으로 인해 유동인구 및 외국 관광객의 감소로 국내 관광수요가 급감하여 관광시장에 큰 충격을 주고 있다(구진경, 2020; 최정은, 김형중, 2020). 구체적으로 살펴보면, 2021년 상반기 주요관광지점 평균방문객은 2019년 동기대비 43.3%로 급격히 관광수요가 감소하였다(권태일, 박소영, 2021).

국가적인 거시적 차원에서는 구체적인 관광수요 통계를 살펴보지 않더라도 코로나19로 인해 전반적으로 국내 관광수요가 급감했음을 쉽게 짐작할 수 있다. 반면, 미시적인 차원에서 살펴보면, 관광수요에 미치는 코로나19의 영향은 개별 관광지별로 매우 상이할 수 있다. 예를 들어, 관광지식정보시스템의 주요관광지점입장객 통계를 살펴보면, 코로나19 발생 이전과 비교하여 코로나19 발생 이후, 서울시의 한 고궁의 관광객 수는 감소했으나, 경기도의 한 컨트리클럽의 관광객 수는 차이가 없고, 대전시의 한 등산로의 관광객 수는 증가했다. 아울러, 코로나 19에 의해 관광수요가 감소했다고 하더라도 관광수요의 감소 정도가 관광지별로 매우 상이하리라 예상된다. 코로나19 때문이 아니라 그간의 관광수요가 감소하는 추세였기 때문에 관광수요가 감소한 관광지도 존재할 수 있다.

코로나19와 같은 팬데믹 및 대규모 재해 상황에서 관광지 지원정책과 같은 거시적인 측면에서 관광정책의 계획 및 시행 여부는 코로나19로 인한 관광수요의 평균적인 인과효과를 토대로 정책의 방향성을 수립할 수 있다. 반면, 정책의 실행 단계에서는 예산의 제약과 정책 실행에 소요되는 시간을 고려해야 한다. 따라서 코로나19로 인한 관광수요 변화의 관광지별 개별적인 인과효과를 분석하면 정책의 실행단계에서 관광정책의 경제적 효과 및 실행 속도를 향상시킬 수 있다.

기존 연구에서는 전체 관광 수요 또는 관광지 유형별 수요 관점에서 코로나19가 관광수요에 미치는 영향을 분석하였다. 예를 들어, 권태일, 박소영 (2021)은 코로나19에 의한 전체 관광지의 평균 수요의 변화를 분석하였다. 윤성준, 이희찬(2022)은 실내외, 인공 및 자연, 대형 및 소형으로 관광지의 유형을 구분하고 코로나19에 의한 관광지 유형별 수요 변화를 분석하였다. 따라서 지금까지의 기존 연구는 거시적 측면에서 코로나19에 의한 관광수요의 감소 정도를 분석하였다.

본 연구에서는 계량경제학 및 머신러닝 분야의 인과추론 방법론을 적용하여 코로나19의 발생이 개별 관광지의 관광수요에 미치는 인과효과를 분석한다. 국내 주요관광지를 대상으로 개별 관광지별로 코로나19 발생에 따른 수요변화를 통계적으로 엄밀하게 분석한다. 코로나19에 의해 관광수요가 유의하게 감소 및 증가했는지를 관광지별로 개별적인 인과효과를 분석한다.

인과효과를 다루는 계량경제학에서 치료, 투약, 수술, 광고, 정책 시행과 같이 중

속변수의 변화를 발생시키는 변수를 처치(treatment) 변수라 부른다. 본 연구에서는 관광수요에 영향을 주는 코로나19 발생이 처치변수에 해당한다. 전통적인 계량경제학에서는 일반적으로 처치의 시행 유무에 따른 평균적 인과효과를 분석하였다. 최근에는 머신러닝을 활용하여 처치에 따른 특성변수의 개별적 인과효과를 분석하는 인과머신러닝 분야의 연구가 활발히 진행되고 있다.

처치에 따른 특성의 개별적 인과효과를 분석하면 처치 실행에 시간 및 예산 제약이 있는 경우 처치 효과를 극대화할 수 있다. 예를 들어, 온라인 광고에서 예산 제약이 있는 경우, 광고 효과가 큰 고객 특성별로 고객을 선정하여 광고를 진행하면 무작위 선정에 비해 광고 효과가 향상될 수 있다. 환자에게 약을 처방하는 경우에도 처치 효과가 큰 특성의 환자 또는 소집단부터 처방한다면 처방의 효과를 극대화할 수 있다. 최근 인과효과 분석 및 극대화를 위해 인과머신러닝을 적용하는 연구들이 활발히 진행되고 있다(Zhao & Harinen, 2019; Zou et al., 2020; McFowland et al., 2021). 따라서 기존의 마케팅 및 제약 분야 연구와 같이, 코로나19 발생에 따른 관광지 특성의 개별적 인과효과를 분석하면, 관광지 특성에 따른 의미있는 정책적 시사점을 도출할 수 있으리라 기대한다.

2. 당초 연구 내용, 범위 및 방법

처치의 인과효과를 추정 및 분석하기 위해서는 처치집단과 비교 대상인 대조집단 또는 통제집단(control group)이 필요하다. 통제집단을 구성하는 대표적인 방법으로 무작위 시행이 있다. 무작위 시행은 신약의 효과 분석 등 의료분야에서 광범위하게 적용되며, IT 분야에서는 A/B 시험으로 활용되고 있다. 한편, 무작위 시행은 비용이 많이 들고 윤리적인 문제가 발생할 수도 있기 때문에, 주어진 데이터를 활용하여 인과효과를 분석하는 이중차분법, 회귀단절모형, 도구변수법, 통제변수를 활용한 회귀 분석 등의 다양한 인과추론 방법론이 개발되었다(Angrist & Pischke, 2008; Angrist & Pischke, 2014).

최근, 주어진 데이터에서 통제집단을 선정 또는 구분하기 어려운 경우, 처치를 받지 않은 (또는 정책이 시행되지 않은) 집단을 활용하여 통제집단을 구성하는 가상적 통제집단(synthetic control group)이라는 새로운 방법론이 개발되어 사회과학의 다양한 분야에서 광범위하게 활용되고 있다(Abadie et al., 2010; Abadie, 2021).

가상적 통제집단과 유사하게, Varian(2016)은 통제집단이 존재하지 않은 시계열의 경우 예측모형을 이용하여 가상의 통제집단을 만드는 가상의 TTTC(hypothetical train test treat compare) 방안을 제안하였다. TTTC에서는 머신러닝과 같이 처치 발생 이전 기간의 데이터를 이용하여 시계열 예측모형을 학습하고 성능을 검증하여 최적의 예측모형을 선정한다. 그리고 처치가 발생한 구간에서 최적 예측모형의 예측치를 통제집단으로 활용한다(Varian, 2014; Varian, 2016). Abadie(2021)가 제시한 가상적 통제집단은 처치를 받지 않은 데이터를 이용한 비표본(out of sample) 예측 방

법이다. 따라서 Varian(2016)이 제시한 방법론은 완벽하지는 않지만 개념적으로 시계열에 적용 가능한 가상적 통제집단 방법이라 간주할 수 있다.

계량경제학의 인과분석에서는 전통적으로 처치의 시행 유무에 따른 평균적 인과효과를 분석한다. 최근에는 머신러닝을 활용하여 처치의 시행 유무에 따른 특성변수의 개별적인 인과효과인 HTE(heterogenous treatment effect)를 분석하는 인과머신러닝 관련 연구들이 활발히 진행되고 있다.

개별적인 인과효과를 이용하면 처치 실행에 시간 및 예산 제약이 있는 경우 처치효과를 극대화할 수 있다. 예를 들어, 마케팅의 온라인 광고에서 예산 제약이 있는 경우, 광고의 인과효과가 큰 특성의 고객을 선정하여 광고를 진행하면 무작위 선정에 비해 광고효과가 향상될 수 있다. 환자에게 약을 처방하는 경우에도 처치 효과가 큰 특성의 환자 및 소집단부터 처방한다면 처방의 효과를 극대화할 수 있다. 따라서 최근 처방적분석(prescriptive analytics)과 같이 인과머신러닝을 적용하여 개별적인 인과효과를 다루는 연구들이 활발히 진행되고 있다(Zhao & Harinen, 2019; Zou et al., 2020; McFowland et al., 2021).

인과머신러닝 방법론은 DML(double machine learning)(Chernozhukov et al., 2016; Chernozhukov et al., 2017; Wager & Athey, 2018; Athey et al., 2019), Doubly Robust Learning(Foster & Syrgkanis, 2019), Meta-Learners(Kunzel et al., 2019), Dynamic DML(Lewis & Syrgkanis, 2021) 등이 있다. Microsoft Research에서는 인과머신러닝을 보급하기 위해 EconML이라는 파이썬 API를 개발 및 공개하였다(Oprescu et al., 2019; Microsoft Research, 2019).

본 연구에서는 첫째, 가상적 통제집단 방법론을 활용하여 코로나19가 개별 관광지의 수요에 미치는 인과효과를 분석한다. 둘째, 인과머신러닝 방법론인 DML을 활용하여 코로나19가 관광수요에 미치는 영향에 대해 관광지 특성에 따른 개별적 인과효과를 다룬다.

II. 연구수행 내용 및 결과

(1) 코로나19가 개별 관광지 수요에 미치는 영향 분석

본 절에서는 가상적 통제집단 방법론을 활용하여 대단위의 개별 관광지를 대상으로 코로나19가 개별 관광지의 관광수요에 미치는 인과효과를 분석하는 방안을 다룬다. 구체적인 데이터 분석 알고리즘을 요약하면 다음과 같다.

· 데이터 구성

- 시점 t 에서 관광지 j 의 관광수요: $y_j(t)$, $t = 1, 2, \dots, N$ (t 는 월 단위)
- 시점 t 에서 관광지 j 의 수요예측치: $\widehat{y_j(t)}$, $t = C+1, \dots, N$ (C 는 코로나19 발생 시점)
- $t = C+1, \dots, N$ 에서 $y_j(t)$ 는 처치집단 그리고 $\widehat{y_j(t)}$ 는 가상적 통제집단을 의미

- 관광수요 시계열 예측모형 선정 방법
 - 예측모형 학습: $y_j(1), \dots, y_j(R)$ 을 이용하여 예측모형 학습 ($R < C$)
 - 예측모형 검증: $y_j(R+1), \dots, y_j(C-1)$ 을 이용하여 예측모형 검증 ($R < C$)
 - 검증오차가 가장 작은 시계열 예측모형을 선택하여 $\widehat{y_j(t)}$ 예측, $t = C+1, \dots, N$ (C 는 코로나19 발생 시점)
- 관광지 j 의 관광수요에 대한 코로나19의 인과효과 분석
 - $\{y_j(t), \widehat{y_j(t)}\}$, $t = C+1, \dots, N$ 에 이분산 T-검정 적용

본 연구에서는 관광지별 관광수요 데이터로 관광지식정보시스템의 주요관광지점 입장객통계에서 제공하는 관광지별 월별 관광객 수를 활용하였다. 서울, 인천, 경기도, 강원도에 속한 1372개 관광지를 대상으로 하여 데이터를 수집하였다.

주요관광지점 입장객통계에는 데이터 수집 시점이 관광지별로 상이하여 관광지별로 사용가능한 데이터의 시점 및 개수가 다르다. 아울러 누락된 데이터가 존재하는 관광지도 매우 많다. 데이터 분석을 온전하게 수행하기 위해서는 예측을 위한 학습 데이터와 처치데이터를 합리적으로 구성하고 데이터가 부정확하거나 누락된 관광지는 분석 대상에서 제외하였다.

첫째, 국내에서는 2020년 1월에 코로나19가 발생했다. 따라서 수요예측을 위한 학습데이터는 2020년 이전 관광객 수 데이터를 이용한다. 본 연구에서는 예측의 정확성이 중요하기 때문에 시계열 예측 성능을 높이기 위해 안정적이고 충분한 개수의 데이터 필요하다. 우선, 서브프라임 모기지 사태를 고려하여 2011년 1월 이후의 데이터만을 분석 대상으로 삼았다. 따라서 임의 관광지에 2011년 1월 이전부터 데이터가 존재한다면 학습데이터는 최대 108개를 갖게 된다. (2011년 1월에서 2019년 12월까지 9년치 월별 관광객 수). 한편, 주요관광지점 입장객통계에는 2020년 이전 데이터가 몇 개만 존재하는 관광지도 있다. 예측을 위한 최소한의 데이터를 확보하기 위해 최소 36개 이상의 월별 관광객 수를 보유한 관광지, 즉, 2017년 1월 이전부터 데이터를 보유한 관광지를 분석 대상으로 삼았다. 둘째, 인과효과 분석을 위한 처치데이터는 2020년 2월에서 2020년 12월까지 코로나19 발생 이후 11개월치 관광객 수를 이용하였다. 마지막으로 분석기간 동안 일부 데이터가 누락되었거나 관광객 수가 0명인 관광지는 데이터 수집 오류로 간주하고 분석에서 제외하였다.

본 연구에서는 Hyndman & Khandakar(2008)의 자동시계열예측(Automatic time series forecasting)을 활용하여 수백여 개의 관광지의 수요를 자동적으로 예측한다. 본 연구에서는 다음의 네 가지 시계열 예측모형을 고려한다.

- 예측모형-1: automatic ARIMA, 주기 12개월
- 예측모형-2: automatic ARIMA, 주기 12개월, log 변환
- 예측모형-3: automatic exponential smoothing, 주기 12개월
- 예측모형-4: automatic exponential smoothing, 주기 12개월, log 변환

최적의 예측모형을 도출하기 위한 예측모형 검증 방법은 다음과 같다. 예측모형의 학습데이터는 최대 8년치 (96개, 2011년 1월에서 2018년 12월)에서 최소 2년치 (24개, 2017년 1월에서 2018년 12월)를 적용한다. 검증데이터는 1년치 (12개, 2019년 1월에서 2019년 12월) 데이터를 이용한다.

예측모형의 평가지표는 MSE(Mean Squared Error)와 MAPE(Mean Absolute Percentage Error)를 활용한다. 모형의 상대적 비교는 검증 MSE를 활용한다. 음수 예측치가 없고 검증 MSE가 가장 작은 모형을 최종 예측모형으로 활용한다. 예측 모형의 절대적 비교인 예측모형의 적절성은 검증 MAPE를 활용한다. 윤성준, 이희찬 (2022)이 참고한 Lewis(1982)의 기준을 활용하여 MAPE가 50% 이하로 예측 성능이 합리적인 경우만 분석대상으로 삼았다(<표 2> 참고). 아울러, 연구자의 주관적인 시각화 평가를 통해 부적절한 예측을 배제하였다.

<표 1>과 <표 2>와 같이 서울, 인천, 경기도, 강원도에 속한 관광지식정보시스템의 1372개 관광지 중에서, 데이터 기준으로 136개 관광지가 분석 대상으로 선정되었고, 이 중에서 예측성능 기준으로 최종적으로 117개 관광지를 최종 분석 대상으로 선정하였다.

<표 1> 전체 및 분석 대상 관광지 개수

지역	주요관광지점 입장객통계	데이터 기준	예측성능 기준
서울특별시	23	2	2
인천광역시	96	8	8
경기도	587	64	55
강원도	666	62	52
합계	1372	136	117

<표 2> 예측성능 기준 관광지 개수: 검증 MAPE 및 시각화 평가

MAPE 기준 예측성능 분류		MAPE 기준	시각화 평가 기준
매우 우수	10% 미만	8	8
우수	10% ~ 20%	48	48
합리적	20% ~ 50%	62	61
부정확	50% 초과	18	15
합계		136	132

마지막으로 관광지별 최종 수요예측은 최대 9년치 (108개, 2011년 1월에서 2019년 12월)에서 최소 3년치 (24개, 2017년 1월에서 2019년 12월)를 적용하여 예측모형을 학습하고 코로나19 발생 이후 2020년 월별 수요데이터 11개 (2020년 2월에서 2020년 12월)을 예측한다. 각 관광지의 예측치가 가상적 통제집단의 데이터가 된다.


유의수준 5%를 기준으로 코로나19 발생 후 관광수요의 증가 및 감소 여부를 통계

적으로 분석한 결과는 <표 3>과 같다. 분석 대상인 117개 관광지 중에서 관광수요가 감소했다고 판정된 관광지는 39%이고 관광수요의 변화가 없다고 판정된 관광지는 57% 수준이다. 아울러, 소수이기는 하나 관광수요가 증가한 관광지도 존재한다.

<표 3> 코로나19 발생 이후 관광지별 관광수요 변화 분석 결과

지역	관광지 개수				관광지 비율		
	평가대상	감소	변화없음	증가	감소	변화없음	증가
서울특별시	2	2	0	0	100%	0%	0%
인천광역시	8	2	5	1	25%	63%	13%
경기도	55	24	29	2	44%	53%	4%
강원도	52	18	33	1	35%	63%	2%
합계	117	46	67	4	39%	57%	3%

<그림 1>은 코로나19 발생 이후 관광수요가 감소, 변화없음, 증가했다고 판정된 관광지의 월별 입장객 수 및 예측치 사례이다.



<그림 1> 관광지별 월별 입장객 수 및 예측치: 왼쪽 (코로나19 이후 수요 감소), 가운데 (코로나19 이후 수요 변화 없음), 오른쪽 (코로나19 이후 수요 증가).
그림에서 실선은 실제 수요이고 점선은 예측치이다.

마지막으로 각 예측모형별로 자동시계열예측을 적용한 최적 예측모형은 각각 27, 31, 35, 24개가 적용되었다. 구체적인 예측모형은 <표 4> 및 <표 5>와 같다.

<표 4> ARIMA 모형

No	구분	합계	예측모형-1	예측모형-2
1	ARIMA(1,0,0)(0,1,1)[12]	5	3	2
2	ARIMA(1,0,0)(0,1,1)[12] with drift	3	1	2
3	ARIMA(0,0,0)(0,1,1)[12]	2	1	1
4	ARIMA(0,0,0)(1,1,0)[12] with drift	2	0	2
5	ARIMA(0,0,1)(0,1,1)[12] with drift	2	2	0
6	ARIMA(0,1,0)	2	1	1
7	ARIMA(0,1,1)(0,1,0)[12]	2	2	0

※ 한국연구재단 평가에 참여하는 평가위원은 평가에서 알게 된 비밀을 다른사람에게 누설하거나 직무상 목적 외 용도로 이용하여서는 안됩니다.(국가연구개발혁신법 제40조)

8	ARIMA(0,1,1)(0,1,1)[12]	2	1	1
9	ARIMA(0,1,1)(0,1,2)[12]	2	1	1
10	ARIMA(1,0,0)(1,0,0)[12] with non-zero mean	2	2	0
11	ARIMA(0,0,0)(0,1,0)[12] with drift	1	1	0
12	ARIMA(0,0,0)(0,1,1)[12] with drift	1	0	1
13	ARIMA(0,0,0)(2,1,1)[12] with drift	1	1	0
14	ARIMA(0,0,1) with non-zero mean	1	0	1
15	ARIMA(0,0,1)(0,1,1)[12]	1	0	1
16	ARIMA(0,0,1)(0,1,2)[12] with drift	1	1	0
17	ARIMA(0,0,1)(1,0,0)[12] with non-zero mean	1	1	0
18	ARIMA(0,0,1)(1,1,0)[12]	1	0	1
19	ARIMA(0,1,0)(0,0,1)[12]	1	1	0
20	ARIMA(0,1,0)(1,1,0)[12]	1	1	0
21	ARIMA(0,1,1)(1,1,0)[12]	1	0	1
22	ARIMA(0,1,2)(0,1,1)[12]	1	0	1
23	ARIMA(1,0,0)(0,1,0)[12] with drift	1	0	1
24	ARIMA(1,0,0)(1,1,0)[12] with drift	1	1	0
25	ARIMA(1,0,0)(1,1,1)[12]	1	1	0
26	ARIMA(1,0,0)(2,1,0)[12] with drift	1	0	1
27	ARIMA(1,0,0)(2,1,1)[12] with drift	1	1	0
28	ARIMA(1,0,1)(0,1,1)[12] with drift	1	1	0
29	ARIMA(1,0,1)(2,1,0)[12]	1	0	1
30	ARIMA(1,0,2) with non-zero mean	1	0	1
31	ARIMA(1,0,2)(1,1,0)[12]	1	0	1
32	ARIMA(1,1,0)(0,1,0)[12]	1	0	1
33	ARIMA(1,1,1)(0,1,1)[12]	1	0	1
34	ARIMA(1,1,1)(1,0,0)[12] with drift	1	0	1
35	ARIMA(1,1,1)(1,0,1)[12]	1	0	1
36	ARIMA(2,0,0) with non-zero mean	1	1	0
37	ARIMA(2,0,0)(0,1,1)[12]	1	0	1
38	ARIMA(2,0,0)(1,1,0)[12]	1	0	1
39	ARIMA(2,0,0)(2,0,0)[12] with non-zero mean	1	0	1
40	ARIMA(2,0,2)(0,1,1)[12] with drift	1	1	0
41	ARIMA(2,1,0)(1,1,0)[12]	1	0	1
42	ARIMA(2,1,1)(2,0,0)[12]	1	0	1
43	ARIMA(3,0,0)(0,1,1)[12] with drift	1	1	0
44	ARIMA(3,0,0)(2,0,0)[12] with non-zero mean	1	0	1
	합계	58	27	31

<표 5> exponential smoothing 모형

No	구분	합계	예측모형-3	예측모형-4
1	ETS(M,N,M)	27	23	4

※ 이를 위반할 경우 2년 이하의 징역 또는 2천만원 이하의 벌금에 처하게 됩니다.(국가연구개발혁신법 제41조)

2	ETS(A,N,A)	13	3	10
3	ETS(M,N,A)	9	1	8
4	ETS(A,A,A)	5	3	2
5	ETS(A,N,N)	1	1	0
6	ETS(M,A,A)	1	1	0
7	ETS(M,A,M)	1	1	0
8	ETS(M,Ad,M)	1	1	0
9	ETS(M,N,N)	1	1	0
	합계	59	35	24

(2) 코로나19의 관광수요 영향에 대한 관광지 특성의 개별적 인과효과 분석

본 연구에서는 대표적인 인과머신러닝 방법론인 DML을 활용하여 서울에서 관광지까지의 거리에 따른 코로나19에 의한 관광지 수요 변화를 분석한다.

대표적인 인과머신러닝 방법론인 DML의 수학적 구조는 다음과 같다.

$$\begin{aligned} Y &= \theta(X)T + g(X, W) + \epsilon \\ T &= f(X, W) + \eta \end{aligned}$$

여기에서 Y 는 결과(outcome), T 는 처치(treatment), X 는 특성(feature), W 는 X 의 Y 및 T 와 관련 있는 다른 속성으로 통제변수에 해당한다. 위 식에서 $\theta(X)$ 는 특성 X 의 함수로 $\theta(X)$ 를 통해 HTE를 추정한다. 즉, 샘플의 특성에 따른 처치효과를 함수형태로 추정한다.

DML에서는 X 와 W 를 통해 Y 와 T 를 예측하고, 두 예측 결과를 이용하여 $\theta(X)$ 를 추정한다. Y , T , $\theta(X)$ 의 예측에는 선형회귀를 비롯하여 gradientboosting과 같이 python의 머신러닝 패키지인 scikit-learn이 지원하는 대부분의 머신러닝 방법론을 적용할 수 있다(Oprescu et al., 2019).

본 연구에서 사용하는 변수 및 각 변수의 의미는 다음과 같다. 첫째, 처치변수 T 는 코로나19의 발생 여부를 의미한다. 코로나19 발생 이전이면 $T=0$ 이고 코로나19 발생 이후이면 $T=1$ 이다. 둘째, $Y_k(T)$ 는 결과변수로 처치에 따른 관광지 k 의 평균 관광객 수를 의미한다. $Y_k(T=0)$ 과 $Y_k(T=1)$ 은 각각 코로나19 발생 이전 및 이후, 관광지 k 의 평균 관광객 수이다. 국내에 2020년 1월에 코로나19가 발생했으므로 관광지 k 의 코로나19 발생 이전 및 이후 평균 관광객 수는 각각 2019년 2월에서 2019년 12월까지 월별 관광객 수 평균과 2020년 2월에서 2020년 12월까지 월별 관광객 수 평균을 이용하였다. 셋째, X_k 는 개별적 인과효과 분석 대상인 관광지 k 의 특성변수이다. 본 연구에서는 주요 수요처에서 관광지 k 까지의 거리를 관광지 특성변수로 고려한다. 본 연구에서는 서울시청에서 관광지 k 까지 거리로 X_k 를 정의하였다. 서울시청에서 특정 관광지까지의 거리는 네이버 지도 기준이며 km단위이다. 마

지막으로 통제변수 $W1_k$ 과 $W2_k$ 는 관광지 k 의 속성을 나타낸다. $W1_k$ 는 주요관광지점 입장객통계에서 제공하는 관광지 k 의 장소적 속성을 의미하며 관광지 k 가 문화, 자연 및 생태환경, 관광장소 및 시설 중 어느 속성에 속하는지를 나타낸다. 아울러, $W2_k$ 는 관광지 k 의 공간적 속성을 의미하며 실내, 실외, 복합 여부를 나타낸다.

관광지별 관광수요 데이터는 관광지식정보시스템의 주요관광지점 입장객통계를 활용하였다. 서울, 인천, 경기도, 강원도에 속한 1372개 관광지의 수요 데이터를 수집하였다. 주요관광지점 입장객통계에는 데이터 수집 시점이 관광지별로 상이하여 관광지별로 사용가능한 데이터의 시점 및 개수가 다르다. 아울러 누락된 데이터가 존재하는 관광지도 매우 많다. 본 연구에서는 코로나19 발생 이후 11개월 동안에 월별 관광객 수가 누락되었거나 0인 경우에는 수집오류로 간주하고 해당 관광지를 분석에서 제외하였다. 최종 분석 대상 관광지 수는 <표 6>과 같다.

<표 6> 지역별 분석대상 관광지 수


지역	주요관광지점 입장객통계	분석대상 관광지
서울특별시	23	5
인천광역시	96	12
경기도	587	124
강원도	666	107
합계	1372	248

본 연구에서는 <표 7>과 같이 2가지 모형을 적용하여 DML 모형을 분석하였다. 첫 번째 모형에서는 $\theta(X)$ 를 선형모형이라 가정하였다. 두 번째 모형에서는 $\theta(X)$ 의 비선형성을 고려하기 위해 Causal Forest 모형을 적용하였다.

<표 7> DML 모형

구분	DML 모형1	DML 모형2
모델 Y	Random Forest	Gradient Boosting
모델 T	Random Forest	Gradient Boosting
모델 θ	Linear model	Causal Forest

DML 모형의 분석결과는 <그림 2>와 같다. <그림 2>의 왼쪽 및 오른쪽 그림은 각각 $\theta(X)$ 에 선형모형을 적용한 DML 모형1 및 비선형 모형을 적용한 DML 모형2의 분석 결과이다. <그림 2>에서 검은색 점이 특성 X 의 개별적 인과효과이고 파란색 및 붉은색 점은 각각 유의수준 5%에서 개별적 인과효과의 상한 및 하한을 나타낸다. 아울러, DML 모형1의 계수 추정 결과는 <표 8>과 같다.



<그림 2> DML 분석 결과: (왼쪽) DML 모형1 (오른쪽) DML 모형2

<표 8> DML 모형1 계수 추정 결과

	point_estimate	stderr	zstat	pvalue	ci_lower	ci_upper
X	95.087	49.497	1.921	0.055	-1.926	192.1
cate_intercept	-22752.787	7902.748	-2.879	0.004	-38241.889	-7263.684

선형모형을 가정한 DML 모형1에서는 서울에서 관광지까지의 거리가 증가할수록 코로나19에 의한 관광수요의 감소 정도가 감소한다. 반면, 비선형 모형을 가정한 DML 모형2에서는 명확한 패턴을 말하기 어렵다. 따라서 거리에 따른 코로나19에 의한 관광수요의 변화를 명확하게 분석하기 위해, 첫째, 분석 대상 관광지의 개수를 늘리고, 둘째, 통제변수를 늘이는 방향으로 연구를 확장해야 한다.

Ⅲ. 연구결과 활용계획

1. 연구결과 활용계획

본 연구의 활용방안의 다음과 같다. 첫째, 본 연구에서는 국내 백여 개 관광지의 관광수요에 미치는 코로나19의 영향을 인과적으로 분석하였다. 따라서 코로나19와 같은 팬데믹 상황에서 미시적인 차원의 관광 정책 및 관광지 지원정책을 수립하고 실행하는데 유용하게 활용되리라 기대한다. 둘째, 본 연구에서는 기존 연구와 같이 통계 소프트웨어를 사용하여 특정 지역이나 섹터에 속한 소수 관광지의 수요를 개별적으로 수동으로 분석하는 대신 R과 파이썬을 활용하여 국내 백여 개 관광지의 관광 수요에 대한 분석을 한꺼번에 자동적으로 다루었다. 본 연구는 다수의 관광지를 종합적으로 다루는 일종의 종합분석툴이므로 관광 관련 국가기관, 연구소, 지방자치단체 및 민간기업에서 본 연구에서 제시한 방법론을 유용하게 활용할 수 있으

리라 기대한다. 최근, 인과추론 및 인과머신러닝은 인공지능의 추론 영역에 적용할 수 있기 때문에 인공지능 분야에서도 이에 대한 연구가 활발히 진행되고 있다 (Scholkopf et al., 2021). 따라서 시계열의 인과추론과 인과머신러닝을 다루는 본 연구가 사회과학을 비롯한 다양한 분야에서도 활용되리라 기대한다.

2. 연구성과

본 연구는 한국연구재단 등재학술지에 논문을 투고하기 위해 준비 중이다.

IV. 참고문헌

- [1] Abadie, A. (2021). Using Synthetic Controls: Feasibility, Data Requirements, and Methodological Aspects. *Journal of Economic Literature*, 59(2), 391-425.
- [2] Abadie, A., Diamond, A., & Hainmueller, J. (2010). Synthetic control methods for comparative case studies: Estimating the effect of California's tobacco control program. *Journal of the American statistical Association*, 105(490), 493-505.
- [3] Angrist, J. D., & Pischke, J. S. (2008). *Mostly harmless econometrics*. Princeton university press.
- [4] Angrist, J. D., & Pischke, J. S. (2014). *Mastering metrics: The path from cause to effect*. Princeton university press.
- [5] Athey, S., Tibshirani, J., & Wager, S. (2019). Generalized random forests. *The Annals of Statistics*, 47(2), 1148-1178.
- [6] Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2016). Double/debiased machine learning for treatment and causal parameters. *arXiv preprint arXiv:1608.00060*.
- [7] Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., & Newey, W. (2017). Double/debiased/neyman machine learning of treatment effects. *American Economic Review*, 107(5), 261-65.
- [8] Foster, D. J., & Syrgkanis, V. (2019). Orthogonal statistical learning. *arXiv preprint arXiv:1901.09036*.
- [9] Hyndman, R. J., & Khandakar, Y. (2008). Automatic time series forecasting: the forecast package for R. *Journal of statistical software*, 27, 1-22.
- [10] Kunzel, S. R., Sekhon, J. S., Bickel, P. J., & Yu, B. (2019). Metalearners for estimating heterogeneous treatment effects using machine learning. *Proceedings of the national academy of sciences*, 116(10), 4156-4165.
- [11] Lewis, G., & Syrgkanis, V. (2021). Double/debiased machine learning for dynamic treatment effects. *Advances in Neural Information Processing Systems*, 34.

- [12] Lewis, C. D. (1982). Industrial and business forecasting methods: A practical guide to exponential smoothing and curve fitting. Oxford:Butterworth-Heinemann.
- [13] McFowland, E., Gangarapu, S., Bapna, R., & Sun, T. (2021). A prescriptive analytics framework for optimal policy deployment using heterogeneous treatment effects. Forthcoming at MIS Quarterly.
- [14] Microsoft Research (2019), EconML, <https://github.com/Microsoft/EconML>.
- [15] Oprescu et al. (2019). EconML: A Machine Learning Library for Estimating Heterogeneous Treatment Effects, 33rd Conference on Neural Information Processing Systems (NeurIPS 2019), Vancouver, Canada.
- [16] Scholkopf, B., Locatello, F., Bauer, S., Ke, N. R., Kalchbrenner, N., Goyal, A., & Bengio, Y. (2021). Toward causal representation learning. Proceedings of the IEEE, 109(5), 612-634.
- [17] Varian, H. R. (2014). Big data: New tricks for econometrics. Journal of Economic Perspectives, 28(2), 3-28.
- [18] Varian, H. R. (2016). Causal inference in economics and marketing. Proceedings of the National Academy of Sciences, 113(27), 7310-7315.
- [19] Wager, S., & Athey, S. (2018). Estimation and inference of heterogeneous treatment effects using random forests. Journal of the American Statistical Association, 113(523), 1228-1242.
- [20] Zhao, Z., & Harinen, T. (2019, October). Uplift modeling for multiple treatments with cost optimization. In 2019 IEEE International Conference on Data Science and Advanced Analytics (DSAA) (pp. 422-431). IEEE.
- [21] Zou, W. Y., Du, S., Lee, J., & Pedersen, J. (2020). Heterogeneous causal learning for effectiveness optimization in user marketing. arXiv preprint arXiv:2004.09702.
- [22] 구진경. (2020). 포스트 코로나 19 관광산업 회복을 위한 정책 방향. 한국관광정책, (80), 60-64.
- [23] 권태일, 박소영. (2021). 2021년 상반기 주요관광지점 방문객 현황: 코로나 전후 관광지점 유형별 특성. 한국관광정책, (85), 108-117.
- [24] 윤성준, 이희찬. (2022). Bayesian VAR 모형을 이용한 국내 관광 수요의 코로나 영향력 추정 실내·외, 자연·인공, 대형·소형 유형 관광지 영향력 차이 분석. 관광학연구, 46(1), 83-104.
- [25] 주요관광지점입장객통계, 관광지식정보시스템(www.tour.go.kr), 한국문화관광연구원, 2022.
- [26] 최경은, 김형중. (2020). 코로나 19에 따른 관광시장 전망. 한국관광정책, (80), 30-38.