

<마케팅연구 편집위원회 귀중>

1. 논문제목 (영문제목 포함)

(국문) 데이터 중심 AI를 통한 마케팅 피로도와 구매 역동성 규명: 다중 접점 환경에서의 동태적 상태 변수와 XAI를 중심으로

(영문) **Unveiling Marketing Fatigue and Purchase Dynamics via Data-Centric AI:
Focusing on Dynamic State Variables and XAI in Multi-Touchpoint Environments**

2. 원고매수 : 총 28매 (부록 및 참고문헌 제외, 본문 쪽번호 기준)

3. 투고일자 : 2025.04.28

데이터 중심 AI 를 통한 마케팅 피로도와 구매 역동성 규명: 다중 접점 환경에서의 동태적 상태 변수와 XAI 를 중심으로

딥러닝의 다양한 성공사례에도 불구하고, 정보의 희소성이 높고 비선형적인 고객 관계 관리(CRM) 데이터 환경에서 딥러닝의 실효성은 여전히 의문으로 남아있다. 본 연구는 무조건적인 딥러닝 도입을 지양하고, 마케팅 이론을 데이터 모델링에 직접 결합하는 도메인 지식 기반 특성 공학(Domain-Knowledge Driven Feature Engineering) 프레임워크를 제안한다. 기존의 정적인 고객 프로파일링의 한계를 극복하기 위해, 본 연구는 소비자 습관화, 상황 의존적 선호, Buy Till You Die 모형 등의 마케팅 이론을 실시간 동태적 상태 변수(마케팅 피로도, 시점 역동성, 구매 주기 등)로 조작화하여 알고리즘의 귀납적 편향(Inductive Bias)으로 주입하였다. 매우 높은 희소성(전환율 0.12%)을 보이는 대규모 이커머스 데이터셋(REES46)을 실증 분석한 결과, 도메인 지식으로 강화된 경량화 트리 모델(XGBoost)이 복잡한 시계열 딥러닝 모델(LSTM, CNN 등)보다 성능과 효율성 측면에서 우수한 결과를 보임을 확인하였다. 제안된 프레임워크는 베이스라인 대비 F1-score 를 23.14% 향상시켰으며, 동일 목표 하에서 마케팅 전환 비용을 13.1% 절감할 수 있음을 입증하였다. 또한, SHAP 분석을 통해 단기적 예측 맥락에서 마케팅 피로도와 시점 역동성 변수가 전통적인 구매 이력과 상호작용하며 전환 예측 성능 향상에 중요한 기여를 함을 확인하였다. 본 연구는 모델 중심에서 데이터 중심 AI 로의 전환을 제안하며, 도메인 지식과 경량 알고리즘의 결합이 마케팅 조직의 동적 타겟팅 전략과 지속 가능한 디지털 전환을 위한 최적의 비즈니스 애널리틱스 해법임을 시사한다.

주제어: 데이터 중심 AI, 구매 전환 예측, 동태적 상태 변수, 마케팅 피로도, 설명가능한 AI

Unveiling Marketing Fatigue and Purchase Dynamics via Data-Centric AI: Focusing on Dynamic State Variables and XAI in Multi-Touchpoint Environments

Despite the various success stories of deep learning, its efficacy in Customer Relationship Management (CRM) environments characterized by highly sparse and non-linear data remains questionable. This study challenges the unconditional application of deep learning by proposing a “Domain-Knowledge Driven Feature Engineering” framework that directly integrates marketing theories into data modeling. To overcome the limitations of traditional static customer profiling, this study operationalizes established marketing theories—such as consumer habituation, context-dependent preference, and the Buy Till You Die model—into real-time dynamic state variables (e.g., marketing fatigue, temporal dynamics, and purchase cycles), injecting them as inductive biases into the predictive algorithm. Empirical analysis using the extremely sparse REES46 e-commerce dataset (0.12% conversion rate) demonstrates that a lightweight tree-based model (XGBoost) enhanced with domain knowledge shows superior results in both performance and computational efficiency compared to complex time-series deep learning architectures (e.g., LSTM, CNN). The proposed framework achieved a 23.14% improvement in F1-score over the baseline and demonstrated a 13.1% reduction in marketing conversion costs under the same target. Furthermore, SHAP analysis confirms that in a short-term prediction context, “marketing fatigue” and “temporal dynamics” variables interact with traditional purchase history, making a significant contribution to enhancing conversion prediction performance. Advocating for a shift from model-centric to Data-Centric AI, this research suggests that integrating marketing domain knowledge with lightweight algorithms offers an optimal business analytics solution for dynamic targeting and sustainable digital transformation strategies.

Keywords: Data-Centric AI, Purchase Conversion Prediction, Dynamic State Variables, Marketing Fatigue, Explainable AI (XAI)

I. 서론

오늘날의 고객은 즉각적으로 구매를 결정하지 않는다. 이메일을 열어보고, 며칠 뒤 모바일 푸시 알림을 확인하며, SMS 를 수신한 뒤에 비로소 결제 버튼을 누른다. 이처럼 산발적으로 흩어진 접점이 누적되어 하나의 복잡한 고객 여정(Customer Journey)이 완성된다(P. Harris, H. Pol, and G. Van Der Veen 2020). 기업 입장에서 이 파편화된 기록을 연결하여 누가 구매할지 예측하고, 한정된 마케팅 예산을 어디에 투입할지 결정하는 것은 수익성과 직결되는 지속 가능성을 위한 핵심 과제다. 그럼에도 불구하고 많은 기업 실무에서는 여전히 마지막 접점에만 기여도를 부여하거나, 임의 가중치를 부여하는 단순 휴리스틱 모델에 의존하고 있어, 최종 구매에 이르기까지 고객이 거처온 선행 접점들의 기여도를 과소평가하고, 구매 의사결정의 인과관계를 지나치게 단순화하는 결과를 초래한다.

디지털 전환이 가속화됨에 따라 현대 기업은 전례 없는 양의 고객 상호작용 데이터를 축적하고 있다. 고객 여정은 더 이상 선형적인 깔때기 구조가 아니라, 이메일 개봉, 앱 푸시 확인, 소셜 미디어 클릭 등 다채널에서 발생하는 파편화된 접점들의 비선형적 집합체로 진화하였다(S. Vasileva 2024). 기업들은 이러한 페타바이트 규모의 로그 데이터가 고객 행동을 완벽하게 설명해 줄 것이라는 데이터의 풍요를 기대하지만, 실제 분석 환경에서는 심각한 정보의 희소성 문제에 직면한다(R. Jia et al. 2017).

일반적인 이커머스 환경에서 구매 전환율은 2~3% 수준에 불과하며, 이는 전체 데이터의 97% 이상이 구매와 직접적 관련이 없는 노이즈(Noise)이거나 단순 탐색 행동임을 의미한다. 이러한 데이터의 희소성은 기계 학습 모델(J. Shin et al. 2022), 특히 최근 각광받는 딥러닝(Deep Learning) 모델의 학습을 저해하는 결정적 요인으로 작용한다. 딥러닝 모델은 고차원의 잠재 표현(Latent Representation)을 학습하기 위해 밀도 높은 데이터를 요구하므로, 고객 로그와 같이 데이터의 희소성이 높고 결측치가 빈번한 구조에서는 무의미한 노이즈를 학습하여 과적합(Overfitting) 될 위험이 크다.

최근 학계와 산업계에서는 이미지 인식이나 자연어 처리(NLP) 분야에서 트랜스포머(Transformer)와 같은 딥러닝 아키텍처가 거둔 우수한 성과를 바탕으로(A. Vaswani et al. 2017), 시계열 마케팅 데이터에도 Long Short-Term Memory(LSTM)이나 Recurrent Neural Network(RNN)을 적용하려는 시도가 주류를 이루고 있다(M. Du et al. 2019).

일부 선행연구는 딥러닝이 기존 머신러닝을 더 좋다고 보고하며, “주요 해결책은 딥러닝”이라는 암묵적인 전제를 강화해 왔다. 하지만 여기에는 중요한 맹점이 존재한다. 딥러닝의 높은 성과는 대개 데이터가 풍부하고 품질이 정제된 실험적 환경에서 도출된 결과다(C. Sun et al. 2017). 반면, 실제 기업의 고객 관계 관리(CRM) 데이터는 고객의 구매 행동이 드문드문 발생하는 희소성이 높고, 이벤트 간의 시간 간격이 불규칙하며, 온라인과 오프라인 기록이 혼재되어 있다. 이러한 희소한 데이터 환경에서는 수많은 파라미터를 가진 복잡한 딥러닝 구조가 이론만큼의 성능 우위를 발휘하지 못할 가능성이 높다(L. Grinsztajn, E. Oyallon, and G. Varoquaux 2022; W. Lindskog and C. Prehofer 2023). 데이터의 밀도가 낮은 상황에서 무조건적인 고비용 모델 도입은 연산 비용과 마케팅 운영 비용 측면에서 비효율적일 수 있다는 것이다(G. Farjon and A. Bar-Hillel 2022).

2024 년과 2025 년에 발표된 다수의 대규모 벤치마크 연구들은 정형 데이터(Tabular Data) 영역에서 딥러닝의 우월성에 대해 심각한 의문을 제기하고 있다. 이는 마케팅 예측의 문제가 단순히 더 깊은 모델을 사용하는 것이 아니라, 데이터의 특성에 맞는 적정 기술을 선택하는 문제임을 시사한다. 특히 정형 데이터의 불연속적 속성과 비선형적 경계로 인해, 딥러닝의 매끄러운 함수 근사보다는 트리 모델의 분할 방식이 오히려 더 적합한 귀납적 편향을 제공할 수 있다 (E. Beyazit et al. 2023; L. Grinsztajn et al. 2022).

본 연구는 딥러닝 모델이 겪는 데이터 희소성 문제를 해결하기 위한 대안으로, 도메인 지식 기반 특성 공학(Knowledge-based Feature Engineering)을 제안한다. 전통적인 CRM 문헌에서 활용된 Recency, Frequency, Monetary(RFM) 모형이나 확률 기반의 고객 생애 가치(CLV) 이론은 주로 과거의 집계된 데이터를 바탕으로 한 정적 모델링에 의존해 왔다. 따라서 다중 접점 환경에서 실시간으로 급변하는 고객의 동태적 상태, 즉 “마케팅 피로도”나 “시점 역동성”을 모형 내에 내재화하는 데에는 이론적, 방법론적 공백이 존재했다(J. Akter et al. 2025; L. Wathieu 2004). 본 연구에서 제안하는 “데이터 중심 AI 와 도메인 지식 기반 특성 공학”은 이러한 공백을 메우기 위한 시도이다 (D. Zha et al. 2025). 즉, 추상적인 마케팅 이론을 예측 모형이 실시간으로 처리할 수 있는 동적 상태 변수로 조작화함으로써, 마케팅 이론을 실증적으로 확장하고자 한다.

본 연구에서 제안하는 “지식 기반 특성 공학”이란, 단순한 통계적 데이터 전처리를 넘어, 소비자 행동을 설명하는 마케팅 이론(습관화, 고객 생애 가치 등)을 기계학습 모델이 직접 연산할 수 있는 수학적 함수나 동적 변수의 형태로 조작화하는 방법론적 과정을 의미한다.

또한, 이를 통해 모델에 “이론의 귀납적 편향을 주입”한다는 것은, 알고리즘이 아무런 사전 정보 없이 방대한 데이터 속에서 백지상태로 패턴을 탐색하게 두는 순수 데이터 기반 딥러닝 접근법과 명확히 대비되는 개념이다. 이는 마케터가 축적해 온 검증된 직관을 모델의 학습 과정에 명시적인 사전 지식이자 제약 조건으로 부여하는 것을 뜻한다. 기존의 순수 데이터 기반 접근법은 극도로 희소한 CRM 데이터 환경에서 유의미한 신호를 찾지 못하고 노이즈를 학습하여 과적합될 위험이 크다. 반면, 본 연구의 개념은 마케팅 도메인 지식을 모델의 탐색 공간을 효율적으로 좁혀, 데이터의 구조적 희소성을 극복하고 예측의 정확성과 설명 가능성을 동시에 달성하는 핵심 기제로 작용한다.

본 연구는 기존 마케팅 이론의 단순한 적용이나 검증에 머물지 않고, 이를 현대 디지털 이커머스 환경에 맞게 확장하는 데 목적이 있다. 전통적인 습관화 이론이나 켈런더 효과는 주로 거시적이고 집계된 관점에서 논의되었다면, 본 연구는 이를 개별 고객 단위의 실시간 동태적 상태 변수로 조작화함으로써 이론의 적용 범위를 미시적이고 실증적인 예측의 영역으로 확장한다.

- **RQ1.** [이론적 지식의 가치] 정적인 인구통계학적 정보나 과거 구매 이력 중심의 기존 변수에 마케팅 이론 기반의 “동적 상태 변수(피로도, 시점 역동성 등)”를 결합하는 것이, 고객의 구매 의사결정 메커니즘을 설명하는 데 어떠한 추가적인 기여를 하는가?
- **RQ2.** [설명 가능성과 매커니즘] 4 가지 마케팅 도메인 지식 축 중 구매 전환의 핵심 트리거로 작동하는 요인은 무엇이며, 블랙박스 모델 대비 이는 실무자에게 어떠한 해석 가능한 마케팅 전략의 근거를 제공하는가?
- **RQ3.** [모델 적합성과 자원 효율성] 희소성이 매우 높은 실제 디지털 마케팅 환경에서, 마케팅 이론이 귀납적 편향으로 주입된 경량화 트리 모델은 딥러닝 모델 대비 예측 정확도와 마케팅 자원 배분의 효율성을 어떻게 개선하는가?

결론적으로 본 연구의 차별적 기여도는 다음과 같다. 첫째, 기존 연구들이 고객 행동 이론을 단순한 서술적 배경이나 사후 해석의 도구로만 활용한 것과 달리, 본 연구는 추상적인 마케팅 이론을 머신러닝 모델이 학습 가능한 구체적인 수치형 벡터로 변환하는 체계적인 프레임워크를 제안한다. 이는 도메인 지식을 알고리즘의 귀납적 편향으로 주입하여, 데이터가 희소한 환경에서도 모델이 신호와 소음을 효과적으로 구분할 수 있게 한다. 둘째, 단순히 누가 구매할 것인지를 맞추는 블랙박스 예측을 넘어, SHAP(SHapley

Additive exPlanations) 분석을 통해 "왜 지금이 마케팅 적기인가?"를 설명할 수 있는 모델을 구현하였다. 특히 마케팅 피로도와 재구매 준비도가 구매 예측에 미치는 비선형적 기여도를 시각화함으로써, 실무자가 직관적으로 이해하고 마케팅 액션을 취할 수 있는 데이터 기반의 단서를 제공한다. 셋째, 최근 학계의 Tabular Data 에서의 딥러닝과 머신러닝 경쟁 논쟁에 기여하여, 구매 전환율이 극도로 낮은(0.12%) 실제 CRM 데이터 환경에서는 복잡한 딥러닝의 표현 학습보다 잘 설계된 도메인 특성을 장착한 경량 모델이 예측 성능과 일반화 능력 면에서 더 우월함을 실증적으로 규명한다. 이는 무조건적인 고비용 딥러닝 도입을 경계하고, 데이터 특성에 맞는 적정 기술의 중요성을 입증한다.

본 논문의 구성은 다음과 같다. 2 장에서는 관련 선행 연구를 고찰하고 본 연구의 지식 기반 변수 설계 근거를 제시한다. 3 장에서는 연구 실험 과정에서 사용된 데이터와 분석 알고리즘과 검증 방향을 상세하게 소개하고, 4 장에서는 각 실험 결과와 해석을 소개한다. 마지막으로 5 장 토의에서 연구의 이론적 및 실무적 시사점과 한계를 논의한 후, 6 장에서 연구 결과를 요약하며 마무리한다.

II. 문헌연구

본 연구는 마케팅 <표도메인 지식과 최신 기계학습 방법론의 융합을 통해 최소한 고객 데이터 환경에서의 예측 성능을 극대화하고자 한다. 이를 위해 (1) 고객 생애 가치 및 행동 이론의 진화, (2) 정형 데이터 환경에서의 딥러닝과 트리 기반 모델 간의 성능 논쟁, (3) 도메인 지식을 활용한 특성 공학의 이론적 타당성, (4) 설명 가능한 AI의 필요성을 중심으로 선행 연구를 고찰한다.

2.1 고객 행동 이론의 진화

2.1.1 고객 생애 가치와 RFM 프레임워크

고객 가치를 평가하는 가장 고전적이면서도 강력한 프레임워크는 RFM 모형이다. 초기 연구들은 RFM 지표가 미래 수익성과 강한 상관관계를 가짐을 실증하였다. 그러나 단순한 집계 방식의 RFM은 고객의 이탈(Churn) 시점을 명시적으로 알 수 없는 비계약적 환경에서의 행동을 설명하는 데 한계를 보였다.

이를 극복하기 위해 D. C. Schmittlein, D. G. Morrison, and R. Colombo (1987)은 Pareto/NBD 모형을, P. S. Fader, Hardie, Bruce G. S., Lee, Ka Lok (2005)는 이를 개선한 BG/NBD 모형을 제안하며 Buy Til You Die (BTYD) 프레임워크를 확립하였다. 이들은 고객의 구매 이력을 확률 과정(Stochastic Process)으로 모델링하여 잠재적인 이탈 확률을 추정하였다. 특히 이들이 제기한 빈도의 역설(Paradox of Frequency)은 구매 빈도가 높더라도 최근성(Recency)이 개인의 평균 주기보다 길어지면 이탈 확률이 급격히 증가한다는 현상을 언급하였다.

최근 연구들은 CLV 추정의 정교화를 위해 기계학습 기법과의 융합을 시도하고 있다. 예를 들어, 고객의 웹 브라우징 세션을 임베딩(Embedding) 기술로 벡터화하여 거래 가치를 예측하는 방법론이 제안되는 등(B. P. Chamberlain et al. 2017) 전통적인 확률 모형의 한계를 보완하려는 시도가 이어지고 있다. 그러나 이러한 접근법은 대부분 모형의 복잡성 증대에 초점을 맞추고 있으며, 도메인 지식을 명시적으로 통합하는 시도는 여전히 제한적이다. 본 연구는 이러한 간극을 메우고자, 현재 시점이 고객의 평균 재구매 주기에 얼마나 근접했는지를 확률 밀도 함수로 정량화하는 재구매 준비도 지표를 제안한다.

2.1.2 시계열적 역동성과 피로도 이론

소비자의 반응은 물리적 시간의 흐름과 마케팅 자극의 강도에 따라 비선형적으로 변화한다. Y. Koren (2009)의 연구는 사용자 선호가 고정된 것이 아니라 시간에 따라 표류한다는 사실을 규명하며 시점 역동성 모델링의 중요성을 강조하였다. 그는 추천 시스템 분야에서 협업 필터링(Collaborative Filtering) 모델에 시간 의존적 편향(Time-varying Bias)을 도입함으로써, 예측 정확도를 유의미하게 개선하였다. 이러한 연구는 시간적 맥락이 예측 모델에 필수적으로 통합되어야 함을 보여주는 이론적 토대를 제공한다.

최근 이커머스 환경에서는 행동 경제학 및 마케팅 분야의 연구를 기반으로 특정 요일이나 급여일 전후로 구매 확률이 변동하는 캘린더 효과가 주요한 예측 변수로 다루며 특정 시점에 소비자의 구매력과 지출 성향이 일시적으로 변동함을 실증하였다(A. Olafsson and M. Pagel 2018). 이러한 발견은 본 연구에서 제안하는 급여일 근접도 및 분기말 근접도 변수의 이론적 정당성을 뒷받침한다. 특히 2020 년 이후 팬데믹, 인플레이션 등 거시 충격이 소비 패턴을 급변시키면서, 시간 의존적 모델링의 실무적 중요성은 더욱 부각되고 있다. 또한, 인간의 생체 리듬이 인지적 성과에 미치는 영향을 규명한 연구 (T. Althoff et al. 2017)의

통찰을 마케팅 맥락에 적용하면, 고객의 활동 시간대와 일치하는 시점의 메시지 전달이 정보에 대한 인지적 수용성을 극대화할 수 있음을 시사한다. 본 연구는 이러한 통찰을 반영하여, 현재 발송 시점과의 코사인 거리를 산출함으로써 선호 시간대와 얼마나 일치하는지 정도를 변수를 구성하였다.

한편, 정보 처리 이론(Information Processing Theory)과 습관화 이론은 반복적인 마케팅 자극이 소비자의 주의를 감소시키고 반응 역치를 높인다고 설명한다. 이는 마케팅 피로도도 개념화되며, 과도한 메시지 노출이 오히려 클릭률과 전환율을 저하시키는 역 U 자형 관계를 형성함을 시사한다 (I. Chae, H. A. Bruno, and F. M. Feinberg 2019). 심리학의 베버-페히너 법칙(Weber-Fechner Law)에 따르면 동일한 자극의 반복은 감각 역치를 상승시킨다. 본 연구는 이러한 원리를 마케팅에 적용하여, 과도한 메시지가 고객의 변별력을 저하시키고 피로도를 유발한다는 점에 주목한다.

최근 추천 시스템 분야의 연구는 이러한 피로도 개념을 정보 필터링의 맥락으로 확장하였다. C.-N. Ziegler et al. (2005)은 추천 목록 내 항목 간 유사도가 높을수록 사용자의 만족도가 저하됨을 실증하였으며, 이를 한계 효용 체감의 법칙으로 해석하였다. 이들의 연구는 공간적 차원에서의 유사성이 효용 감소를 유발한다는 점을 보였으나, 본 연구는 이를 시간적 차원으로 확장하여, 동일 채널을 통한 반복적 메시지 노출이 시간의 흐름에 따라 피로도를 누적시킨다는 가설을 제안한다. 최근 연구들은 이러한 피로도를 모델링하기 위해 지수 감쇠(Exponential Decay) 함수 등을 도입하고 있으나, 이를 머신러닝의 입력 변수로 동적으로 구현하여 최적화한 시도는 여전히 부족하다. 본 연구는 이러한 이론적 배경을 바탕으로, 채널별 반감기를 고려한 누적 피로도 함수를 제안하여 모델에 내재된 과적합 위험을 제어하고자 한다. 실제 각 채널의 피로도 반감기는 매체의 침해성과 고객 반응 임계점에 대한 선행 연구를 기반으로 차등 설정되었다. 특히, 최근 노출 빈도와 마지막 노출 후 경과 시간을 결합한 복합 감쇠 함수를 적용하였으며, 매체별 특성에 따라 $SMS(\kappa = 1.5, \tau = 72) < 푸시(\kappa = 2.0, \tau = 24) < 이메일(\kappa = 4.0, \tau = 48)$ 순으로 파라미터를 정의하였다.

2.1.3 마케팅 콘텐츠 신규성 및 경로 효율성 이론

마케팅 메시지의 효과는 단순히 노출 빈도나 타이밍에만 의존하지 않으며, 메시지 자체의 내용적 특성과 고객의 과거 경험 간의 상호작용에 의해 조절된다. 이러한 관점은 크게 두

가지 이론적 흐름으로 구분된다: (1) 콘텐츠 신규성이 주의 환기와 정보 가치에 미치는 영향, (2) 설득 경로의 구조적 효율성이 전환 확률에 미치는 영향이다.

콘텐츠 신규성의 중요성은 정보 이론과 심리학의 새로운 선호 연구로부터 도출된다. C. E. Shannon (1948)의 정보 엔트로피 개념에 따르면, 예측 가능한 메시지는 정보량이 낮으며 수신자에게 전달하는 가치가 제한적이다. 반면, 새로운 정보는 높은 엔트로피를 가지며 주의를 환기시키는 효과가 크다. 마케팅 맥락에서 이는 동일한 주제나 제안의 반복적 노출이 정보의 한계 효용을 감소시킨다는 것을 의미한다. C.-N. Ziegler et al. (2005)는 주제 다양화를 통해 완화할 수 있음을 보였다. 본 연구는 이러한 공간적 유사성 개념을 시간적 차원으로 전환하여, 특정 주제에 대한 최근 노출 빈도와 마지막 노출 이후 경과 시간을 결합한 복합 감쇠 함수를 제안한다.

설득 경로 효율성은 고객 여정 연구의 핵심 주제이다. 전통적인 Attention, Interest, Desire, Action(AIDA) 모델이나 깔때기 프레임워크는 선형적 단계를 가정하지만, 현대의 옴니채널 환경에서 고객 여정은 고도로 비선형적이며 개인별로 이질적이다(K. N. Lemon and P. C. Verhoef 2016). 디지털 전환 이후 전통적 선형 모델이 비선형 및 다중 접점 고객 여정 모델로 대체되는 패러다임 전환이 진행 중이며, 이러한 복잡성 속에서 특정 채널 조합이 전환으로 이어지는 성공 경로를 식별하는 것은 마케팅 효율성 극대화의 핵심 과제로 부상하였다. E. Anderl et al. (2016)은 그래프 기반 마코프 모델(Markov Graph Model)을 활용하여 온라인 광고 채널 간의 기여도를 정량화하였다. 전통적인 Last-Click 귀속 모델이 초기 접점의 기여를 과소평가한다는 점을 실증하였으며, 채널 간 상호작용을 고려한 속성 분석의 중요성을 강조하였다. 특히 그들이 발견한 경로 의존성 현상, 즉 동일한 채널이라도 선행 접점의 구성에 따라 효과가 달라진다는 결과는, 본 연구에서 제안하는 성공 경로 일치도 변수의 이론적 근거를 제공한다.

2.2 지식 기반 특성 공학을 통한 이론의 귀납적 편향 주입 연구

마케팅 분야에서 도메인 지식을 데이터 분석에 통합하려는 시도는 오랜 역사를 가지고 있으나, 최근 머신러닝 및 인공지능 기술의 발전과 함께 그 양상이 질적으로 변화하고 있다. 전통적으로 도메인 지식은 모델링 이전 단계에서 변수 선택이나 데이터 전처리의 지침으로 활용되었으나, 최근 연구들은 이를 모델의 구조적 제약이나 학습 과정의 귀납적 편향으로

명시적으로 주입하려는 시도를 보이고 있다. 이러한 흐름은 크게 세 단계로 구분될 수 있다: (1) 초기 단계에서는 이론적 개념을 수작업으로 수식화 하여 변수로 변환하는 전통적 피처 엔지니어링이 주류를 이루었고, (2) 확장 단계에서는 AutoML 과 같은 자동화 도구가 피처 생성 및 선택 과정을 효율화 하였으며, (3) 최근에는 거대언어모델(LLM)을 활용하여 이러한 지식들을 반영하는 자동화 시도가 등장하고 있다. 이는 도메인 지식이 인간 전문가의 전유물이 아니라, 방대한 텍스트 데이터에서 추출 가능한 일반화된 지식임을 시사한다. 본 연구는 이러한 흐름의 연장선상에서, 도메인 지식을 체계적으로 변수화하는 프레임워크를 제시한다.

P. S. Fader, B. G. Hardie, and K. L. Lee (2005)은 RFM 이론을 Pareto/NBD 확률 모형과 연결함으로써, 고객의 구매 이력이라는 관찰 데이터를 잠재적 행동 성향의 충분통계량으로 변환하였다. 이는 단순히 과거 데이터를 집계하는 것을 넘어, 확률 모형의 파라미터 추정을 통해 미래 행동을 예측 가능한 형태로 정제한다는 점에서 의의가 있다. V. Kumar et al. (2019)은 고객의 소셜 네트워크 구조와 과거 구매 이력을 결합하여 영향력 점수라는 파생 변수를 생성하였으며, 이를 추천 시스템에 투입함으로써 예측 정확도를 개선하였다. 이들의 접근법은 사회적 영향력 이론을 네트워크 중심성 지표로 조작화한 것으로 볼 수 있으며, 본 연구의 방법론적 지향과 유사한 맥락을 공유한다. A. Lambrecht and C. Tucker (2013)는 리타겟팅 광고의 빈도가 과도할 경우 오히려 전환율이 감소하는 역 U 자형 관계를 실증하였으며, 이는 피로도 현상의 경험적 증거로 해석된다. 그러나 이들의 연구는 집계 수준의 분석에 한정되어 있어, 개별 고객의 피로도를 동적으로 추적하는 메커니즘을 제공하지 못한다.

최근에는 거대언어모델을 활용한 연구들이 위치한다. 전자상거래 분야에서는 LLM 을 이용해 상품 설명 텍스트로부터 자동으로 마케팅 관련 특성(예: 계절성, 가격 민감도)을 추출하고, 이를 수요 예측 모델의 입력으로 활용하는 프레임워크를 제안하였다(H. Zhang et al. 2024). 이러한 접근법은 도메인 지식이 인간 전문가의 암묵지가 아니라, 방대한 텍스트 데이터로부터 추출 가능한 명시적 지식으로 전환될 수 있음을 시사한다. 그러나 LLM 기반 접근법은 생성된 특성의 해석 가능성과 인과적 타당성이 보장되지 않는다는 근본적 한계를 갖는다. X. Wang et al. (2019)은 사용자 프로필과 맥락 정보를 그래프 신경망에 통합하는 딥러닝 방법론을 제안하였다. 이와 달리, 본 연구는 복잡한 딥러닝 아키텍처를 구축하는 대신, 도메인 지식 자체를 경량화된 피처로 조작화하여 실무적 예측 효율성을 극대화하는 대안적 방향을 취한다.

2.3 정형 데이터 분석에서의 알고리즘 논쟁

최근 학계, 특히 2024 년과 2025 년의 주요 화두 중 하나는 정형 데이터 영역에서 딥러닝이 과연 전통적인 트리 기반 모델을 능가하는가에 대한 논쟁이다 (Y. Gorishniy, A. Kotelnikov, and A. Babenko 2024; L. Grinsztajn et al. 2022). 이미지(Convolutional Neural Network, CNN)나 텍스트(Transformer) 분야에서 딥러닝이 거둔 매우 높은 성과에 힘입어, 마케팅 분야에서도 고객 행동 로그를 시계열 데이터로 간주하고 LSTM 이나 TabNet, TabTransformer 와 같은 딥러닝 아키텍처를 적용하려는 시도가 급증했다 (S. Ö. Arik and T. Pfister 2021; Q. Chen et al. 2019; X. Huang et al. 2020). 이들은 딥러닝이 수작업 특징 추출 없이도 원시 데이터로부터 고차원의 잠재 표현을 학습할 수 있다는 End-to-End 학습의 장점을 강조한다(Y. Gorishniy et al. 2024).

W. Verbeke et al. (2012)은 로지스틱 회귀, 의사결정나무, 서포트 벡터 머신 등 다양한 알고리즘을 비교하였으며, 앙상블 기법(Ensemble Methods)이 단일 모델 대비 우수한 성능을 보임을 실증하였다. 이후 XGBoost 와 LightGBM 과 같은 그래디언트 부스팅 계열 알고리즘이 Kaggle 경진대회 등에서 매우 높은 성능을 보이며 실무 표준으로 자리잡았다. L. Grinsztajn et al. (2022)은 45 개의 데이터셋을 대상으로 한 대규모 실험을 통해, 트리 기반 모델이 ResNet, Transformer 등의 딥러닝 모델보다 정형 데이터에서 일관되게 우수한 성능을 보임을 실증하였다. 이러한 발견은 본 연구가 회소한 CRM 데이터 환경에서 트리 기반 모델을 기준 모델로 선택한 이론적 근거를 제공한다. 이러한 결과는 딥러닝이 정형 데이터에서 절대적 우위를 점하기보다는, 특정 조건에서만 그 효용이 발휘됨을 시사한다.

물론 딥러닝 진영의 반격도 지속되고 있다. K.-Y. Chen et al. (2023)은 정형 데이터 처리에 특화된 새로운 딥러닝 아키텍처를 제안하며, 딥러닝이 구조적 한계를 극복하고 트리 모델과 대등하거나 이를 능가할 수 있는 가능성을 제시하였다. 본 연구는 이러한 학계의 양립된 논의를 수용하여, 단일 모델에 얽매이기보다는 데이터의 회소성 특성에 부합하는 도메인 지식의 융합에 초점을 맞춘다. 최근 2025 년에 발표된 연구들 또한 딥러닝 모델이 하이퍼파라미터 튜닝에 극도로 민감하며, 학습 비용 대비 성능 효율성이 트리 모델에 미치지 못하는 경우가 많음을 지적한다(V. Attari and R. Arroyave 2025). 이러한 현상이 발생하는 핵심 원인은 데이터의 회소성과 모델의 귀납적 편향의 불일치에 있다(E. Beyazit et al. 2023; L. Grinsztajn et al. 2022).

따라서 본 연구는 무조건적인 딥러닝 도입을 지양하고, 데이터의 특성에 적합한 모델을 베이스라인으로 선정하되, 딥러닝의 한계를 극복하기 위한 새로운 접근법을 모색한다.

2.4 설명가능한 AI

예측 모델의 성능만큼이나 중요한 과제는 모델의 결과를 마케터가 신뢰하고 의사결정에 활용할 수 있는가이다. 2025 년 현재, 단순히 학술적 관심사를 넘어, 유럽의 AI 법안(EU AI Act) 등 규제 환경의 변화로 인해, 예측 모델의 투명성은 선택이 아닌 필수가 되었다(EU 2024; P. Hacker 2024). 딥러닝 모델, 특히 순환 신경망은 내부 작동 원리를 파악하기 어려운 블랙박스로 간주된다. 반면, 트리 기반 모델은 SHAP 값과 결합될 때 각 변수가 예측에 기여한 정도를 게임 이론에 기반하여 정량적으로 분해할 수 있다(S. M. Lundberg et al. 2020; S. M. Lundberg and S.-I. Lee 2017). 이는 마케터에게 “왜 이 고객에게 추천해야 하는가?”에 대한 근거를 제공하여, AI 도입의 가장 큰 장벽인 신뢰 문제를 해결한다.

LIME(Local Interpretable Model-agnostic Explanations)은 M. T. Ribeiro, S. Singh, and C. Guestrin (2016)이 제안한 사후 해석 기법으로, 예측하려는 관측치 주변의 국소 영역에서 선형 모델을 근사함으로써 설명을 생성한다. LIME 은 모델에 구애받지 않는 특성 덕분에 딥러닝 모델에도 적용 가능하나, 국소 근사의 안정성이 보장되지 않으며 반복 실행 시 설명이 변동할 수 있다는 한계가 있다(D. Alvarez-Melis and T. S. Jaakkola 2018). 본 연구는 SHAP 의 공리적 안정성을 우선시하여 LIME 은 보조적으로만 활용한다. 트리 모델과 SHAP 의 결합은 특히 강력한 설명력을 제공한다. TreeSHAP 알고리즘(S. M. Lundberg et al. 2020)은 트리 앙상블 모델에 대해 정확한 Shapley Value 를 다항 시간에 계산할 수 있으며, 이는 모델의 예측을 개별 관측치 수준에서 완전히 분해 할 수 있음을 의미한다. 본 연구는 이러한 기법을 활용하여, 최종 모델이 어떤 변수들의 조합을 통해 고성능을 달성했는지를 규명하며, 특히 제안된 도메인 지식 변수들이 기존 베이스라인 변수 대비 어떤 차별적 설명력을 갖는지를 비교 분석한다.

III. 데이터 및 방법론

3.1 데이터 수집 및 특성

본 연구는 제안하는 도메인 지식 기반 예측 방법론의 실증적 유효성과 실무적 재현성을 확보하기 위해, 대규모 이커머스 환경의 실제 로그를 담고 있는 Kaggle 의 "E-commerce multichannel direct messaging 2021-2023" 데이터셋(REES46)을 분석 대상으로 선정하였다. 이 데이터는 2021 년부터 2023 년까지 2 년간 중형 이커머스 플랫폼에서 수집된 CRM 기반의 마케팅 메시징 로그로, 개인화된 이메일, 웹이나 모바일 푸시 등의 프로모션과 리텐션(Retention) 활동을 포함한 실제 비즈니스 상 전자제품, 화장품, 다품목 스토어 등 다양한 카테고리의 운영 기록을 익명화하여 구성한 것이다. 구체적으로 해당 데이터셋은 총 1 억 7,200 만 건의 방대한 메시지 발송 로그를 포함하고 있으며, 약 185 만 명의 사용자를 대상으로 총 1,907 개의 마케팅 캠페인의 실행 이력이 포함되어 있다.

분석에 활용된 원시(Raw) 데이터는 고객의 메시지 수신 및 반응 로그를 중심으로, 이를 설명하는 캠페인 속성, 고객 속성, 그리고 외부 시점 정보가 포함된 4 개의 관계형 테이블로 구성된다(<표 1>). 그리고 캠페인 유형은 고객의 프로파일이나 프로모션과 직접적인 연관이 있는 것들로 제한하였고, 단순한 거래 진행 현황과 같은 정보들의 캠페인은 제외하였다. 이들은 전처리 과정을 통해 통합되어, 후술할 도메인 지식 기반 파생변수의 기초가 된다.

<표 1> 데이터테이블 주요 변수 구성 및 속성 설명

관계형 테이블	세부 속성 및 설명
메시지 전송 및 반응 로그 (Interaction Logs)	- 속성: 발송 시각(Timestamp), 채널(Channel), 플랫폼, 메시지 유형, 이메일 제공자 - 반응: Open, Click, Purchase 등 고객의 단계별 행동 데이터
캠페인 메타 정보 (Campaign Metadata)	- 속성: 캠페인 유형(Bulk/Trigger/Transactional), 주제(Topic), 마케팅 채널 - 설명: 마케팅 전략 및 운영 기간 등 공급자 측면의 의도(Intent) 정보
고객 관계 속성 (Customer Attributes)	- 속성: 고객 식별자(User ID), 최초 구매일(First Purchase Date) - 설명: 고객의 라이프사이클(Lifecycle) 단계 및 충성도를 추정하는 기준 정보
외부 시점 정보 (Temporal Context)	- 속성: 공휴일 여부, 요일, 월 정보 - 설명: 계절성(Seasonality) 및 사회적 이벤트가 소비에 미치는 외부 효과 정보

데이터의 이해도를 높이기 위해, 본 연구의 모델링에 활용되는 데이터의 구조적 특징은 크게 세 가지로 요약된다. 첫째, 단순히 특정 캠페인에 대한 반응이 포함된 것이 아니라 다양한 캠페인 반응을 포함한 고객의 다중 접점(Multi-touch) 여정을 반영하고 있다. 고객은 단 한 번의 메시지로 즉시 구매하지 않는다. 이메일, 앱 푸시, SMS 등 시간의 흐름에 따라 다양한 채널을 통해 메시지가 누적되며, 고객이 최종적으로 설득되거나 이탈하는 과정이

데이터에 포함되어 있다. 둘째, 최종적인 목표인 구매 여부 클래스의 불균형이 극심하다. 전체 발송 메시지 중 실제 구매로 이어진 비율은 약 0.12%에 불과하기 때문이다. 마지막으로 셋째는 메시지, 캠페인, 고객, 시간 정보가 서로 다른 식별자(Key)로 분리되어 있다. 따라서 이를 통합하여 개별 고객이 시간 흐름에 따라 겪는 경험을 하나의 시퀀스 형태로 재구성하는 전처리 과정이 필수적이다. 이러한 과정은 최종적으로 병합되어 향후 기술할 지식 기반 파생변수 생성의 기초가 된다.

나아가, 본 연구가 제안하는 특성 공학 프레임워크를 실제 기업 환경에 도입하기 위해서는 중요한 실무적 전제 조건이 요구된다. 모델이 의도한 성능을 발휘하려면 단순한 결제 중심의 데이터베이스를 넘어, 고객이 여러 채널(이메일, 푸시, SMS 등)에서 언제 상호작용했는지를 실시간으로 추적할 수 있는 “다중 점점 통합 로깅 시스템”이 사전에 구축되어야 한다. 비록 본 데이터가 특정 지역의 플랫폼에서 수집되었으나, 해당 플랫폼은 다수의 상품 카테고리를 포괄하는 종합 이커머스 형태를 띠고 있다. 또한, 고객 행동 로그가 전형적인 메시지 수신 -> 오픈 -> 클릭 -> 구매로 이어지는 깔대기 구조로 구성되어 있고 마케팅에 대한 반응 곡선도 글로벌리 유사한 롱테일(Long-tail) 분포를 따르고 있기에, 본 연구의 결과가 일반적인 이커머스 환경에 충분히 일반화 될 수 있다고 판단된다

3.2 도메인 지식 기반 파생변수 프레임워크

본 연구는 제 2 장에서 고찰된 마케팅 이론의 추상적 개념들을 머신러닝 모델이 직접 학습 가능한 정량적 입력 벡터로 변환하는 이론의 조작화에 중점을 두었다.

첫째, 구매 및 재구매 주기 패턴은 고객 생애 가치(CLV) 이론을 기반으로 고객별 구매 주기의 규칙성을 정량화한다. 특히 행동 경제학의 “냉각기 효과”를 반영하여, 구매 직후 추가 구매 확률이 급감했다가 일정 주기가 지나면 다시 상승하는 기저 성향을 조작화하였다. 개별 고객의 과거 구매 간격 분포를 통해 현재 시점이 고객 고유의 구매 사이클상 어느 단계에 있는지를 산출하며, 상세한 산출 함수식은 <부록 1>에 명시하였다.

둘째, 시계열적 역동성 및 메시지 반응 패턴은 소비자 행동론의 “상황 의존적 선호”와 유통 관리의 “캘린더 효과”에 근거하여 시간적, 경제적 맥락을 반영한다. 원형 통계 기법을

통해 고객별 선호 시간대와의 일치도를 계산하고, 급여일이나 분기 말 등 가처분 소득 변화 시점에 대한 근접도를 모델링하여 마케팅 수용도의 변화를 포착한다.

셋째, 마케팅 피로도 및 상호작용 강도 패턴은 광고 심리학의 “광고 마모 효과 소비자 습관화 이론”을 기반으로 한다. 반복적인 마케팅 자극으로 인한 인지적 자원 고갈 상태와 회복 과정을 지수 감쇠 모델로 구현하여, 채널별 침해성에 따른 누적 피로도를 실시간으로 추적한다.

넷째, 마케팅 콘텐츠 신규성 및 경로 효율성 패턴은 정보 이론의 엔트로피 개념과 설득 경로의 구조적 효율성을 반영한다. 특정 주제에 대한 노출 빈도와 경과 시간을 결합하여 콘텐츠의 신선도를 측정하고, 과거 구매자들의 성공적인 채널 경로와 현재 고객 여정 간의 유사도를 산출하여 전환 가능성을 예측한다.

3.3 데이터 전처리 및 데이터셋 구축

본 연구는 파편화된 원시 로그 데이터가 내포한 고차원성과 희소성, 그리고 클래스 불균형(Class Imbalance) 문제를 해결하고 모델의 예측 타당성을 확보하기 위해 엄격한 전처리 파이프라인을 구축하였다.

첫째, 모델이 실제 마케팅 실무 환경과 동일한 조건에서 학습되도록 데이터 누수(Data Leakage)와 선견 편향(Look-ahead Bias)을 통제하였다. 관계형으로 분리된 테이블을 통합하여 개별 고객의 시계열적 고객 여정 시퀀스로 재구성하되, 모델의 입력은 예측 시점(t) 직전($t-1$)까지 관측된 과거 데이터로만 엄격히 제한하였다. 또한, 범주형 변수의 과도한 증가가 유발하는 “차원의 저주와 과적합”을 방지하기 위해 상위 빈도를 점유하는 핵심 범주만 보존하고 롱테일(Long-tail) 범주를 통합하는 차원 축소를 수행하였으며, 발송 이후 결정되는 사후 기술 변수들은 배제하였다.

둘째, 구매 전환율이 약 0.12%에 불과한 매우 높은 클래스 불균형 문제를 해결하기 위해 하이브리드 샘플링 전략을 채택하였다. 희소한 소수 클래스의 정보 손실을 방지하기 위해 1.7 억 건 중 실제 구매 로그는 전량 보존한 반면, 다수 클래스 편향을 막기 위해 비구매 로그는 양성 비율이 약 10%에 수렴하도록 무작위 언더샘플링을 수행하였다 (F. Thabtah et al. (2020))

3.4 예측 알고리즘 아키텍처 및 실험 설계


본 연구의 분석 대상인 고객 여정 로그는 채널 간의 상호작용과 시간 의존성에 의해 복잡적으로 결정된다. 본 연구는 도메인 지식 기반의 피처 엔지니어링을 통해 시계열적 맥락을 충분히 내재화했을 때, 전통적 머신러닝과 딥러닝 아키텍처가 각각 어떠한 예측 성능을 발휘하는가를 규명하고자 총 8 종의 알고리즘을 비교 분석하였다. 우선, 정형 데이터 분석에서 강건한 일반화 성능이 입증된 트리 기반 앙상블 모델인 Random Forest 와 XGBoost 를 객관적 평가를 위한 기준점(Baseline)으로 채택하였다. 이들은 본 연구에서 설계한 동태적 도메인 피처(구매 주기, 피로도 등)가 고객의 시간적 구조를 얼마나 효과적으로 정형 신호로 요약하고 있는지 검증하는 핵심 기준이 된다.

나아가, 딥러닝 아키텍처의 효용성을 다각도로 검증하기 위해 데이터의 위상학적 표현 방식과 귀납적 편향을 달리한 6 종의 신경망 모델을 구축하였다. 전역적 상호작용을 학습하는 MLP, 국소적 패턴 포착에 유리한 CNN, 그리고 순차적 정보의 필터링 능력을 갖춘 RNN 과 LSTM 을 단일 아키텍처로 구성하였으며, 이들의 장점을 결합한 하이브리드 구조(CNN-LSTM, RNN-LSTM)를 추가하였다. 이를 통해 복잡한 시퀀스 학습 능력을 갖춘 딥러닝 모델이 전환율 0.12%의 매우 높은 최소성을 띤 CRM 데이터 환경에서도 트리 모델 대비 유의미한 성능 우위를 제공할 수 있는지 실증적으로 검증하고자 한다. 각 모델의 최적화를 위한 하이퍼파라미터는 베이지안 최적화(Bayesian Optimization)를 통해 튜닝하였다.

3.5 모델 평가 및 검증

본 연구는 타겟 변수인 구매 전환의 매우 높은 클래스 불균형을 고려하여 단순 정확도(Accuracy)의 한계를 보완하고자 하였다. 이에 모델의 판별력과 마케팅 자원 배분의 효율성을 종합적으로 평가하기 위해 정밀도(Precision), 재현율(Recall), F1-score, 그리고 AUC(Area Under Curve)를 핵심 성능 평가 지표로 채택하였다.

IV. 실증 분석 결과



<그림 1> 제안하는 방법론의 프레임워크

4.1 하이퍼파라미터 최적화 및 검증 프로토콜

본 연구는 모든 비교 모델에 대해 동일한 학습, 검증 프로토콜을 적용하여 실험의 공정성을 확보하였다. 데이터는 시계열적 순서를 보존한 학습(Train), 검증(Validation), 테스트(Test) 분할을 유지하되, 학습 단계에서는 특정 데이터 분포에 의한 과적합을 방지하기 위해 5-fold 교차검증을 적용하였다. 이는 특정 데이터 조합에 의해 우연히 성능이 높게 나타나거나 미래의 정보가 과거 학습에 반영되는 편향을 원천 차단하기 위함이다. 각 알고리즘의 최적 하이퍼파라미터 탐색을 위해, 기존의 무작위 탐색 대비 수렴 속도와 탐색 효율이 우수한 Optuna 기반의 베이지안(Bayesian) 최적화 기법을 도입하였다. 탐색 공간(Search Space)은 각 모델의 구조적 특성을 반영하여 개별 설정되었으며, 자세한 파라미터 탐색 범위 및 최적값은 <부록 2>에 제시하였다. 검증 세트의 AUC 를 최대화하는 파라미터 조합을 최적해로 선정하였다. 아울러 Early Stopping 과 Pruning 기법을 병행하여 불필요한 연산 비용을 절감하고 일반화 성능을 극대화하였다.

4.2 지식 기반 파생변수의 통계적 특성 및 상관 구조

본 절에서는 제안된 도메인 지식 기반 파생변수들이 실제 고객 행동 데이터 내에서 어떠한 분포적 특성과 상호 의존성을 갖는지 검증한다. 이는 단순한 기초 통계 확인을 넘어, 모델링 입력 변수로서의 판별력과 변수 간 다중 공선성(Multicollinearity) 위험을 사전에 진단하기 위함이다.

우선, 지식 기반 파생변수의 기술통계 분석 결과(<부록 3>), 본 데이터셋은 이커머스 고객 행동의 전형적인 특징인 회소성과 비대칭성을 뚜렷하게 드러낸다. 첫째, 종속변수인 “메시지 발송 후 24 시간 이내 구매 전환 여부”의 양성 비율이 10%에 불과하고 주요 행동 변수들이 강한 롱테일 분포를 보이는 행동의 양극화가 확인된다. 둘째, 대다수 고객이 분석 시점 기준 물리적 제약을 벗어난 잠재적 활성 상태에 진입해 있으며, 셋째, 기업의 운영 패턴에 따른 외생적 시점 의존성이 관찰된다. 그리고 파생변수 간 상관관계 분석 결과(<부록 4>), 대부분의 변수가 0.2 미만의 낮은 선형 상관성을 보였다. 유일하게 구매 후 불응기만이 유의미한 음의 상관(-0.37)을 나타내어 행동 경제학의 냉각기 효과를 실증적으로 뒷받침한다. 이러한 낮은 선형성은 구매 의사결정이 복잡한 비선형적 상호작용에 의해 결정됨을 시사하며, 본 연구가 트리 기반 앙상블 및 딥러닝 모델을 채택한 당위성을 제공한다.

4.3 지식 기반 변수의 한계 기여도 분석

본 절에서는 제안한 4 가지 도메인 지식 축이 예측 성능에 미치는 고유한 기여분을 검증하기 위해, 베이스라인 모델에 각 피쳐 세트를 개별적으로 추가하는 절삭 실험을 수행하였다. 8 중 알고리즘의 평균 성능 변화를 요약한 결과는 <표 2>과 같다.

<표 2> 도메인 지식 축별 모델 평균 성능 개선 요약

지식 축 및 추가된 변수군	Precision	Recall	F1-score	Accuracy	AUC (ROC)
Baseline	0.8627	0.5581	0.6766	0.9458	0.959
+ 마케팅 채널 효과성	0.8872	0.5494	0.673	0.9464	0.949
	(+2.84%)	(-1.56%)	(-0.53%)	(+0.07%)	(-1.04%)
+ 구매 및 재구매 주기	0.8682	0.6161	0.7195	0.9514	0.9655
	(+0.64%)	(+10.39%)	(+6.34%)	(+0.59%)	(+0.68%)
+ 시계열적 반응 패턴	0.8807	0.6084	0.7114	0.9506	0.9673
	(+2.08%)	(+9.02%)	(+5.15%)	(+0.51%)	(+0.86%)
+ 마케팅 피로도 패턴	0.9514	0.7316	0.8248	0.9686	0.9707
	(+10.28%)	(+31.09%)	(+21.91%)	(+2.41%)	(+1.22%)

실험 결과, 4 가지 도메인 지식 축은 성능에 균일하게 기여하지 않고 명확한 위계적 역할을 수행함이 확인되었다. 주요 발견점은 다음과 같다. 첫째, 마케팅 피로도 패턴의 현저한 기여도가 관찰된다. 모든 실험 조건 중 피로도 변수군이 가장 뚜렷한 성능 향상을 견인하였다. 이는 최근의 노출 강도와 반응 저하 수준이 고객의 즉각적 전환 의도를 판별하는 가장 강력한 단기 신호임을 시사한다. 둘째, 구매 주기 패턴과 시계열적 반응 패턴 역시 F1-score 를 각각 6.34%, 5.15% 향상시켰다. 이는 물리적 시점 정보와 개인의 재구매 사이클이 단순한 보조 지표를 넘어, 내재된 구매 욕구가 실제 행동으로 증폭되는 최적의 타이밍을 결정하는 조절 변수 역할을 수행함을 의미한다. 셋째, 마케팅 채널 효과성 변수군은 유일하게 Recall 과 F1-score 의 소폭 하락(-0.53%)을 동반하였으나 Precision 은 향상(+2.84%)시켰다. 표면적인 지표 하락으로 보일 수 있으나, 이는 모델이 과거 성공 패턴과 일치하지 않는 모호한 케이스를 보수적으로 배제하여 타겟팅의 정밀도(Precision)를 높이는 필터 역할을 수행한 것으로, 비용 절감이 중요한 실무 환경에서 유의미한 트레이드오프 기제로 작용한다.

도메인 지식은 단순한 변수 결합이 아니라, 피로도에 의한 1 차 선별, 주기 및 시점에 의한 확률 증폭, 채널에 의한 효율화라는 단계적 의사결정 프로세스를 모델에 성공적으로 내생화하였음을 실증한다.

4.4 지식 기반 모델의 예측 성능 평가 및 설명력 검증

4.4.1 통합 지식 기반 알고리즘별 최종 성능 비교

<표 3>은 제안된 4 가지 도메인 지식 축을 모두 통합한 고차원 피쳐 공간 하에서, 각 알고리즘의 식별력과 분류 효율성을 종합적으로 검증한 결과이다. 실험 결과, 머신러닝 기반의 트리 앙상블 모델이 복잡한 심층 신경망 계열 대비 일관된 우위를 보였다. 우선, 도메인 특화 변수의 도입 효과가 통계적으로 뚜렷하게 나타났다. 전체 알고리즘 평균 기준 Accuracy 의 상승폭은 2.54%에 그쳤으나, 핵심 지표인 Precision, Recall, 그리고 F1-score 등 주요 분류 성능 지표가 상당폭 향상되었다. 이는 본 연구의 피쳐 엔지니어링이 단순히 데이터의 차원을 늘린 것이 아니라, 구매 의도 판별에 필요한 정보 이득을 구조적으로

극대화했음을 실증한다. 특히 최소한 구매 패턴을 포착하는 민감도가 수치적으로 개선된 점은 실무적 활용 가치를 뒷받침한다.

XGBoost 알고리즘은 모든 지표에서 최고 성능을 달성하였다. 특히 Recall(0.8438)과 Precision(0.9670)을 동시에 기록한 것은, 과잉 마케팅 비용을 통제하면서도 잠재 고객의 이탈을 방지해야 하는 비용-효익 트레이드오프를 최적 수준에서 해결했음을 의미한다. Random Forest 는 F1-score(0.8866)으로 준수한 성능을 보였으나, Recall(0.8203) 측면에서 XGBoost 에 소폭 열세를 보였다.

마지막으로, 딥러닝은 AUC 기준으로는 0.97~0.98 수준의 높은 값을 보였으나, 실질적인 분류 지표인 Recall 과 F1-score 에서는 트리 모델을 넘어서지 못했다. 특히 CNN 과 MLP 는 높은 Precision(0.97~0.93)에도 불구하고 낮은 Recall(0.62~0.69)을 기록하여, 확실한 패턴만 구매로 예측하는 보수적 경향을 드러냈다. 이는 정형 데이터 특유의 불연속적 초평면을 학습하는 데 있어, 딥러닝의 연속적 미분 가능 함수 보다는 트리 모델의 방식이 더 적합하다는 최근 연구 결과(L. Grinsztajn et al. 2022)와 맥을 같이한다. 이에 본 연구는 실무적으로 XGBoost 를 최종 예측 모델로 선정하고, Random Forest 를 보조적 검증 도구로 활용하는 하이브리드 앙상블 전략을 사용할 것을 추천한다.

<표 3> 전체 변수군 반영 시 알고리즘별 최종 성능

Algorithm	Precision		Recall		F1-score		Accuracy		AUC	
	Baseline	Total	Baseline	Total	Baseline	Total	Baseline	Total	Baseline	Total
XGB	0.8401	0.9670	0.6046	0.8438	0.7032	0.9012	0.9479	0.9811	0.9639	0.9926
RF	0.8564	0.9646	0.5928	0.8203	0.7007	0.8866	0.9483	0.9786	0.9641	0.9915
LSTM	0.8695	0.9267	0.5575	0.7686	0.6794	0.8403	0.9463	0.9701	0.9601	0.9833
CNN-LSTM	0.8499	0.9236	0.5810	0.7588	0.6902	0.8332	0.9468	0.9690	0.9653	0.9833
RNN-LSTM	0.8710	0.9428	0.5830	0.7444	0.6985	0.8319	0.9486	0.9693	0.9631	0.9827
RNN	0.8659	0.9311	0.5614	0.7248	0.6812	0.8151	0.9463	0.9664	0.9605	0.9733
MLP	0.8727	0.9381	0.5065	0.6934	0.6410	0.7974	0.9421	0.9640	0.9555	0.9490
CNN	0.8764	0.9783	0.4778	0.6203	0.6184	0.7592	0.9399	0.9599	0.9397	0.9177
Average	0.8627	0.9465	0.5581	0.7468	0.6766	0.8331	0.9458	0.9698	0.9590	0.9717
Gain	9.71%		33.82%		23.14%		2.54%		1.32%	

4.4.2 다차원 성능 평가 및 지식의 기여도


본 절에서는 4 가지 도메인 지식 축이 예측 성능에 미치는 상대적 기여도를 입체적으로 규명하기 위해, 레이더 차트(Radar Chart) 면적에 기반한 종합 평가 지표를 도입하였다. 이는

Precision, Recall, F1-score, Accuracy, AUC 의 5 대 핵심 지표를 5 각형의 축으로 매핑하고 그 내부 면적의 비율을 산출하는 방식이다. 이 레이더 차트는 특정 마케팅 지식 축이 비즈니스 성과에 기여하는 “다차원적 효용”을 평가하는 전략적 의사결정 도구로 기능한다. 차트의 각 축은 마케팅 실무의 핵심 KPI 와 직결된다. 예를 들어, 정밀도(Precision)는 타겟 마케팅의 헛방을 줄여 마케팅 예산을 절감하는 “비용 효율성 및 스팸 피로도 통제 역량”을 대변하며, 재현율(Recall)은 전환 가능한 잠재 고객을 놓치지 않는 “기회 포착 역량”을 의미한다. 따라서, 모든 비교군에 동일한 축 순서를 적용하여 도출된 레이더 차트의 전체 면적은 특정 변수군이 마케팅 비용 절감(Precision)과 기회 창출(Recall) 간의 상충 관계를 얼마나 성공적으로 극복하여 종합적인 마케팅 Return on Investment(ROI)를 극대화하는지를 시각적으로 진단하는 지표이다.

아울러 교차검증을 위해 5 개 지표의 산술평균을 포함하였고, 레이더 차트의 우선순위와 동일하게 나타났다. 분석 결과(<표 4> 및 <그림 2>), 지식 축들은 예측 성능에 균일하게 기여하지 않았으며, 마케팅 피로도(82.35%) > 시계열 반응(76.15%) > 구매 주기(74.50%) > 채널 효과성(67.87%) 순의 뚜렷한 위계적 구조를 형성하였다.

<표 4> 도메인 지식 변수 영향력 우선순위 및 최적 모델링 요약

우선순위	최적 알고리즘	Precision	Recall	F1-score	Accuracy	AUC	5 Average	Radar Chart
마케팅 피로도	RF	0.9388	0.7823	0.8534	0.9725	0.9873	0.9069	82.35%
시계열적 메시지 반응	XGB	0.8924	0.7216	0.7980	0.9627	0.9817	0.8713	76.15%
구매 및 재구매 주기	RF	0.8922	0.6980	0.7833	0.9606	0.9737	0.8616	74.50%
마케팅 채널 효과성	XGB	0.8724	0.6032	0.7132	0.9505	0.9665	0.8212	67.87%



<그림 2> 알고리즘별 지식 기반 변수 영향력 비교 레이더 차트

가장 높은 기여도(Area Ratio=82.35%)를 기록한 피로도 변수군은 구매 여부를 결정짓는 가장 직접적인 근접 결정요인임이 확인되었다. 이는 최근 일정 기간 동안의 접촉 빈도, 누적 노출 강도, 반응 저하 수준과 같은 피로도 관련 지표가 구매 여부를 설명하는 데 있어 가장 직접적인 예측 신호로 작용함을 의미한다. 최적 모델인 RF 는 F1-score 0.8534 를 달성하며 탁월한 탐지력을 보였다. 이는 최근의 노출 빈도와 반응 이력이 고객의 즉각적 구매 의도를 대변하는 강력한 신호이며, 과도한 마케팅으로 인한 반응 임계점을 포착하는 것이 예측 정확도 확보의 선결 조건임을 의미한다.

다음으로 시계열 변수군은 두 번째로 높은 기여도(Area Ratio=76.15%)를 보였으며, XGBoost 모델에서 F1-score 0.7980 의 최적 성능을 기록하였다. 해당 축은 요일, 시간대, 급여 주기, 분기 말과 같은 시간적 맥락 변수를 중심으로 구성되어 있으며, 이는 구매 행동 자체를 직접적으로 유발하기보다는 구매 가능성이 증폭되는 시점을 조절하는 역할을 수행한다. 이는 비교적 안정적인 Precision 과 중간 수준의 Recall 조합을 통해 구매 확률의 순위를 안정화하는 데 기여한다.

세번째로, 구매 주기 변수군(Area Ratio=74.50%)은 RF 모델에서 높은 성능을 보였다. 이 결과는 구매 간격, 누적 구매 이력, 재구매 준비도와 같은 장기적 행동 특성이 고객의 기본적인 구매 성향을 형성하는 데 기여함을 시사한다. 이는 고객의 장기적 소비 습관과 재구매 사이클이 개별 고객의 기저 구매 확률을 형성하는 구조적 요인으로 작용하기 때문에


상대적으로 낮은 Recall 을 보이는 것으로 해석된다. 그림에도 불구하고, 전반적인 예측 안정성과 일관성 측면에서는 중요한 기반 변수로 기능한다.

가장 낮은 면적(Area Ratio=67.87%)을 기록한 채널 변수군은, 전반적인 성능 향상보다는 조건부 필터로서의 성격이 강하다. 최적 모델인 XGBoost 의 결과(Precision 0.8724 vs Recall 0.6032)에서 보듯, 이 변수군은 구매 가능성이 모호한 대상을 배제하고 확실한 성공 패턴과 일치하는 타겟만을 선별함으로써 마케팅 효율성을 최적화하는 미세 조정 역할을 수행한다. 이는 채널 유형이나 메시지 포맷과 같은 요소가 구매 결정에 직접적인 영향을 미치기보다는, 이미 형성된 구매 의사에 대해 설득 강도에 보조적 역할을 수행함을 의미한다. 즉, 채널 효과성 변수는 단독으로 강력한 예측력을 발휘하기보다는, 다른 핵심 변수들과 결합될 때 그 효용이 극대화되는 구조적 특성을 지닌다.

본 실험 결과는 도메인 지식 기반 예측 모델이 단순한 변수의 결합이 아니라, 피로도에 의한 1 차 필터 → 시점에 의한 확률 증폭 → 주기에 의한 기저 보정 → 채널에 의한 효율화라는 단계적 의사결정 프로세스를 반영하고 있음을 실증적으로 규명하였다. 마케팅에서 보통 구매이력이 가장 강력한 영향력으로 알려져 있음에도 불구하고, 본 연구에서는 마케팅 피로도나 시간적 맥락이 더욱 높은 영향력으로 작용했다. 전통적인 마케팅은 누가(Who)에 집중했으나, 현대의 실시간 이커머스 환경에서는 지금의 상태가 더욱 중요한 결정변수임이 밝혀졌다.

4.4.3 모델의 설명력 및 변수 중요도 검증: SHAP 분석

본 연구는 전체 지식 변수를 통합한 최적 모델이 어떠한 변수들의 조합과 상호작용을 통해 고성능을 달성했는지 규명하기 위해, SHAP 기법을 적용하여 사후 해석을 수행하였다. SHAP 은 게임 이론에 기반하여 각 특성이 개별 예측 값에 미치는 한계 기여도(Marginal Contribution)를 산출하는 방법론으로, 변수의 전역적 중요도(Global Importance) 와 영향의 방향성을 동시에 시각화할 수 있다는 장점이 있다. <그림 3>은 테스트 데이터 전체에 대한 SHAP Summary Plot 을 도식화한 것이다. Y 축은 변수 중요도 순(Rank 1~30)으로 정렬되어 있으며, X 축의 SHAP Value 는 해당 변수가 구매 확률에 미치는 영향력을 의미한다. 점의 색상은 변수 값의 크기(Red: High, Blue: Low)를 나타낸다.



Knowledge Category	Positive Contribution	Rank	Negative Contribution	Knowledge Category
마케팅 피로도 패턴	채널별 특정 주제 캠페인 오픈율(30일 내)	1	메시지 수신: 기타	베이스라인
구매 및 재구매 주기 패턴	재구매 준비도	2	총 구매 횟수	베이스라인
마케팅 피로도 패턴	이메일 경과 시간	3	캠페인 채널: 모바일 푸시	베이스라인
베이스라인	채널 메세지 유형: 기타 거래 발송	4	채널 메세지 유형: 전체 유저 발송	베이스라인
마케팅 피로도 패턴	푸시 경과 시간	5	채널 캠페인 유형: 특정 유저 행동 발송	베이스라인
베이스라인	캠페인 채널: 이메일	6	이메일 계정: 지메일	베이스라인
베이스라인	이메일 계정: 기타	7	분기 말 근접도	시계열적 메시지 반응 패턴
베이스라인	채널 캠페인 유형: 기타 거래 발송	8	캠페인 채널: 멀티채널	베이스라인
시계열적 메시지 반응 패턴	선호 시간대 일치도	9	채널 캠페인 유형: 전체 유저 발송	베이스라인
시계열적 메시지 반응 패턴	선호 요일 일치도	10	마지막 클릭 경과 시간(평균)	베이스라인
시계열적 메시지 반응 패턴	급여일 근접도	11	주말 여부	시계열적 메시지 반응 패턴
구매 및 재구매 주기 패턴	마지막 구매 경과일	12	발송 채널: 모바일 푸시	베이스라인
베이스라인	메시지 수신: 스마트폰	13	주제 경과 시간	마케팅 채널 효과성 패턴
베이스라인	메시지 수신: 데스크탑	14	캠페인 주제: 할인 정보	베이스라인
구매 및 재구매 주기 패턴	구매 후 불응기	15	발송 간격 표준편차	마케팅 피로도 패턴
베이스라인	가입 기간(첫 구매 경과)	16	캠페인 지속 시간 (평균)	베이스라인
마케팅 피로도 패턴	유저 클릭율(30일 내)	17	이메일 계정: Mail.ru	베이스라인
베이스라인	캠페인 주제: 기타	18	주제 노출 수(7일)	마케팅 채널 효과성 패턴
마케팅 피로도 패턴	마케팅 피로도	19	채널 메세지 유형: 특정 유저 행동 발송	베이스라인
베이스라인	마지막 오픈 경과 시간(평균)	20	마지막 접속 경과 시간	마케팅 피로도 패턴

<그림 3> 구매 예측 설명을 위한 상위 30 위 변수 중요도 및 영향 방향성 결과

분석 결과, 상위 5 위권 변수는 본 연구가 제안한 “마케팅 피로도 패턴”과 “구매 주기 패턴”이 장악하고 있음이 확인되었다. 이는 구매가 단순한 노출이 아닌, 고객의 능동적 반응과 심리적 상태에 의해 결정됨을 시사한다. 전체 1 위를 차지한 “채널별 특정 주제 캠페인 오픈율(30 일 내)”은 고객이 최근 일정 기간 동안 해당 유형의 메시지에 얼마나 반복적으로 노출되고 반응했는지를 반영하는 지표이다. 해당 변수는 SHAP 값이 양(+)의 방향으로 길게 뻗어 있어, 최근 고객이 특정 주제에 대해 반복적으로 반응(Open)했을 때 구매 확률이 비선형적으로 급증함을 보여준다. 이는 누적된 관심도가 실제 전환의 가장 강력한 선행 지표임을 의미한다. 즉, 최근 반응 이력이 활발한 고객일수록 구매 확률이 비선형적으로 급증함을 보여준다. 또한, 주목할 점은 3 위 “이메일 경과 시간”과 5 위 “푸시 경과 시간”의 패턴이다. 두 변수 모두 빨간색 점(높은 값=오랜 경과 시간)이 우측에, 파란색

점(낮은 값=최근 수신)이 좌측에 분포한다. 이는 메시지를 받은 지 얼마 안 된 시점에서는 구매 확률이 억제되다가, 일정 시간이 경과하여 피로도가 해소될수록 구매 가능성이 높아지는 마케팅 휴식기의 필요성을 정량적으로 입증한다. 그리고 전체 2 위인 구매 및 재구매 주기 패턴의 “재구매 준비도”는 고객 고유의 소비 사이클에 기반한 잠재 욕구를 대변한다. 해당 플롯을 보면, 파란색 점(준비 안 됨)은 0 근처에 머무르나, 빨간색 점(준비됨)은 우측으로 길게 꼬리를 형성한다. 이는 준비도가 낮은 상태에서는 구매 확률에 미치는 영향이 중립적이지만, 임계치를 넘어서는 순간 구매 전환의 강력한 트리거로 작동하는 비선형적 특성을 보여준다.

허나 주목할 점은 고정적 환경 맥락을 의미하는 베이스라인 변수인 다양한 “캠페인 채널, 채널 메시지 유형, 메시지 수신, 이메일 계정” 등이 상위권에 다수 포진해 있다는 사실이다. 그러나 이들은 대부분 이산형 변수로서, 고객이 처한 구조적 환경을 설명한다. 예를 들어, 거래 알림(배송/결제 등)은 고객이 이미 서비스에 깊게 관여하고 있음을 나타내는 대리 지표로 작용하여 구매 확률을 높인다. 즉, 베이스라인 변수가 구매가 일어나기 쉬운 환경을 정의한다면, 도메인 지식 변수는 그 환경 속에서 발생하는 동태적 구매 의도를 포착하여 예측의 정밀도를 완성한다.

또한, 중위권에는 “분기 말 근접도, 선호 시간대 일치도, 급여일 근접도, 주말 여부”와 같은 시계열적 메시지 반응 패턴 변수들이 위치하여, 이미 형성된 구매 의도가 실행으로 옮겨지는 최적의 타이밍을 포착하는 데 기여한다. 한편, 마케팅 채널 효과성 패턴은 상위권 진입이 제한적이었으나, “주제 경과 시간, 주제 노출 수”와 같은 변수들이 하위권에 분포하였으며, 이를 통해 해당 변수가 설득 효율을 보조적으로 제어하는 요인임을 재확인하였다. 이는 앞선 레이더 차트 분석 결과와 일치하는 것으로, 채널 및 콘텐츠 변수가 구매 자체를 결정하기보다는 이미 형성된 구매 의도를 가진 고객에 대한 설득 효율을 보조적으로 제어하는 요인임을 재확인시켜 준다.

따라서, SHAP 분석은 본 연구의 예측 모델이 최근 상호작용과 피로도 관리(1 차 신호)와 기저 구매 성향(2 차 신호)를 기반으로, 고정적 환경(베이스라인)과 시점 맥락(시계열)을 통해 확률을 정교화하는 계층적 의사결정 구조를 학습했음을 의미한다. 이러한 결과는 본 연구에서 제안한 지식 기반 변수 설계가 단순한 특성 나열이 아니라, 실제 구매 의사결정 프레임워크의 타당성을 실증적으로 뒷받침한다.

V. 토의 및 한계

5.1 이론적 기여: 정적 프로파일링에서 동태적 상태 감지로의 전환

본 연구의 가장 큰 이론적 기여는 전통적 고객 관계 관리 이론이 지녔던 “정적 모델링의 한계”라는 이론적 공백을 데이터 중심 AI 방법론을 통해 극복했다는 점이다. 기존의 RFM 모형이나 확률 기반의 고객 생애 가치 문헌들은 주로 장기간 집계된 과거 데이터를 기반으로 고객의 장기적 성향을 프로파일링하는 데 집중해왔다. 이로 인해 다중 접점이 일상화된 현대 디지털 환경에서, 메시지 수신 직후 실시간으로 급변하는 고객의 “동태적 심리 상태”를 예측 모형 내에 내생화하는 데에는 구조적 한계가 존재했다.

또한, 데이터 중심 AI 특성 공학을 적용하여, 추상적인 마케팅 이론을 실시간 추적 가능한 동적 변수로 조작화함으로써 이 공백을 메웠다. 특히 가장 높은 기여도를 보인 “마케팅 피로도 패턴”은 소비자 습관화 이론과 정보 처리 이론을 결합하여 실증한 결과다. 기존 연구들이 피로도를 주로 설문이나 거시적 수준에서 측정했다면, 본 연구는 이를 실시간 로그 기반으로 측정하여 고객의 인지적 자원 한계와 회복 메커니즘이 작동함을 증명하였다. 특히 SHAP 분석에서 확인된 경과 시간과의 양의 상관관계는, 메시지 수신 후 일정 기간의 휴식기가 주어졌을 때 구매 확률이 비선형적으로 반등함을 입증한다. 이는 마케팅을 단순히 더 많이 노출하는 것이 아니라, 고객의 인내심이 회복될 때까지 기다리는 것으로 재정의해야 함을 이론적으로 뒷받침한다. 따라서 본 연구의 마케팅 피로도 패턴은 사실상 상호작용의 양면성을 포괄한다. 고객의 능동적 관심과 수동적 피로 사이의 균형점을 찾는 것이 핵심일 수 있다.

나아가, 두 번째로 높은 기여도를 보인 “시계열적 반응 패턴(시점 역동성)”은 상황 의존적 선호 문헌의 한계를 극복하는 실증적 근거를 제시한다. 소비자의 내재된 구매 욕구는 고정되어 발현되는 것이 아니라, 급여일과 같은 경제적 맥락이나 개인의 활동 리듬(선호 시간대)이라는 특정 외부 트리거와 결합할 때 비로소 행동으로 증폭된다. 본 연구는 이러한

시점 역동성이 단순한 캘린더 효과를 넘어, 구매 의사결정을 촉발하는 핵심 기제로 작동함을 실증적으로 규명함으로써 기존 소비자 행동 이론을 확장하였다.

5.2 방법론적 함의: 정형 데이터에서의 귀납적 편향과 모델 적합성

본 연구의 핵심적인 방법론적 기여는 최근 마케팅 애널리틱스 분야를 주도하고 있는 “순수 데이터 기반 딥러닝 접근”의 한계를 실증적으로 지적하고, 도메인 지식 융합의 우월성을 입증한 데 있다. 기존의 많은 시계열 예측 연구는 원시 로그를 LSTM 이나 Transformer 등에 주입하여 모델 스스로 특징을 추출하게 하는 End-to-End 표현 학습 방식에 의존해 왔다. 그러나 본 연구는 구매 전환율이 0.1% 대에 불과한 극도로 희소한 CRM 데이터 환경에서는, 알고리즘이 노이즈를 학습하여 수렴에 실패할 위험이 있음을 확인하였다.

본 연구는 희소성과 이질성이 높은 CRM 로그 데이터에서 트리 기반 앙상블 모델이 고도화된 딥러닝보다 우수한 성능을 보임을 확인하였다. 이는 L. Grinsztajn et al. (2022)이 주장한 바와 같이, 정형 데이터 특유의 불연속적인 결정 경계를 학습하는 데 있어, 신경망의 매끄러운 함수 근사보다는 트리의 축 정렬 분할 방식이 더 적합한 귀납적 편향을 가지기 때문으로 해석된다. 또한, 도메인 지식 피처가 투입되었을 때 모든 모델의 성능이 수치적으로 향상된 점은, 데이터 중심 AI 관점에서 모델 아키텍처의 고도화보다 데이터 자체의 표현력을 높이는 것이 성능 개선의 한계 효용이 더 큼을 시사한다. 본 연구가 모델 구조의 복잡성보다 데이터의 표현력에 집중한 것이 바로 선행연구에서 제안한 데이터 중심 AI의 실천적 사례로 볼 수 있다. (D. Zha et al. 2025)

5.3 실무적 함의: 효율적 자원 배분을 위한 의사결정 프레임워크

본 연구 결과는 마케터에게 누가(Who)를 넘어 언제(When), 무엇을(What)을 최적화하는 구체적인 가이드라인을 제공한다. 연구에서 확인된 변수 중요도의 위계에 따라 다음과 같은 3 단계 운영 전략을 제안한다. 1 단계는 피로도 기반 필터링으로 피로도 변수를 활용하여 최근 과도한 노출로 반응 임계치가 낮아진 고객을 선제적으로 배제함으로써 이탈을 방지한다. 2 단계는 시점 및 주기 기반 타겟팅으로 시계열 반응 패턴과 재구매 준비도가 높은 고객을 식별하여, 구매 욕구가 최고조에 달한 타이밍에 메시지를 발송한다. 3 단계는

채널 효율화로 채널 효과성 변수를 활용하여, 구매 가능성이 확인된 고객에게 가장 설득력 높은 채널과 콘텐츠를 매칭함으로써 전환 비용을 최소화한다.

추가적으로, 본 연구는 제안된 전략의 효용성을 검증하기 위해 비용 편익 분석 시뮬레이션을 수행하였다. 분석 결과, 최적 모델(XGBoost)을 적용할 경우 베이스라인 대비 동일 예산 하에서 약 1.15 배의 구매 전환 성과(Precision: 0.8401 -> 0.9670)를 창출하며, 동일 목표 달성 기준으로는 불필요한 메시지 발송 비용을 약 13.1% 절감할 수 있는 것으로 추산되었다. 또한, 기존의 무작위 타겟팅(Precision=10%) 방식과 비교할 경우, 약 9.7 배 더 높은 타겟팅 적중률을 보여 마케팅 효율성을 유의미하게 제고할 수 있음을 시사한다. 이는 정밀도의 향상이 마케팅 ROI 의 실질적 개선으로 직결됨을 시사하며, 제안된 프레임워크가 단순한 예측을 넘어 비용 효율적인 의사결정 도구로 기능함을 입증한다.

5.4 한계점

본 연구는 마케팅 도메인 지식을 체계적으로 구조화하여 예측 성능과 설명 가능성을 동시에 제고할 수 있음을 실증하였다. 이는 복잡한 딥러닝 도입에 앞서 도메인 지식의 동태적 조작화가 실무적 대안이 될 수 있음을 시사한다. 그럼에도 불구하고 본 연구는 다음과 같은 한계점을 지니며, 이는 향후 연구의 과제로 남는다.

첫째, 분석 대상의 국한성이다. 본 연구는 특정 이커머스 플랫폼의 로그 데이터에 기반하고 있어, 상품 카테고리나 비즈니스 모델(예: 정기 구독 vs 단건 구매)에 따른 변수 중요도의 차이를 포괄적으로 검증하지 못했다. 향후 연구에서는 다양한 도메인의 데이터셋을 활용한 교차 검증과 실제 캠페인에 모델을 적용하여 ROI 변화를 직접 측정하는 현장 실험이 요구된다.

둘째, 방법론적 엄밀성과 인과관계 해석의 문제이다. 본 연구는 SHAP 분석을 통해 마케팅 피로도나 시점 역동성의 상대적 기여도를 확인하였으나, 이는 예측 모델의 출력값에 대한 한계 기여도일 뿐 변수와 구매 간의 엄밀한 인과관계를 의미하지는 않는다. 특히 피로도 요인이 구매 전환 예측에 강력하게 기여한다는 본 연구의 결과는 단기적 예측 맥락에서의 발견이며, 이를 기존 마케팅 문헌의 일반적 견해인 장기적 구매 이력의 영향력을 상쇄하는 인과적 결론으로 확대 해석하는 데에는 주의가 필요하다.

셋째, 이론적 파라미터 설정의 가설적 성격이다. 마케팅 피로도 모델에 적용된 채널별 반감기는 실무적 가이드라인에 기반한 탐색적 설정치이다. SMS 와 같이 침해성이 높은 매체는 소비자에게 강한 심리적 반발을 유발하여 오히려 인지적 회피가 빠르게 일어나 반감기가 짧게 나타날 가능성도 존재한다. 따라서 향후 연구에서는 고정된 파라미터 대신, 실제 고객 반응 데이터를 통해 채널 및 개인별 최적 반감기를 동적으로 추정하는 알고리즘 고도화가 필요하다.

마지막으로, 모델 효율성의 정량적 측정 문제이다. 본 연구는 딥러닝 대비 트리 기반 경량 모델이 연산 리소스 측면에서 효율적임을 논하였으나, 실제 CPU 와 GPU 간의 구체적인 연산 시간 비교나 에너지 소비량 및 탄소 배출량에 대한 정량적 측정치는 제시하지 못했다. 경량화 알고리즘의 실무적 효율성을 명확히 하기 위해서는 실제 운영 환경에서의 하드웨어 자원 점유율에 대한 정량적 비교 분석이 수반되어야 할 것이다.

VI. 결론

본 연구는 “데이터의 표현력이 모델의 구조적 복잡성을 능가할 수 있는가?”라는 근본적 질문에서 출발하여, 이커머스 고객 행동 예측을 위한 도메인 지식 기반의 프레임워크를 제안하고 실증하였다. 대규모 로그 데이터를 활용한 실험 결과, 도메인 이론(피로도, 시점 역동성 등)을 반영한 특성 공학은 예측 정확도를 유의미하게 제고하였으며, 특히 경량화된 기계학습 알고리즘이 고도화된 시계열 딥러닝 모델을 상회하는 성능을 입증하였다. 이는 희소성과 이질성이 높은 CRM 데이터 환경에서는 맹목적인 모델 깊이의 추구보다 데이터의 질적 맥락을 보강하는 것이 성공의 핵심 요인임을 시사한다.

첫째, 데이터 중심 AI 의 유효성을 입증하였다. 수억 건의 데이터라도 정보 밀도가 낮다면 딥러닝 모델은 과적합되거나 수렴에 실패할 수 있음을 확인하였다. 반면, 마케팅 도메인 지식을 통해 데이터에 귀납적 편향을 주입했을 때 성능이 유의미하게 개선됨을 실증함으로써, 빅데이터 시대에도 여전히 데이터 과학자의 도메인 이해도가 모델 성능의 상한선을 결정하는 변수임을 확인하였다. 둘째, 동태적 마케팅 제어 변수의 발견이다. 구매 예측의 결정적 변수는 정적인 인구통계학적 속성이 아니라, 동적인 피로도와 시점 역동성임이 밝혀졌다. 이는 마케팅이 고정된 타겟팅에서 벗어나, 고객의 실시간 상태에 따라

메시지 발송 빈도와 타이밍을 조절하는 동적 제어 시스템으로 진화해야 함을 의미한다. 셋째, 지속 가능한 고효율 모델링의 실현이다. 고가의 GPU 인프라를 요구하는 딥러닝 대비, 본 연구의 방법론은 CPU 환경에서도 더 높은 성능과 빠른 추론 속도를 달성했다. 이는 GPU 등 고비용 인프라가 필수적인 딥러닝 모델 대비 CPU 환경에서도 효율적인 학습과 추론이 가능하다는 점에서, 실무적 운영 리소스를 절감할 수 있는 현실적인 대안을 제시한다.

나아가, 본 연구가 제시한 데이터 중심 AI 접근은 기업의 마케팅 전략, CRM 조직, 그리고 디지털 전환(DX) 전략에 근본적인 구조적 변화를 요구한다. 첫째, 마케팅 전략 수립에 있어 기업은 과거의 인구통계학적 세분화나 사전 기획된 정적 캠페인 운영에서 벗어나야 한다. 대신, 고객의 실시간 피로도와 시간적 맥락을 모니터링하여 최적의 개입 시점을 결정하는 “동적 오케스트레이션(Orchestration)” 체계로 마케팅 프로세스를 재설계해야 한다. 둘째, 고객 관계 관리 조직은 알고리즘을 개발하는 데이터 사이언티스트와 캠페인을 실행하는 마케터가 분리된 기존의 사일로 구조를 타파해야 한다. 데이터 중심 AI가 성공하기 위해서는 마케팅 지식을 기계학습 모델이 이해할 수 있는 변수로 번역하고 연결하는 “애널리틱스 트랜슬레이터(Translator)” 중심의 융합형 조직 구축이 필수적이다. 셋째, 디지털 전환 전략 측면에서, 기업은 무조건적인 고비용 딥러닝 인프라(GPU 등)의 무비판적인 도입을 경계해야 한다. 대신 자사 데이터의 희소성과 특성을 명확히 파악하고, 도메인 지식과 설명 가능성(XAI)이 결합된 적정 기술을 도입함으로써 비용 효율적이고 지속 가능한 AI 경영 체계를 구축해야 한다.

특히 시뮬레이션을 통해 입증된 13.1%의 비용 절감과 1.15 배의 성과 향상은 본 연구가 단순한 학술적 탐구를 넘어 기업의 이익을 극대화하는 실질적인 적정 기술로 기능할 수 있음을 강력히 뒷받침한다. 향후 본 연구가 인과 추론과 결합하여 마케팅의 진정한 증분 효과를 측정하는 연구로 확장되기를 기대한다.

Appendix

<부록 1> 도메인 지식 기반 파생변수 산출 상세 수식

1. 재구매 준비도($h_{(t)}$): 고객별 구매 주기의 정규분포 근사 및 확률 밀도 유사도 산출식

$$h_{(t)} = \exp\left(-\frac{1}{2}\left(\frac{\text{마지막 구매 경과일} - \mu}{\sigma}\right)^2\right)$$

2. 구매 후 불응기($r_{(t)}$): 소비 직후 냉각기 반응을 위한 역지수 감쇠 함수

$$r_{(t)} = 1 - \exp\left(-\frac{t}{\tau}\right)$$

3. 선호 시간대 일치도(d_{norm}): 원형 좌표계 매핑 및 코사인 거리 산출식

$$d_{norm} = \frac{(1 - \cos(\theta_{curr} - \bar{\theta}))}{2}$$

4. 경제적 캘린더 효과($bump(t)$): 급여일 등 특정 시점 근접도 산출을 위한 가우시안 범프 함수

$$bump(t) = \exp\left(-\frac{(t - t_p)^2}{\sigma^2}\right)$$

5. 누적 마케팅 피로도($F(t)$): 채널별 반감기를 고려한 누적 지수 감쇠 함수

$$F(t) = \sum_{c \in C} \exp\left(-\frac{\Delta t_c(t)}{\tau_c}\right)$$

6. 콘텐츠 주제 신선도($N_{topic(t)}$): 주제 노출 빈도와 경과 시간을 결합한 복합 감쇠 함수

$$N_{topic(t)} = \exp\left(-\frac{N_{7d}}{\kappa}\right) \cdot \left(1 - \exp\left(-\frac{\Delta t}{\tau}\right)\right)$$

<부록 2> 모델링의 하이퍼파라미터 탐색범위 및 최적값 요약

알고리즘	파라미터	탐색범위	최적값
Random Forest	n_estimators	100 ~ 800 (step=50)	700
	max_depth	10 ~ 30 (step=5)	30
	min_samples_split	2 ~ 10	2

	min samples leaf	1 ~ 5	8
XGBoost	n estimators	100 ~ 1,000	450
	learning rate	0.001 ~ 0.3 (log)	0.0608
	max depth	3 ~ 10	3
	min child weight	1 ~ 10	4
	subsample	0.5 ~ 1.0	0.5733
	colsample bytree	0.5 ~ 1.0	0.5461
	gamma	0 ~ 5	0.9313
	reg_alpha	1e-5 ~ 10 (log)	0.0011
	reg_lambda	1e-5 ~ 10 (log)	0.0002
MLP	n layers	1 ~ 3	2
	activation	relu/gelu/selu	gelu
	units l0	32 ~ 512	128
	dropout l0	0.0 ~ 0.5	0.2080
	l2	1e-6 ~ 1e-2	4.87E-03
	optimizer	adam/rmsprop/sgd	rmsprop
	learning rate	1e-4 ~ 1e-2	2.83E-04
	batch size	16/32/64/128	32
CNN	conv_filters	32 ~ 256	224
	kernel_size	2 ~ 5	2
	pool_size	2 ~ 3	3
	num_conv_layers	1 ~ 2	2
	dense_units	32 ~ 256	192
	dropout_rate	0.1 ~ 0.6	0.2400
	l2	1e-6 ~ 1e-2	1.44E-04
	learning_rate	1e-5 ~ 1e-3	1.17E-04
RNN	batch_size	32/64/128	32
	num_layers	1 ~ 2	2
	rnn_units1	32 ~ 256	224
	rnn_units2	16 ~ 128	128
	dense_units	16 ~ 256	96
	dropout_rate	0.0 ~ 0.5	0.3461
	l2	1e-6 ~ 1e-2	3.20E-03
	activation	tanh/relu/sigmoid	tanh
LSTM	learning_rate	1e-5 ~ 1e-2	1.21E-05
	batch_size	32/64/128	32
	num_lstm_layers	1 ~ 2	2
	lstm_units_1	32 ~ 256	96
	lstm_units_2	32 ~ 256	112
	dense_units	16 ~ 64	48
	dropout_rate	0.1 ~ 0.5	0.4530
	l2	1e-5 ~ 1e-2	7.43E-04
CNN-LSTM	learning_rate	1e-5 ~ 1e-3	3.18E-04
	batch_size	32/64/128	128
	conv_filters	16 ~ 128	48
	kernel_size	2 ~ 5	4
	pool_size	2 ~ 4	4
	lstm_units	32 ~ 256	256
	dense_units	16 ~ 64	16
	dropout_rate	0.1 ~ 0.5	0.1156
RNN-LSTM	l2	1e-5 ~ 1e-2	3.23E-05
	learning_rate	1e-5 ~ 1e-3	5.71E-04
	batch_size	32/64/128	128
	lstm_units1	32 ~ 256	256
	lstm_units2	16 ~ 128	64
	dense_units	16 ~ 64	64
	dropout_rate	0.1 ~ 0.5	0.4873
	l2	1e-5 ~ 1e-2	7.33E-04
	learning_rate	1e-5 ~ 1e-3	1.77E-04
	batch_size	32/64/128	32


<부록 3> 도메인 지식 기반 파생변수의 기초 통계량 요약

그룹(Group)	변수명(Variable)	Mean	Std	Min	Median	Max	Skewness
종속변수	구매 여부(Target)	0.1000	0.3000	0.0000	0.0000	1.0000	2.6667
베이스라인	채널별 특정 주제 캠페인 오픈율(30 일 내)	0.2429	0.2034	0.0000	0.1899	0.9999	3.0450

	캠페인 지속 시간(평균)	0.0791	0.6584	0.0014	0.0214	41.5650	27.8123
	불만 접수 경과 시간(평균)	0.2624	48.7905	0.0000	0.0000	15285.7822	235.0926
	가입 기간(첫 구매 경과)	60.7500	584.7629	0.0000	0.0000	11803.0029	12.1177
	마지막 클릭 경과 시간(평균)	87.1980	745.2856	0.0000	0.0000	17154.8535	11.9734
	마지막 오픈 경과 시간(평균)	151.5883	987.9755	0.0000	0.0000	17235.3750	9.6985
	구독 취소 경과 시간(평균)	9.0440	212.1757	0.0000	0.0000	17109.6523	50.5934
	공휴일 여부	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
	총 캠페인 수	0.2395	0.7184	0.0000	0.0000	14.0000	4.9444
	총 메시지 수신 수	0.2939	1.1131	0.0000	0.0000	48.0000	12.1055
	총 구매 횟수	0.1786	0.8070	0.0000	0.0000	48.0000	17.1999
	메시지 수신: 기타	0.8663	0.3403	0.0000	1.0000	1.0000	-2.1524
	메시지 수신: 데스크탑	0.0844	0.2780	0.0000	0.0000	1.0000	2.9906
	메시지 수신: 패블릿	0.0039	0.0625	0.0000	0.0000	1.0000	15.8656
	메시지 수신: 스마트폰	0.0436	0.2041	0.0000	0.0000	1.0000	4.4720
	메시지 수신: 태블릿	0.0018	0.0429	0.0000	0.0000	1.0000	23.1998
	발송 채널: 이메일	0.6128	0.4871	0.0000	1.0000	1.0000	-0.4631
	발송 채널: 모바일 푸시	0.3871	0.4871	0.0000	0.0000	1.0000	0.4636
	발송 채널: 웹 푸시	0.0001	0.0104	0.0000	0.0000	1.0000	96.0255
	이메일 계정: 지메일	0.0998	0.2997	0.0000	0.0000	1.0000	2.6712
	이메일 계정: Mail.ru	0.3346	0.4718	0.0000	0.0000	1.0000	0.7011
	이메일 계정: 기타	0.5657	0.4957	0.0000	1.0000	1.0000	-0.2649
	채널 캠페인 유형: 전체 유저 발송	0.6701	0.4702	0.0000	1.0000	1.0000	-0.7235
	채널 캠페인 유형: 기타 거래 발송	0.1053	0.3069	0.0000	0.0000	1.0000	2.5717
	채널 캠페인 유형: 특정 유저행동 발송	0.2246	0.4173	0.0000	0.0000	1.0000	1.3198
	캠페인 채널: 이메일	0.3889	0.4875	0.0000	0.0000	1.0000	0.4557
	캠페인 채널: 모바일 푸시	0.3865	0.4869	0.0000	0.0000	1.0000	0.4663
	캠페인 채널: 멀티채널	0.2246	0.4173	0.0000	0.0000	1.0000	1.3198
	캠페인 채널: SMS	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
	캠페인 주제: 이벤트	0.0014	0.0379	0.0000	0.0000	1.0000	26.3436
	캠페인 주제: 생일 축하	0.0001	0.0091	0.0000	0.0000	1.0000	109.7238
	캠페인 주제: 리뷰 요청	0.0000	0.0050	0.0000	0.0000	1.0000	198.5149
	캠페인 주제: 연관 상품 추천	0.0001	0.0111	0.0000	0.0000	1.0000	90.4250
	캠페인 주제: 기타	0.3299	0.4702	0.0000	0.0000	1.0000	0.7235
	캠페인 주제: 할인 정보	0.6617	0.4731	0.0000	1.0000	1.0000	-0.6835
	채널 메시지 유형: 전체 유저 발송	0.6699	0.4703	0.0000	1.0000	1.0000	-0.7224
	채널 메시지 유형: 기타 거래 발송	0.1055	0.3072	0.0000	0.0000	1.0000	2.5679
	채널 메시지 유형: 특정 유저행동 발송	0.2246	0.4173	0.0000	0.0000	1.0000	1.3198
	메시지 클릭 여부	0.0328	0.1780	0.0000	0.0000	1.0000	5.2495
	메시지 불만 접수 여부	0.0001	0.0089	0.0000	0.0000	1.0000	112.9056
	메시지 오픈 여부	0.0543	0.2267	0.0000	0.0000	1.0000	3.9317
	메시지 구독 취소 여부	0.0006	0.0241	0.0000	0.0000	1.0000	41.4407
구매 및 재구매	마지막 구매 경과일	3.1000	28.5713	0.0000	0.0000	715.0884	12.8470
	재구매 준비도	0.9526	0.1713	0.0000	0.9933	1.0000	-4.4794
	구매 후 불응기	0.9645	0.1768	0.0000	1.0000	1.0000	-4.9744
시계열적 메시지	선호 시간대 일치도	0.5673	0.5244	0.0000	0.3831	2.0000	1.2387
	선호 요일 일치도	0.8740	0.6482	0.0000	0.8996	2.0000	0.2242
	주말 여부	0.1150	0.3190	0.0000	0.0000	1.0000	2.4141
	주차 정보	2.7642	1.3802	0.0000	3.0000	5.0000	0.1868
	급여일 근접도	0.1412	0.2564	0.0000	0.0022	1.0000	1.8939
마케팅 피로도	분기 말 근접도	0.1575	0.3411	0.0000	0.0000	1.0000	1.9582
	마케팅 피로도	0.0807	0.2567	0.0000	0.0000	1.8809	3.1047
	이메일 경과 시간	479.7941	1487.1741	0.0000	336.3022	17232.4902	6.5181

마케팅 채널 효과성	푸시 경과 시간	368.8277	909.9960	0.0000	368.8547	17354.7129	11.1822
	마지막 접촉 경과 시간	415.3945	814.1870	0.0000	368.8547	17354.7129	11.3288
	발송 간격 표준편차	2.7441	55.9622	0.0000	0.0000	11154.6445	84.2715
	유저 오픈율(30 일 내)	0.0426	0.1941	0.0000	0.0000	1.0000	4.5129
	유저 클릭율(30 일 내)	0.0236	0.1430	0.0000	0.0000	1.0000	6.2345
	유저 오픈 횟수(30 일 내)	0.0883	0.5700	0.0000	0.0000	29.0000	16.0412
	채널별 특정 주제 캠페인 오픈율(30 일 내)	0.2429	0.2034	0.0000	0.1899	0.9999	3.0450
	주제 신선도	0.4192	0.0595	0.0000	0.4192	0.7553	-1.3031
	주제 노출 수(7 일)	0.0777	0.3728	0.0000	0.0000	11.0000	7.7448
	주제 경과 시간	89.0337	720.1280	0.0000	0.0000	17354.7129	13.2766
	성공 경로 일치도	0.0051	0.0706	0.0000	0.0000	1.0000	13.8587
	성공 캠페인 유사도	0.0193	0.1290	0.0000	0.0000	1.0000	7.2235

<부록 4> 주요 파생변수 간 피어슨 상관관계 히트맵



참고문헌

Akter, J., A. Roy, S. Rahman, S. Mohona, and J. Ara (2025), "Artificial intelligence-driven customer lifetime value (CLV) forecasting: Integrating RFM analysis with machine learning for strategic customer retention," *Journal of Computer Science and Technology Studies*, 7 (1), 249-57.

Althoff, T., E. Horvitz, R. W. White, and J. Zeitzer (2017), "Harnessing the web for population-scale physiological sensing: A case study of sleep and performance," in Proceedings of the 26th international conference on World Wide Web, Perth, Australia: IW3C2, 113-22.

Alvarez-Melis, D. and T. S. Jaakkola (2018), "On the robustness of interpretability methods," *arXiv preprint arXiv:1806.08049*.

Anderl, E., I. Becker, F. Von Wangenheim, and J. H. Schumann (2016), "Mapping the customer journey: Lessons learned from graph-based online attribution modeling," *International journal of research in marketing*, 33 (3), 457-74.

Arik, S. Ö. and T. Pfister (2021), "Tabnet: Attentive interpretable tabular learning," in Proceedings of the AAAI conference on artificial intelligence: AAAI Press, 6679-87.

Attari, V. and R. Arroyave (2025), "Decoding non-linearity and complexity: Deep tabular learning approaches for materials science," *Digital Discovery*, 4 (10), 2765-80.

Beyazit, E., J. Kozaczuk, B. Li, V. Wallace, and B. Fadlallah (2023), "An inductive bias for tabular deep learning," *Advances in Neural Information Processing Systems*, 36, 43108-35.

Chae, I., H. A. Bruno, and F. M. Feinberg (2019), "Wearout or weariness? Measuring potential negative consequences of online ad volume and placement on website visits," *Journal of Marketing Research*, 56 (1), 57-75.

Chamberlain, B. P., A. Cardoso, C. B. Liu, R. Pagliari, and M. P. Deisenroth (2017), "Customer lifetime value prediction using embeddings," in Proceedings of the 23rd ACM SIGKDD international conference on knowledge discovery and data mining, Halifax, NS, Canada: ACM 1753-62.

Chen, K.-Y., P.-H. Chiang, H.-R. Chou, T.-W. Chen, and T.-H. Chang (2023), "Trompt: Towards a better deep neural network for tabular data," *arXiv preprint arXiv:2305.18446*.

Chen, Q., H. Zhao, W. Li, P. Huang, and W. Ou (2019), "Behavior sequence transformer for e-commerce recommendation in alibaba," in Proceedings of the 1st international workshop on deep learning practice for high-dimensional sparse data, 1-4.

Du, M., C. A. Hammerschmidt, G. Varisteas, R. State, M. Brorsson, and Z. Zhang (2019), "time series modelling of market price in real-time bidding," in ESANN.

EU (2024), "Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence," *Official Journal of the European Union*, 2024/1689.

Fader, P. S., B. G. Hardie, and K. L. Lee (2005), "RFM and CLV: Using iso-value curves for customer base analysis," *Journal of marketing research*, 42 (4), 415-30.

Fader, P. S., Hardie, Bruce G. S., Lee, Ka Lok (2005), "'Counting Your Customers" the Easy Way: An Alternative to the Pareto/NBD Model," *Marketing Science*, 24 (2), 275-84.

Farjon, G. and A. Bar-Hillel (2022), "Sparse Hierarchical Table Ensemble—A Deep Learning Alternative for Tabular Data," *IEEE Access*, 10, 75376-84.

Gorishniy, Y., A. Kotelnikov, and A. Babenko (2024), "Tabm: Advancing tabular deep learning with parameter-efficient ensembling," *arXiv preprint arXiv:2410.24210*.

Grinsztajn, L., E. Oyallon, and G. Varoquaux (2022), "Why do tree-based models still outperform deep learning on typical tabular data?," *Advances in neural information processing systems*, 35, 507-20.

Hacker, P. (2024), "Sustainable AI regulation," *Common Market Law Review*, 61 (2).

Harris, P., H. Pol, and G. Van Der Veen (2020), "Customer journey: From practice to theory," in *The Routledge companion to strategic marketing*. Routledge.

Huang, X., A. Khetan, M. Cvitkovic, and Z. Karnin (2020), "Tabtransformer: Tabular data modeling using contextual embeddings," *arXiv preprint arXiv:2012.06678*.

Jia, R., R. Li, M. Yu, and S. Wang (2017), "E-commerce purchase prediction approach by user behavior data," in 2017 international conference on computer, information and telecommunication systems (CITS), Dalian, Liaoning, China: IEEE, 1-5.

Koren, Y. (2009), "Collaborative filtering with temporal dynamics," in Proceedings of the 15th ACM SIGKDD international conference on Knowledge discovery and data mining, Paris, France: ACM, 447-56.

Kumar, V., B. Rajan, R. Venkatesan, and J. Lecinski (2019), "Understanding the role of artificial intelligence in personalized engagement marketing," *California management review*, 61 (4), 135-55.

Lambrecht, A. and C. Tucker (2013), "When does retargeting work? Information specificity in online advertising," *Journal of Marketing research*, 50 (5), 561-76.

Lemon, K. N. and P. C. Verhoef (2016), "Understanding customer experience throughout the customer journey," *Journal of marketing*, 80 (6), 69-96.

Lindskog, W. and C. Prehofer (2023), "A federated learning benchmark on tabular data: Comparing tree-based models and neural networks," in 2023 Eighth International Conference on Fog and Mobile Edge Computing (FMEC), Tartu, Estonia: IEEE, 239-46.

Lundberg, S. M., G. Erion, H. Chen, A. DeGrave, J. M. Prutkin, B. Nair, R. Katz, J. Himmelfarb, N. Bansal, and S.-I. Lee (2020), "From local explanations to global understanding with explainable AI for trees," *Nature machine intelligence*, 2 (1), 56-67.

Lundberg, S. M. and S.-I. Lee (2017), "A unified approach to interpreting model predictions," *Advances in neural information processing systems*, 30.

Olafsson, A. and M. Pagel (2018), "The liquid hand-to-mouth: Evidence from personal finance management software," *The Review of Financial Studies*, 31 (11), 4398-446.

Ribeiro, M. T., S. Singh, and C. Guestrin (2016), "" Why should i trust you?" Explaining the predictions of any classifier," in Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining, San Francisco, CA: ACM, 1135-44.

Schmittlein, D. C., D. G. Morrison, and R. Colombo (1987), "Counting your customers: Who-are they and what will they do next?," *Management science*, 33 (1), 1-24.

Shannon, C. E. (1948), "A mathematical theory of communication," *The Bell system technical journal*, 27 (3), 379-423.

Shin, J., W. Kim, J. Lee, J. Park, and C. Y. Ock (2022), "Controlling Weight Update Probability of Sparse Features in Machine Learning," in 2022 14th International Conference on Knowledge and Systems Engineering (KSE), Nha Trang, Vietnam: IEEE, 1-6.

Sun, C., A. Shrivastava, S. Singh, and A. Gupta (2017), "Revisiting unreasonable effectiveness of data in deep learning era," in Proceedings of the IEEE international conference on computer vision, Venice, Italy: IEEE, 843-52.

Thabtah, F., S. Hammoud, F. Kamalov, and A. Gonsalves (2020), "Data imbalance in classification: Experimental evaluation," *Information Sciences*, 513, 429-41.

Vasileva, S. (2024), "Cutting through the noise: understanding the usage of the customer journey mapping," in Competitivitatea și inovarea în economia cunoașterii, 42-50.

Vaswani, A., N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin (2017), "Attention is all you need," *Advances in neural information processing systems*, 30.

Verbeke, W., K. Dejaeger, D. Martens, J. Hur, and B. Baesens (2012), "New insights into churn prediction in the telecommunication sector: A profit driven data mining approach," *European journal of operational research*, 218 (1), 211-29.

Wang, X., X. He, Y. Cao, M. Liu, and T.-S. Chua (2019), "Kgat: Knowledge graph attention network for recommendation," in Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining, Anchorage, AK, USA: ACM, 950-58.

Wathieu, L. (2004), "Consumer habituation," *Management Science*, 50 (5), 587-96.

Zha, D., Z. P. Bhat, K.-H. Lai, F. Yang, Z. Jiang, S. Zhong, and X. Hu (2025), "Data-centric artificial intelligence: A survey," *ACM Computing Surveys*, 57 (5), 1-42.

Zhang, H., C. Arvin, D. Efimov, M. W. Mahoney, D. Perrault-Joncas, S. Ramasubramanian, A. G. Wilson, and M. Wolff (2024), "Llmforecaster: Improving seasonal event forecasts with unstructured textual data," *arXiv preprint arXiv:2412.02525*.

Ziegler, C.-N., S. M. McNee, J. A. Konstan, and G. Lausen (2005), "Improving recommendation lists through topic diversification," in Proceedings of the 14th international conference on World Wide Web, Chiba, Japan: ACM, 22-32.