

<마케팅연구 편집위원회 귀중>

1. 논문제목 (영문제목 포함)

(국문) 동태적 마케팅 지식 통합을 통한 이커머스 구매 전환 예측 프레임워크:

데이터 중심 AI 접근법

(영문) A Data-Centric AI Framework for E-Commerce Purchase Conversion Prediction

via Dynamic Marketing Knowledge Integration

2. 원고매수 : 총 30 매 (부록 및 참고문헌 제외, 본문 쪽번호 기준)

3. 투고일자 : 2026.08.19

동태적 마케팅 지식 주입을 통한 이커머스 구매 전환 예측 및 의사결정 메커니즘 분석: 데이터 중심 AI 접근법

본 연구는 극단적인 클래스 불균형(전환율 0.1234%)을 지닌 전자상거래 고객관계관리(CRM) 환경에서, 모형의 구조적 복잡성보다 데이터 표현력의 질적 보강을 우선시하는 데이터 중심 인공지능(Data-Centric AI) 기반의 도메인 지식 특성 공학 프레임워크를 제안하고 실증하였다. 전통적 고객 분석의 정적 모델링 한계를 보완하기 위해, 소비자 습관화, 상황 의존적 선호, 고객 생애 가치, 정보 엔트로피 이론에 기반한 4 대 동태적 상태 변수군(구매 및 재구매 주기, 시계열적 반응, 마케팅 피로도, 마케팅 채널 효과성)을 구축하고 이를 모형에 귀납적 편향으로 통합 주입하였다. 2 개년에 걸친 1 억 7,200 만 건의 다채널 메시징 로그와 원분포 홀드아웃 테스트 세트를 바탕으로 총 9 종의 머신러닝, 심층 신경망, 정형 딥러닝 알고리즘을 비교 검증하였다. 실증 분석 결과, 도메인 지식이 통합된 트리 기반 앙상블 모형인 XGBoost 가 정형 및 시계열 특화 딥러닝(TabNet, LSTM 등)을 제치고 가장 우수한 분류 성능(F1-score 0.3806, PR-AUC 0.3620)을 기록하였으며, 베이스라인 대비 재현율(Recall)을 30.74%에서 52.30%로 70.1% 대폭 향상시켰다. 변수 절삭 및 SHAP 기반 설명 가능성 분석에서는 마케팅 피로도 측이 비반응 고객을 사전에 배제하고, 시계열적 반응 측이 수신 적기를 보정하며, 주기 및 고관여 상호작용 최근성이 전환 예측을 미세 조정하는 계층적 예측 신호 가중치 패턴(Hierarchical Predictive Pattern)이 형성됨을 확인하였다. 아울러 상위 타겟팅 규모 분석 결과, 상위 0.78% 선별만으로 전체 구매 전환의 95.83%를 포착하고 발송 물량을 99.22% 절감하는 실무적 비용 효율성을 입증하였다. 본 연구는 희소 CRM 정형 데이터 환경에서 맹목적인 심층 아키텍처 확장보다 도메인 지식을 반영한 경량화 모형이 예측 성능, 설명력, 운영 경제성 측면에서 실무적으로 우수한 대안이 됨을 입증하고, 동태적 마케팅 오케스트레이션을 위한 정량적 의사결정 기준을 제공한다는 점에서 학술적 및 실무적 의의를 지닌다.

주제어: 데이터 중심 AI, 구매 전환 예측, 도메인 지식 특성 공학, 귀납적 편향, 트리 기반 앙상블, 설명가능한 인공지능, 고객관계관리

Predicting Purchase Conversion and Decision-Making Mechanisms in E-Commerce via Dynamic Marketing Knowledge Injection: A Data-Centric AI Approach

This study proposes and empirically validates a Data-Centric AI framework driven by domain-knowledge feature engineering for e-commerce Customer Relationship Management (CRM) under extreme class imbalance (a conversion rate of 0.1234%). To overcome the limitations of static customer profiling, we operationalized classical marketing theories including consumer habituation, context-dependent preferences, customer lifetime value, and information entropy into four dynamic state feature groups: repurchase cycle patterns, temporal response patterns, marketing fatigue patterns, and channel effectiveness patterns. These features were injected as an inductive bias into nine diverse predictive algorithms, spanning traditional machine learning, deep neural networks, and specialized tabular deep learning. Using a large-scale real-world dataset comprising 172 million multichannel messaging logs over two years and a holdout test, empirical results demonstrated that a domain-enhanced lightweight tree ensemble (XGBoost) consistently outperformed deep learning architectures (such as TabNet and LSTM) in tabular data modeling. Specifically, XGBoost achieved the highest overall classification performance (F1-score: 0.3806, PR-AUC: 0.3620), increasing the recall from 30.74% to 52.30% (+70.1%) compared to the baseline. Feature ablation and SHAP analyses revealed a hierarchical three-step decision mechanism: marketing fatigue and temporal dynamics act as primary filters for negative screening and timing moderation, whereas the repurchase cycle and high-engagement click recency finalize conversion decisions. Furthermore, targeting sensitivity analysis demonstrated practical cost-efficiency; targeting only the top 0.78% of users captured 95.83% of total conversions while reducing blast message volume by 99.22%. This study underscores that in sparse tabular CRM environments, incorporating structured domain knowledge into lightweight tree ensembles provides superior predictive accuracy, explainability, and operational efficiency over blind model scaling, offering quantitative guidelines for dynamic marketing orchestration.

Keywords: Data-Centric AI, Purchase Conversion Prediction, Domain-Knowledge Feature Engineering, Inductive Bias, Tree-based Ensemble, Explainable AI, Customer Relationship Management

1. 서론

오늘날의 고객은 이메일을 열어보고, 며칠 뒤 모바일 푸시 알림을 확인하며, SMS 를 수신한 뒤에 비로소 결제 버튼을 누른다. 이처럼 산발적으로 흩어진 접점이 누적되어 하나의 복잡한 고객 여정(Customer Journey)이 완성된다(Harris et al. 2020). 기업 입장에서 이 파편화된 기록을 연결하여 누가 구매할지 예측하고, 한정된 마케팅 예산을 어디에 투입할지 결정하는 것은 수익성과 직결되는 지속 가능성을 위한 핵심 과제다. 최근 실무 현장에서는 고객의 실시간 반응 로그를 타겟팅에 부분적으로 도입하고 있으나, 이질적인 다채널 상호작용 신호를 기계학습 모형의 입력 변수로 체계적이고 동태적으로 결합하는 표준화된 프레임워크가 여전히 미흡한 실정이다.

기업들은 대규모의 로그 데이터가 고객 행동을 완벽하게 설명해 줄 것이라는 기대감을 갖지만, 실제 분석 환경에서는 심각한 정보의 희소성 문제에 직면한다(Jia et al. 2017). 일반적인 이커머스 환경에서 구매 전환율은 2~3% 수준에 불과하며, 이는 축적된 로그의 대다수가 즉각적인 구매로 전환되지 않는 고객 여정상의 비전환 탐색 행동으로 구성되어 있음을 의미한다. 이러한 극단적인 클래스 불균형과 희소성은 기계학습 모형(Shin et al.

2022), 특히 데이터의 밀도에 민감한 딥러닝(Deep Learning) 모형의 학습 효율성을 저해하는 주요 요인으로 작용한다.

자연어 처리(NLP)나 컴퓨터 비전 분야에서 트랜스포머(Transformer) 계열 딥러닝 아키텍처가 거둔 우수한 성과를 바탕으로(Vaswani et al. 2017), 시계열 마케팅 데이터에도 Long Short-Term Memory(LSTM)이나 Recurrent Neural Network(RNN)을 적용하려는 시도가 이어져 왔다(Du et al. 2019). 하지만 딥러닝의 높은 성능은 대개 데이터 밀도가 보장된 정제된 환경에서 도출된 결과다(Sun et al. 2017). 반면 실제 기업의 고객 관계 관리(CRM) 정형 로그는 이벤트 간격이 극히 불규칙하고 희소성이 높아, 방대한 파라미터를 지닌 딥러닝 구조가 이론적인 성능 우위를 발휘하지 못하거나 불필요한 연산 자원을 낭비할 위험이 크다(Grinsztajn et al. 2022; LindskogPrehofer 2023). (FarjonBar-Hillel 2022).

나아가 최근의 벤치마크 연구들은 불연속적 속성과 비선형적 경계가 지배적인 정형 데이터(Tabular Data) 환경에서, 연속 함수를 근사하는 신경망보다 축 정렬 분할을 수행하는 트리 기반 앙상블 모형이 더 우수한 귀납적 편향을 제공할 수 있음을 보고하고(Beyazit et al. 2023; Grinsztajn et al. 2022).

본 연구가 제안하는 도메인 지식 기반 특성 공학은 이러한 문제를 해결하기 위한 데이터 중심 AI 관점의 접근법이다(Zha et al. 2025). 전환율 0.12% 수준의 극심한 희소 환경에서 순수 데이터 기반 딥러닝 모델은 백지상태에서 노이즈와 고차원 잠재 패턴을 구분해야 하는 구조적 한계에 부딪힌다 (Karpatne et al. 2017). 본 연구는 검증된 마케팅 이론들을 수학적 감쇠 함수와 확률 밀도 함수 형태의 동태적 상태 변수로 조작화하여 모형의 입력단에 주입한다. 이는 알고리즘이 탐색해야 할 가설 공간을 도메인 지식을 통해 사전에 효율화함으로써, 경량 트리 모형이 희소 정형 데이터에서도 높은 예측 정확도와 자원 효율성을 동시에 달성하도록 지원하는 기제로 작동한다.

전통적인 고객관계관리 문헌의 Recency, Frequency, Monetary(RFM) 모형이나 확률 기반의 고객 생애 가치(CLV) 이론은 주로 과거의 장기간 집계된 거래 이력을 바탕으로 한 정적 모델링에 의존해 왔다. 이에 따라 실시간 다중 접점에서 급변하는 고객의 인지적 상태(마케팅 피로도)나 시간적 맥락(시계열 반응성)을 개별 변수 단위로 다루는 연구는 존재했으나, 이들을 단일 모형 내에 유기적으로 통합하여 AI 모형의 귀납적 편향으로 정립한 시도는 상대적으로 제한적이었다(Akter et al. 2025; Wathieu 2004).

본 연구는 마케팅 이론 기반의 동태적 상태 변수들을 단일 프레임워크로 통합하여 기계학습 모형에 주입하고, 그 예측적 효용을 실증하고자 하며, 구체적인 연구 질문은 다음과 같다.

- **RQ1.** [도메인 지식 통합의 예측적 가치] 전통적 정적 고객 이력 변수에 마케팅 이론 기반의 동태적 상태 변수군들을 동시에 통합하여 반영했을 때, 기존 모형 대비 구매 전환 예측 성능과 오분류 비용 절감에 어떠한 실질적 추가 기여를 제공하는가?
- **RQ2.** [설명 가능성과 예측 신호] 통합된 도메인 변수군 중 전환 예측에 가장 결정적으로 기여하는 핵심 신호는 무엇이며, 설명 가능한 인공지능을 통해 도출된 변수별 기여 패턴은 실무자에게 어떠한 타겟팅 실행 기준을 제공하는가?
- **RQ3.** [모형 적합성과 자원 효율성] 희소성이 매우 높은 실제 디지털 마케팅 환경에서, 마케팅 이론이 귀납적 편향으로 주입된 경량화 트리 모형은 딥러닝 모델 대비 예측 정확도와 마케팅 자원 배분의 효율성을 어떻게 개선하는가?

본 연구의 기여는 다음과 같다. 첫째, 기존 CRM 연구에서 개별적으로 다루어지던 다양한 마케팅 이론을 실시간 로그 기반의 4 대 동태적 상태 변수군으로

체계화하고, 이를 알고리즘의 귀납적 편향으로 결합하는 통합 프레임워크를 정립하였다. 둘째, 블랙박스 예측에 머무르지 않고 SHAP(SHapley Additive exPlanations) 분석을 통해 개별 변수군이 구매 전환 확률에 미치는 예측적 기여도와 비선형적 패턴을 정량화 함으로써, 마케터가 직관적으로 타겟팅 임계값을 설정하고 해석 가능한 기준을 제공하였다. 셋째, 극단적 불균형(0.1234%)을 지닌 대규모 CRM 정형 데이터에서 정형 특화 딥러닝(TabNet) 및 시계열 딥러닝보다 도메인 지식을 장착한 경량 트리 모형이 예측 성능, 추론 효율성, 실무적 ROI 면에서 더 우수한 적정 기술이 될 수 있음을 객관적으로 입증하였다.

본 논문의 2 장에서는 관련 선행 연구를 고찰하고 본 연구의 지식 기반 변수 설계 근거를 제시한다. 3 장에서는 연구 실험 과정에서 사용된 데이터와 분석 알고리즘, 검증 방향을 상세하게 소개하고, 4 장에서는 각 실험 결과와 해석을 다룬다. 마지막으로 5 장 토의에서 연구의 이론적 및 실무적 시사점과 한계를 논의한 후, 6 장에서 연구 결과를 요약하며 마무리한다.

2. 문헌연구

본 연구는 도메인 지식 기반의 특성 공학을 통해 희소한 정형 CRM 데이터 환경에서의 구매 전환 예측력을 제고하고,

설명 가능한 AI 를 바탕으로 다차원 예측 신호를 규명하고자 한다. 이를 위해 2.1 절에서는 동태적 마케팅 변수를 활용한 구매 전환 예측의 이론적 배경과 분절된 이론들의 동시 통합 필요성을 논의하고, 2.2 절에서는 구매 전환 예측 모형의 기술적 진화 과정과 정형 데이터 환경에서의 귀납적 편향 및 적정 기술 선택 문제를 고찰한다.

2.1 동태적 마케팅 변수를 활용한 구매 전환 예측과 이론적 통합 체계

고객 관계 관리 및 데이터베이스 마케팅 문헌에서 고객의 미래 거래 가능성을 평가하는 가장 고전적인 기준은 RFM 모형이다. 선행 연구들은 거래의 최근성, 빈도, 금액이 고객의 미래 수익성과 유의미한 상관관계를 가짐을 실증해 왔다. 나아가 비계약적 환경에서 고객의 잠재적 이탈 시점을 확률 과정(Stochastic Process)으로 모형화하기 위해 Pareto/NBD 모형(Schmittlein et al. 1987)과 BG/NBD(Fader et al. 2005) 등 Buy 'Til You Die(BTYD) 계열의 확률 모형들이 확립되었다. 국내 마케팅 연구에서도 BTYD 프레임워크를 기반으로 비계약적 소매 유통 환경에서의 고객 생애 가치(CLV)를 추정하고 이탈 위험을 정량화하는 연구들이 꾸준히 진행되었다(김병도·박성호 (2011),

《마케팅연구》 (BTYD 기반 고객가치 측정 및 이탈 분석); 라선아·이유재 2015).

그러나 전통적인 RFM 및 확률 모형은 주로 과거의 장기 거래 이력을 일정 기간 단위로 사후 집계하여 고객의 기저 성향을 정적으로 프로파일링하는 데 집중되어 있다. 이로 인해 오늘날과 같이 이메일, 모바일 푸시, SMS 등 다중 접점(Multi-touchpoint)에서 실시간으로 상호작용이 일어나는 디지털 옴니채널 환경에서, 메시지 수신 직후 급변하는 고객의 인지적 상태나 시간적 맥락을 모형 내에 동태적으로 내생화하는 데에는 방법론적 한계가 존재한다. 디지털 환경에서의 고객 여정은 고도로 비선형적이며, 단일 채널에 대한 노출 효과 역시 고객이 직전에 경험한 접점들의 배열과 시간 간격에 따라 상이하게 나타나기 때문이다(박철·강신웅 2018), 《마케팅연구》 (옴니채널 환경의 비선형 고객 여정 및 채널 전환); Lemon and Verhoef 2016). (LemonVerhoef 2016)

이러한 정적 모델링의 공백을 메우기 위해 마케팅 및 소비자 행동 이론에서는 개별 고객의 동태적 상태를 포착하려는 시도들이 분과적으로 이루어져 왔다.

첫째, 소비자 습관화(Habituation) 및 정보 처리 이론은 반복적인 마케팅 자극 노출이 소비자의 인지적 과부하를 유발하고 반응 역치를 상승시킨다고 설명한다. 이는 광고 피로도 또는 마모 현상으로 정의되며, 특정

임계치를 초과한 과도한 메시지 노출은 수신자의 주의력을 감퇴시키고 광고 회피 및 클릭률 저하를 초래한다(Chae et al. 2019; Lambrecht and Tucker 2013). (Chae et al. 2019) (LambrechtTucker 2013) 국내 마케팅 연구에서도 모바일 환경에서 빈번하게 발송되는 마케팅 알림 메시지가 소비자의 지각된 침해성과 피로도를 가중시켜 메시지 회피 및 앱 삭제로 이어질 수 있음을 실증한 바 있다(이수원·김상훈 2020), 《마케팅연구》 (모바일 마케팅 피로도, 지각된 침해성과 광고 회피); 최자영 2019). 본 연구는 이러한 원리를 바탕으로 메시지 수신 후 시간 경과에 따른 피로도의 누적 및 회복 과정을 채널별 반감기(τ) 기반의 지수 감쇠 모델로 조작화한다.

둘째, 상황 의존적 선호 및 캘린더 효과 문헌은 소비자의 구매 확률이 고정되어 있지 않고 시간의 흐름과 경제적 맥락에 따라 비선형적으로 유동함을 보여준다. 사용자의 기저 선호가 물리적 시간에 따라 표류한다는 시점 역동성(Temporal Dynamics) 모델링(Koren 2009)과, 가치분 소득이 급증하는 급여일이나 특정 결제 주기에 소비 성향이 일시적으로 변동한다는 캘린더 효과(OlafssonPagel 2018)는 발송 타이밍이 마케팅 반응의 결정적 조절 요인임을 뒷받침한다. 아울러 미디어 소비 패턴과 생체 리듬의 일치가 정보 수용성을

극대화한다는 실증 발견(Althoff et al. 2017)에 착안하여, 본 연구는 원형(Circular) 통계를 통한 개인별 선호 시간대 일치도와 가우시안 범프(Gaussian Bump) 함수를 활용한 경제적 이벤트 근접도를 동태적 시계열 반응 변수로 구축한다.

셋째, 고객 생애 가치와 행동경제학의 냉각기 효과(Cooling-off Effect)는 구매 직후 일정 기간 동안 소비자의 심리적 만족과 재고 보유로 인해 단기 재구매 확률이 억제되었다가, 고유의 소비 주기가 도래함에 따라 점진적으로 회복되는 규칙성을 설명한다. Fader et al. (2005)의 “빈도의 역설(Paradox of Frequency)”이 지적하듯, 고객의 최근 거래 이후 경과 시간이 개인의 평균 주기를 벗어날 경우 잠재적 이탈 위험이 비선형적으로 급증한다. 본 연구는 이를 반영하여 개별 고객의 구매 간격 분포를 기반으로 현재 시점이 재구매 적기에 얼마나 도달했는지를 정량화한 “재구매 준비도”와 구매 직후의 억제 기간을 정의한 “구매 후 불응기”를 위험률 함수 형태로 설계한다.

넷째, 정보 이론(Information Theory)과 고객 여정의 경로 의존성은 콘텐츠의 참신성과 전달 순서의 구조적 적합성을 다룬다. Shannon (1948)의 정보 엔트로피 이론에 따르면, 예측 가능하고 반복적인 메시지는 정보량이 낮아 수신자의 주의를 환기하지 못하며, 이는 주제 다양화를 통해

정보의 한계 효용 감소를 방어해야 함을 시사한다(Ziegler et al. 2005). 또한 그래프 기반 마코프 모형을 적용한 고객 여정 분석(Anderl et al. 2016)에서 입증되었듯이, 동일한 마케팅 채널이라도 고객이 거처온 선행 접점의 순차적 구성에 따라 전환 기여도가 비선형적으로 조절된다. 국내 개인화 마케팅 연구 역시 추천 맥락과 접점의 정합성이 확보될 때 고객 인게이지먼트와 구매 전환이 유의미하게 제고됨을 보고하고 있다(한상린·성형석 (2021), 《마케팅연구》 (개인화 추천 맥락 정합성과 고객 인게이지먼트)). 본 연구는 이를 “주제 신선도” 및 자카드 계수 기반의 “성공 경로 일치도”로 조작화한다.

중요한 점은, 기존 연구들이 이들 동태적 변수군(피로도, 시점, 주기, 채널) 중 특정 요인만을 단편적으로 분리하여 검증해 왔다는 사실이다. 그러나 실제 디지털 CRM 환경에서 고객의 구매 반응은 단일 요인에 의해 독립적으로 결정되지 않는다. 예를 들어, 최근 메시지 수신 빈도가 높다는 사실은 마케팅 피로도의 누적을 의미할 수도 있지만, 동시에 해당 고객의 구매 욕구가 최고조에 달하여 활발히 반응하고 있는 고관여 상태를 반영할 수도 있다. 따라서 고객의 내재적 거래 주기, 발송 시점의 상황적 맥락, 누적된 노출 피로도, 그리고 전달 경로의 적합성을 하나의 모형 내에 동시에 통합하여

상호작용 효과를 통제하지 않는다면, 개별 변수의 예측적 가치를 왜곡하거나 과대평가할 위험이 크다. 이에 본 연구는 4 대 마케팅 이론 축을 단일 예측 프레임워크로 결합하여, 모형이 계층적이고 유기적인 다차원 예측 신호를 학습할 수 있도록 구조화한다.

2.2 구매 전환 예측 모형의 비교와 적정 기술

이커머스 및 CRM 환경에서 구매 전환 예측 모형은 통계 및 계량경제학적 확률 모형에서 머신러닝, 그리고 심층 신경망으로 발전해 왔다. 초기에는 로지스틱 회귀분석, 생존 분석, 그리고 Pareto/NBD 와 같은 확률 모형이 주를 이루었으나, 이들 모형은 변수 간의 비선형적 상호작용과 고차원 이질성을 유연하게 수용하는 데 구조적 한계가 존재했다. 이에 Random Forest, Gradient Boosting, XGBoost 와 같은 머신러닝 기반 트리 앙상블 모형이 도입되었으며, 다양한 산업군의 고객 이탈 및 구매 예측 문제에서 단일 모형 대비 일관되게 우수한 분류 성능을 입증하며 실무적 표준으로 자리 잡았다(Verbeke et al. 2012).

한편, 컴퓨터 비전 및 자연어 처리(Transformer) 분야에서 딥러닝이 거둔 성과(Vaswani et al. 2017)에 힘입어, 마케팅

분야에서도 고객 상호작용 로그를 순차적 시계열 데이터로 간주하고 LSTM, RNN 등 순환 신경망 아키텍처를 적용하려는 시도가 주류를 형성하였다(Du et al. 2019). 순차 딥러닝 모형은 수작업 특징 공학 없이도 원시 로그로부터 고차원의 잠재 표현을 스스로 학습하는 End-to-End 표현 학습의 장점을 강조한다(Bengio et al. 2012)(Gorishniy et al. 2024). 나아가 최근에는 정형 데이터의 속성을 모델링하기 위해 Self-Attention 메커니즘을 결합한 TabTransformer(Huang et al. 2020)나 Sequential Attention 기반으로 의사결정 트리의 분기 과정을 모사한 정형 특화 심층 신경망인 TabNet(ArikPfister 2021) 등이 제안되며 정형 딥러닝(Tabular Deep Learning) 연구가 본격화되었다.

그러나 최근의 대규모 벤치마크 연구들은 이질적인 범주형 및 수치형 변수가 혼재된 정형 데이터 영역에서 딥러닝이 트리 기반 앙상블 모형보다 일관되게 우월한가에 대해 근본적인 의문을 제기하고 있다(Gorishniy et al. 2024; Grinsztajn et al. 2022)(Shwartz-Ziv and Armon 2022). 대규모 데이터셋을 비교 분석한 Grinsztajn et al. (2022)은 정형 데이터에서 딥러닝 모형이 겪는 한계의 원인을 “귀납적 편향(Inductive Bias)의 불일치”로 설명한다. 이미지나 음성과 같은 비정형 데이터는 인접 픽셀 간의 평활성과

회전/이동 불변성이 보장되는 연속적 공간에 위치하므로 경사하강법 기반의 매끄러운 다항식 함수 근사가 효과적으로 작동한다. 반면, 실제 CRM 정형 로그 데이터는 변수 간의 불연속적이고 계단식인 경계면, 극심한 정보 희소성, 그리고 결측치와 이상치가 빈번히 발생한다. 이러한 환경에서는 연속적 초평면을 가정하는 신경망보다, 직교하는 초평면을 기준으로 공간을 분할하는 트리의 축 정렬 분할(Axis-aligned Splits) 방식이 데이터의 실제 분포를 훨씬 정확하고 안정적으로 모사할 수 있다.

더욱이 구매 전환율이 0.12% 수준에 불과한 극단적인 클래스 불균형 CRM 환경에서는 수백만 개의 가중치 파라미터를 학습해야 하는 심층 신경망이 소수의 양성 신호 대신 다수의 비구매 노이즈를 과적합하여 수렴에 실패할 위험이 매우 높다(AttariArroyave 2025; FarjonBar-Hillel 2022). 이러한 맥락에서 본 연구는 모델의 복잡성을 무조건적으로 확장하는 모델 중심(Model-Centric) 패러다임을 지양하고, 입력 데이터 자체의 표현력과 정보 밀도를 질적으로 보장하는 데이터 중심 AI(Data-Centric AI) 접근법을 채택한다(Zha et al. 2025). 즉, 사전 지식이 전무한 상태에서 신경망이 원시 로그로부터 시간적 패턴을 백지상태로 탐색하도록 방치하는 대신, 마케팅 도메인

이론을 반영한 4 대 동태적 상태 변수를 통해 모델의 가설 탐색 공간을 사전에 효율화하는 귀납적 편향을 명시적으로 주입한다.

마지막으로, 예측 모형의 비즈니스 도입을 위해서는 예측 정확도뿐만 아니라 마케터가 모델의 출력을 신뢰하고 실행 전략으로 전환할 수 있는 설명 가능성(Explainability)이 필수적으로 담보되어야 한다. 고도화된 심층 신경망은 내부 파라미터 간의 복잡한 가중치 결합으로 인해 예측의 근거를 사후적으로 추적하기 어려운 전형적인 블랙박스 구조를 지닌다. 반면 트리 기반 앙상블 모형은 협조적 게임 이론에 기반한 TreeSHAP 기법과 결합될 때 공리적 일관성을 유지하면서 각 입력 변수가 개별 예측값에 기여한 한계 기여도(Shapley Value)를 다항 시간 내에 정확하게 분해할 수 있다(Lundberg et al. 2020; LundbergLee 2017).

단, 본 연구는 SHAP 분석 결과를 특정 마케팅 처치의 순수 인과적 효과(Causal Effect)로 확대 해석하는 것을 엄격히 경계하며, 모형 내부에서 입력 변수들이 구매 전환 확률을 산출할 때 부여 받은 상대적 예측 기여도와 다차원 행동 패턴을 검증하는 도구로 국한하여 활용한다. 종합하면, 본 연구는 이론 기반의 동태적 변수군이 주입된 경량 트리 모델을 주요

실험 모형으로 설정하고, 이를 최신 정형 딥러닝(TabNet) 및 순차 딥러닝(LSTM, RNN 등)과 동일한 조건에서 비교 검증함으로써, 최소 정형 CRM 환경에서 최적의 예측 성능과 자원 효율성을 제공하는 적정 기술의 당위성을 규명하고자 한다. 세부적인 귀납적 편향 주입 메커니즘과 수식과 매핑은 아래 <표 2>에 제시하였다.

3. 데이터 및 방법론

3.1 데이터 수집 및 특성

본 연구는 대규모 전자상거래 환경의 실제 로그 데이터를 분석하기 위해 Kaggle 에 공개된 REES46 의 “E-commerce multichannel direct messaging 2021–2023” 데이터셋을 분석 대상으로 선정하였다. 해당 데이터는 2021 년부터 2023 년까지 2 개년에 걸쳐 중형 전자상거래 플랫폼에서 수집된 고객관계관리(CRM) 기반의 다채널 메시징 이력으로, 실제 이커머스 환경에서 발생한 익명화된 마케팅 메시징 및 고객 반응 기록 로그로 구성되어 있다. 구체적으로 본 데이터셋은 약 185 만 명의 고객을 대상으로 집행된 총 1,907 개 마케팅 캠페인과 이에 따른 1 억 7,200 만 건의 메시지 발송 및 반응 이력을 포함한다.

분석에 활용된 데이터는 고객의 메시지 수신 및 반응 로그, 캠페인 속성, 고객 속성, 외부 시점 정보로 구성된 4 개의

관계형 테이블로 이루어져 있으며 <표 1>, 캠페인 유형은 고객 프로파일 및 프로모션과 직접적인 연관성을 지닌 마케팅 캠페인으로 한정하고 단순 거래 진행 알림 등 운영성 메시지는 분석 대상에서 제외하였다. 고객은 이메일, 모바일 푸시, SMS 등 다양한 채널을 통해 시간 경과에 따라 복합적인 자극에 노출되며, 이러한 이력은 최종 구매 전환 및 이탈 여부와 연계되어 기록되어 있다. 특히 채널별 침해성과 인지적 회복 속도를 고려하여 최근 노출 빈도와 최종 노출 후 경과 시간을 결합한 복합 감쇠 함수를 적용하고 채널별 반감기 파라미터를 차등화하였다. 최종 타겟 변수인 구매 전환율은 약 0.1234% 수준으로 극단적인 클래스 불균형을 나타내며, 메시지, 캠페인, 고객, 시점 정보가 상이한 식별자로 분리되어 있어 개별 고객의 시간 흐름에 따른 상호작용 여정을 단일 시퀀스 형태로 재구성하는 전처리 과정을 수행하였다. 본 데이터셋은 특정 플랫폼의 로그이나 다수의 상품 카테고리를 아우르고 있으며, 메시지 수신, 오픈, 클릭, 구매로 이어지는 전형적인 마케팅 깔때기 구조와 롱테일(Long-tail) 반응 분포를 충실히 반영하고 있어 일반적인 전자상거래 CRM 환경으로의 연구 결과 확장이 가능할 것으로 판단된다.

<표 1> 데이터테이블 주요 변수 구성 및
속성 설명

관계형 테이블	세부 속성 및 설명
메시지 전송 및 반응 로그 (Interaction Logs)	- 속성: 발송 시각(Timestamp), 채널(Channel), 플랫폼, 메시지 유형, 이메일 제공자 - 반응: Open, Click, Purchase 등 고객의 단계별 행동 데이터
캠페인 메타 정보 (Campaign Metadata)	- 속성: 캠페인 유형(Bulk/Trigger/Transactional), 주제(Topic), 마케팅 채널 - 설명: 마케팅 전략 및 운영 기간 등 공급자 측면의 의도(Intent) 정보

고객 관계 속성 (Customer Attributes)	- 속성: 고객 식별자(User ID), 최초 구매일(First Purchase Date) - 설명: 고객의 라이프사이클(Lifecycle) 단계 및 충성도를 추정하는 기준 정보
외부 시점 정보 (Temporal Context)	- 속성: 공휴일 여부, 요일, 월 정보 - 설명: 계절성(Seasonality) 및 사회적 이벤트가 소비에 미치는 외부 효과 정보

3.2 도메인 지식 기반 파생변수
프레임워크

<표 2> 마케팅 이론 기반 메커니즘 파생변수화 및 수식 매핑 프레임워크

도메인 지식 및 이론적 역할	문헌상 이론적 정의 및 기반 마케팅/행동 이론	본 연구의 조작적 정의 (메커니즘 파생변수화 및 수식)
① 구매/재구매 주기 (기저 구매 성향 및 잠재적 재구매 욕구 포착)	• 이론적 정의: 구매 직후 심리적 만족으로 인한 잠재적 냉각기와 일정 기간 경과 후 소비 주기 재진입에 따른 잠재적 재구매 욕구 변동 상태 • 기반 이론: (1) 고객 생애 가치(CLV), (2) BTYD 모형 (Pareto/NBD, BG/NBD), (3) 행동경제학 냉각기 효과	• 재구매 준비도: 과거 구매 간격 분포 기반 개인별 구매 사이클 단계 계산 $h(t) = \exp\left(-\frac{1}{2}\left(\frac{\text{마지막 구매 경과일} - \mu}{\sigma}\right)^2\right)$ • 구매 후 불응기: 구매 직후 냉각기 및 재구매 임계시점 확률 밀도 지수 계산 $r(t) = 1 - \exp\left(-\frac{t}{\tau}\right)$
② 시계열적 반응 (내재된 구매 욕구가 실제 행동으로 증폭되는 타이밍 조절)	• 이론적 정의: 고정된 선호가 아닌, 시간의 흐름, 요일,	• 선호 시간대 일치도: 원형 좌표계 기반 개인별 선호 시간대 일치도 계산 $d_{norm} = \frac{(1 - \cos(\theta_{curr} - \bar{\theta}))}{2}$

	시간대별 인지 리듬, 경제적 여유 주기 등에 따라 고객 반응 성향이 변동하는 현상 • 기반 이론: (1) 상황 의존적 선호, (2) 유통 관리 캘린더 효과 (가처분 소득 변동), (3) 생체 리듬과 인지 성과	• 경제적 캘린더 효과: 급여일/분기말 근접도 가우시안 범프 지수 기반 계산 $bump(t) = \exp\left(-\frac{(t - t_p)^2}{\sigma^2}\right)$
③ 마케팅 피로도 (과도한 노출 필터링 및 메시지 수신 직후 발생가능한 일시적 예측 확률 감소 현상 포착)	• 이론적 정의: 반복적 광고 자극 노출로 인해 소비자의 인지적 과부하, 주의력 저하 및 자극 회피 심리 상태 • 기반 이론: (1) 정보 처리 이론 및 소비자 습관화 이론, (2) 광고 마모 효과 (Wearout/Weariness), (3) 한계 효용 체감 법칙	• 누적 마케팅 피로도: 반복 자극으로 인한 인지적 자원 고갈 및 회복 과정을 채널별 반감기 파라미터를 적용하여, 최근 메시지들의 시간 경과에 따른 누적 지수 감쇠 합 계산 $F(t) = \sum_{c \in C} \exp\left(-\frac{\Delta t_c(t)}{\tau_c}\right)$ • 고객 비활성 상태여부: 채널 별 마지막 메시지 수신 시점으로부터 임계치 초과 여부로 계산
④ 마케팅 채널 효과성 (모호한 대상을 배제하고 전환 정밀도(Precision) 최적화)	• 이론적 정의: 동일 메시지 반복에 따른 신선도 저하 및 설득 경로상 선행 접점과의 구조적 적합성에 따른 반응 효과 하강 현상 • 기반 이론: (1) 정보 이론 (엔트로피/신규성), (2) AIDA/깔때기 모형, (3) 옴니채널 경로 의존성	• 콘텐츠 주제 신선도: 노출 빈도와 경과 시간을 결합한 복합 감쇠 지수 계산 $N_{topic(t)} = \exp\left(-\frac{N_{td}}{\kappa}\right) \cdot \left(1 - \exp\left(-\frac{\Delta t}{\tau}\right)\right)$ • 성공 구매 경로와의 유사도 산출: 구매 발생 직전의 채널 흐름 기반 유사도 계산 $A_{path} = \frac{ P_{current} \cap P_{success} }{ P_{current} \cup P_{success} }$

선행연구에서 고찰한 마케팅 이론들은
소비자 행동 변화를 설명하는 이론적

기반을 제공하지만, 개념적 수준에 머무를 경우 기계학습 알고리즘이 직접 연산할 수 있는 특성으로 반영되기 어렵다. 이에 본 연구는 이론적 개념과 실제 데이터 연산 방식 간의 간극을 해소하고자 실시간 로그 데이터를 기반으로 4 대 도메인 지식 축에 대한 조작적 정의를 정립하였다. <표 2>는 본 연구에서 도출한 4 대 도메인 지식 축, 기반 이론, 이론적 및 조작적 정의, 산출 수식을 체계적으로 종합하여 제시한다.

첫째, 구매 및 재구매 주기 패턴 축은 고객 생애 가치 이론을 바탕으로 고객별 구매 주기의 규칙성을 정량화한다. 특히 행동경제학의 냉각기 효과(Cooling-off Effect)를 반영하여 구매 직후 추가 구매 확률이 감소했다가 일정 주기 경과 후 점진적으로 회복되는 기저 성향을 모델링하였다. 이를 위해 개별 고객의 과거 구매 간격 분포를 기반으로 현재 시점이 고객 고유의 재구매 사이클상 어느 단계에 위치하는지를 확률 밀도 함수 및 위험률 함수를 통해 산출하였다.

둘째, 시계열적 반응 패턴 축은 소비자행동론의 상황 의존적 선호(Context-dependent Preference) 및 유통 관리의 캘린더 효과(Calendar Effect)에 근거하여 시간적 및 경제적 맥락을 포착한다. 원형 통계(Circular Statistics) 기법을 활용하여 고객별 과거 선호 시간대 및 요일과의

일치도를 코사인 거리 기반으로 계산하고, 급여일 및 분기 말 등 가치분 소득 변동 시점에 대한 근접도를 모델링하여 마케팅 수용도의 동태적 변화를 측정하였다.

셋째, 마케팅 피로도 패턴 축은 광고 마모 효과(Advertising Wear-out)와 소비자 습관화(Habituation) 이론에 기반한다. 반복적인 마케팅 자극으로 인한 인지적 자원 고갈과 회복 과정을 지수 감쇠 모델로 조작화하여, 채널별 침해성에 따른 누적 피로도 지수를 실시간으로 추적하도록 설계하였다.

넷째, 마케팅 채널 효과성 패턴 축은 정보 이론의 엔트로피(Entropy) 개념과 고객 여정의 경로 의존성(Path Dependency)을 반영한다. 특정 주제에 대한 노출 빈도와 경과 시간을 결합하여 콘텐츠의 주제 신선도를 정량화하고, 과거 구매 전환에 기여한 유효 채널 경로와 현재 고객 여정 간의 경로 유사도를 산출하여 전환 가능성을 평가하도록 구성하였다.

3.3 데이터 전처리 및 데이터셋 구축

본 연구는 실제 마케팅 실무 환경의 조건을 온전히 반영하고 데이터 누수(Data Leakage) 및 선견 편향(Look-ahead Bias)을 엄격히 통제하기 위해 데이터 전처리 및 분할 프로토콜을 수립하였다. 먼저 구매

전환율이 약 0.1234%에 불과한 원본 데이터의 극단적인 클래스 불균형 분포를 인위적으로 왜곡하지 않고 그대로 유지하였다. 가상 샘플링을 통한 인위적 데이터 보정은 모형 배포 시 거짓 양성(False Positive)의 급증을 초래할 수 있으므로, 1 억 7,200 만 건의 원천 로그 분포를 보존한 상태에서 층화 무작위 분할(Stratified Random Split)을 적용하여 학습 데이터 70%, 검증 데이터 15%, 테스트 데이터 15%의 비율로 분할하였다(Thabtah et al. 2020). 아울러 학습 과정에서는 비용 민감 학습(Cost-sensitive Learning) 방식을 적용하여 소수 클래스인 구매 전환에 대한 오분류 패널티를 차등 부여함으로써 기저 데이터 분포의 변형 없이 소수 클래스의 식별력을 제고하였다.

또한 데이터 누수를 원천 차단하기 위해 모든 결측치 대체 및 스케일링 등의 전처리 통계량은 오직 학습 데이터셋에서만 산출 및 고정되었으며, 검증 및 테스트 세트에는 학습 세트의 기준을 동일하게 적용하였다. 나아가 관계형 테이블을 결합하여 개별 고객의 시계열적 행동 여정을 재구성함에 있어, 모든 파생변수의 산출 범위는 예측 기준 시점 직전까지 관측된 과거 데이터로 엄격히 제한하여 미래 시점의 정보가 입력 변수에 혼입되는 현상을 방지하였다.

3.4 예측 알고리즘 실험 설계 및 평가


본 연구는 도메인 지식 주입 프레임워크의 유효성을 다각도로 검증하기 위해 전통적인 머신러닝 모델부터 최신 딥러닝 아키텍처에 이르는 총 9 종의 분류 알고리즘을 비교 평가하였다. 정형 데이터 분석에서 우수한 일반화 성능이 입증된 트리 기반 앙상블 계열로는 Random Forest 와 XGBoost 를 선정하였다. 이들 모형은 설계된 동태적 도메인 변수가 고객의 시계열적 행동 구조를 정형 신호로 요약하는 효율성을 평가하는 주요 기준 모형으로 기능한다. 아울러 심층 신경망의 효용성을 종합적으로 비교하기 위해 전역적 상호작용 학습에 적합한 MLP, 국소적 패턴 추출을 위한 CNN, 순차적 시계열 정보 처리에 강점을 지닌 RNN 과 LSTM 등 단일 신경망 구조를 구축하였으며, 이들의 구조적 장점을 결합한 하이브리드 모델인 CNN-LSTM 과 RNN-LSTM 을 함께 구성하였다. 추가적으로 정형 데이터 처리에 특화된 최신 딥러닝 모델인 TabNet 을 실험군에 포함하였다.

평가 지표의 경우 구매 전환 클래스의 극단적인 희소성을 감안하여 통상적인 분류 문제에서 활용되는 정확도(Accuracy) 및 ROC-AUC 외에, 소수 클래스의

포착력과 비즈니스 적중 효율성을 객관적으로 평가할 수 있는 PR-AUC(Precision-Recall AUC)와 재현율에

4. 실증 분석 결과

가중치를 부여하는 F2-score 및 F1-score 를 핵심 평가지표로 설정하였다.



<그림 1> 제안하는 방법론의 프레임워크

4.1 하이퍼파라미터 최적화 및 검증 프로토콜

본 연구는 극단적인 클래스 불균형(0.1234%) 환경에서 예측 모형의 일반화 성능을 확보하고 데이터 누수(Data Leakage)를 방지하기 위해 5-Fold 교차검증과 PR-AUC 목적함수 기반의 Optuna 베이지안 최적화 파이프라인을 구축하였다. 전체 데이터셋은 학습, 검증, 테스트 세트로 엄격히 분할하였으며, 학습 단계에서는 특정 데이터 분할에 따른

과적합을 방지하고 시간적 선후 관계 왜곡을 통제하기 위해 5-Fold Stratified Cross-Validation 을 적용하였다.

각 알고리즘의 최적 하이퍼파라미터 탐색에는 탐색 효율성과 수렴 속도가 우수한 Optuna 기반의 Bayesian Optimization 기법을 활용하였다. 탐색 공간은 각 모형의 아키텍처 특성을 반영하여 개별 정의되었으며, 데이터 스케일러(Scaler) 및 분류 임계값(Threshold)을 포함한 구체적인 파라미터 탐색 범위와 도출된 최적값은 <부록 2>에 수록하였다. 모든

하이퍼파라미터 최적화는 희소 데이터 평가에 적합하도록 검증 세트의 PR-AUC를 최대화하는 방향으로 수행되었다. 아울러 조기 종료(Early Stopping)와 프루닝(Pruning) 기법을 병행하여 비효율적인 연산을 배제하고 모형의 일반화 성능을 안정적으로 확보하였다.

4.2 도메인 지식 기반 파생변수의 기술통계 및 타당성 검증

단변량 집단 간 차이 검정(t -test 및 χ^2 test) 분석 결과, 본 연구에서 제안한 4 대 도메인 지식 기반 동태적 파생변수군 전체가 구매 여부(Purchased vs. Non-purchased)에 따라 통계적으로 유의미한 차이($p < 0.001$)를 나타내어 변수 구축의 개념적 타당성과 집단 판별력을 확인하였다. 변수군별 세부 기술통계 및 가설 검정 결과는 <부록 1>에 제시하였으며, 도메인 지식 축별 주요 통계적 특성은 다음과 같다.

첫째, “구매/재구매 주기 패턴” 변수군은 소비 주기 도래에 따른 집단 간 행동 차이를 유의미하게 포착하였다. 구매 집단의 마지막 구매 경과일은 평균 305.98 ± 129.04 일로 비구매 집단(364.52 ± 11.22 일)에 비해 통계적으로 유의미하게 짧게 관찰되었다. 또한 행동경제학적 냉각기 효과를 반영한 “구매

후 불응기”와 위험률 함수 기반의 “재구매 준비도” 역시 구매 집단에서 유의미하게 높은 평균값을 나타내어, 개인별 재구매 사이클의 임계점에 도달한 고객군을 식별하는 데 기여함을 확인하였다.

둘째, “시계열적 반응 패턴” 변수군은 구매 의사결정이 발현되는 외부 맥락적 접점의 유의미한 차이를 식별하였다. 주말 여부 교차분석 결과, 구매 전환 접점의 21.45%가 주말에 집중된 반면 비구매 접점은 5.75%에 그쳐 뚜렷한 주말 집중 효과를 나타냈다($p < 0.001$). 아울러 “선호 요일 일치도” 및 “급여일 근접도” 역시 두 집단 간 분포 차이가 유의미하게 형성되어, 주기적 가처분 소득 변동과 개인의 활동 리듬이 구매 전환 예측의 유효한 정황 신호로 기능함을 확인하였다.

셋째, “마케팅 피로도 패턴” 변수군은 능동적 참여도와 피로도 누적 간의 상호작용 신호를 명확히 구분하였다. 구매 집단은 최근 30 일간의 유저 오픈율($t = 40.32$, $p < 0.001$) 및 클릭률($t = 38.62$, $p < 0.001$)에서 비구매 집단 대비 현저히 높은 반응성을 보였다. 반면 이메일 경과 시간 분석에서는 구매 집단의 평균 경과 시간이 761.29 ± 1605.05 분으로 비구매 집단(1084.59 ± 071.62 분)보다 유의미하게 짧게 나타나, 적절한 휴식 간격 이후 자극에 노출되었을 때 전환 가능성이

제고되는 동태적 피로도 완화 패턴을 실증하였다.

넷째, “마케팅 채널 효과성 패턴” 변수군은 메시지 콘텐츠의 신선도와 성공 접점 경로의 유의성을 통계적으로 증명하였다. “주제 신선도”($p < 0.001$)와 “성공 캠페인 유사도”($p < 0.001$) 모두 구매 집단에서 통계적으로 높게 형성되었다. 이는 과거 유효했던 설득 경로와의 부합도 및 신규 콘텐츠의 전달 여부가 타겟팅 정밀도를 보정하는 유용한 도메인 지식 신호임을 시사한다.

4.3 회소 CRM 정형 데이터에서의

알고리즘별 예측 성능 비교

본 절에서는 구매 전환율이 0.1234%인 회소 CRM 홀드아웃 테스트 세트 환경에서 총 9 종의 머신러닝, 심층 신경망 및 정형 딥러닝 알고리즘의 예측 성능을 비교 검증하였다. 베이스라인 변수와 전체 도메인 지식이 통합된 변수 투입 시 알고리즘별 개별 및 군집 평균 평가 결과는 <표 3>과 같다.

<표 3> 원본포 홀드아웃 테스트 세트(0.1234%)에서의 알고리즘별 성능 평가 및 증분 비교

Algorithm m	Precision		Recall		F1-score		F2-score		PR-AUC	
	Base	Total	Base	Total	Base	Total	Base	Total	Base	Total
XGB	0.4199	0.2991 (-28.8%)	0.3074	0.5230 (70.1%)	0.3550	0.3806 (7.2%)	0.3248	0.4549 (40.0%)	0.3177	0.3620 (13.9%)
RF	0.2371	0.3041 (28.3%)	0.6456	0.4819 (-25.4%)	0.3468	0.3729 (7.5%)	0.4802	0.4315 (-10.1%)	0.2887	0.3382 (17.1%)
MLP	0.2561	0.2602 (1.6%)	0.4144	0.4635 (11.9%)	0.3165	0.3333 (5.3%)	0.3688	0.4009 (8.7%)	0.2675	0.3072 (14.8%)
CNN	0.2680	0.2392 (-10.8%)	0.3290	0.3549 (7.9%)	0.2954	0.2858 (-3.3%)	0.3147	0.3236 (2.8%)	0.2302	0.2546 (10.6%)
RNN	0.2381	0.2598 (9.1%)	0.4695	0.4965 (5.8%)	0.3159	0.3411 (8.0%)	0.3931	0.4200 (6.8%)	0.2629	0.3195 (21.5%)
LSTM	0.2163	0.2514 (16.2%)	0.6035	0.5084 (-15.8%)	0.3185	0.3364 (5.6%)	0.4444	0.4221 (-5.0%)	0.2688	0.3166 (17.8%)
CNN-LSTM	0.2083	0.2393 (14.9%)	0.6272	0.4155 (-33.8%)	0.3127	0.3037 (-2.9%)	0.4473	0.3621 (-19.0%)	0.2648	0.2647 (-0.0%)
RNN-LSTM	0.2519	0.2983 (18.4%)	0.4290	0.4149 (-3.3%)	0.3174	0.3470 (9.3%)	0.3761	0.3848 (2.3%)	0.2661	0.3176 (19.4%)
TabNet	0.2806	0.2690 (-4.1%)	0.3960	0.4781 (20.7%)	0.3285	0.3443 (4.8%)	0.3659	0.4138 (13.1%)	0.2826	0.3182 (12.6%)

ML Average	0.3285	0.3016 (-8.2%)	0.4765	0.5025 (5.4%)	0.3509	0.3768 (7.4%)	0.4025	0.4432 (10.1%)	0.3032	0.3501 (15.5%)
DL Average	0.2456	0.2596 (5.7%)	0.4669	0.4474 (-4.2%)	0.3150	0.3273 (3.9%)	0.3872	0.3896 (0.6%)	0.2633	0.2997 (13.9%)

실험 결과, 도메인 지식 파생 변수가 통합되었을 때 머신러닝 및 딥러닝 군집 평균 전체에서 PR-AUC 가 각각 +15.5%, +13.9% 상승하였으며, 핵심 종합 평가지표인 F1-score 역시 각각 +7.4%, +3.9% 향상되었다. 이는 마케팅 도메인 지식을 동태적 상태 변수로 조작화하여 주입하는 접근법이 알고리즘 구조와 무관하게 예측 성능을 보편적으로 개선할 수 있음을 시사한다.

최적 예측 모형으로 선정된 XGBoost 는 도메인 지식 결합 후 베이스라인 대비 Recall 이 30.74%에서 52.30%로 대폭 증가(70.1%)하여 구매 전환 고객의 과반을 성공적으로 포착하였다. XGBoost 는 높은 정밀도(41.99%)에 비해 소수 클래스를 보수적으로 예측하여 실제 구매자의 약 70%를 미포착하는 한계가 존재했으나, 도메인 지식을 투입함으로써 잠재적 구매 신호를 효과적으로 포착하였다. 그 결과 F1-score, F2-score, PR-AUC 모두 전체 9 개 알고리즘의 비교 조건 중 가장 높은 수치를 기록하였다.

아울러 정형 데이터 특유의 불연속적 결정 경계를 학습함에 있어 트리 기반 앙상블 모형이 심층 신경망 계열 대비 일관된 성능 우위를 보였다. 도메인 지식 투입 후 ML 군의 평균 F1-score 및 PR-AUC 는 DL 군의 평균 수치를 유의미하게 상회하였다. 특히 정형 데이터 처리에 특화된 최신 아키텍처인 TabNet 이나 RNN-LSTM 역시 도메인 지식 주입 시 성과 개선을 보였으나, 트리 기반 모형인 XGBoost 및 Random Forest 의 F1 수치에는 미치지 못하였다.

단일 지표 간 트레이드오프 관점에서 도메인 지식 주입은 모형별 예측 불균형을 재조정(Rebalancing)하는 역할을 수행하였다. Random Forest 의 경우 베이스라인에서 64.56%의 높은 재현율을 보였으나 정밀도가 23.71% 수준으로 거짓 양성(False Positive)이 빈번히 발생하였다. 반면 도메인 지식 통합을 통해 정밀도를 30.41%로 제고(28.3% 상승)하며 노이즈를 효과적으로 필터링하였으며, 결과적으로 정밀도와 재현율의 균형을 나타내는 F1-score 는 +7.5% 상승하였다. 결론적으로 구매 전환율 0.1234%의 희소 CRM 데이터 환경에서는

사전 지식이 없는 딥러닝의 표현 학습에 의존하기보다, 잘 설계된 마케팅 도메인 변수를 반영한 트리 기반 앙상블 모델을 활용하는 것이 예측 정확도 및 종합 분류 효율성(F1/F2/PR-AUC) 측면에서 가장 유용한 대안임을 실증한다.

4.4 도메인 지식 축별 세부 영향력 분석

XGBoost 모델을 대상으로 수행한 변수 절삭 실험 결과, 마케팅 피로도(③) 축과 시계열적 반응(②) 축이 재현율(Recall)과 종합 분류 효율성(F1, F2, PR-AUC) 제고를 주도하는 핵심 예측 신호임이 확인되었다. 반면, 구매/재구매 주기(①) 축과 마케팅 채널 효과성(④) 축은 단독 투입 시 단기 전환 포착보다는 경계면 재조정을 통한 보조적 스크리닝 역할을 수행하는 것으로 나타났다. 베이스라인 대비 4 가지 도메인 지식 축의 개별 추가에 따른 상세 성과 및 증분 변화율은 <표 4>와 같다.

도메인 지식 축별 세부 기여도를 살펴보면, 마케팅 피로도 축(③)은 단일 변수 그룹 중 가장 큰 폭의 성능 개선을 견인하였다. 베이스라인 대비 Recall 이 72.58% 증가하였으며, 이에 따라 F1-score(+8.11%), F2-score(+41.66%), PR-AUC(+10.40%) 모두 최고 개선 폭을 기록하였다. 이는 최근 노출 강도, 수신

간격, 반응 감쇠율 등의 지표가 고객의 즉각적 전환 의도를 식별하는 1 순위 단기 신호로 작용함을 보여준다.

시계열적 반응 축(②)은 피로도 축 다음으로 높은 예측 기여도를 나타냈다. Recall 이 40.07% 상승함에 따라 F2-score(+24.70%) 및 PR-AUC(+7.47%)의 유의미한 성과 개선이 확인되었다. 이는 요일, 시간대, 특정 급여 주기 등 시간적 맥락 정보가 잠재적 구매 욕구가 실제 행동으로 구현되는 최적의 마케팅 타이밍을 조율하는 요인으로 기능함을 의미한다.

구매/재구매 주기 축(①)과 마케팅 채널 효과성 축(④)은 단독 추가 시 정밀도와 재현율 간의 소폭 조정 양상을 보였다. 두 축 모두 단독 투입 시에는 Recall 과 F1-score 에서 미세한 감소가 관찰되었으나, PR-AUC 에서는 각각 +1.08% 및 +0.21%의 소폭 상승을 보였다. 이는 단기적 구매 자극 신호(②, ③)와 달리, 주기 및 채널 변수는 기저 성향을 보정하고 예측 경계면을 정합화하는 보조적 스크리닝 기제로 작동함을 시사한다.

결론적으로 도메인 지식의 단독 반영 결과는 피로도에 의한 1 차 전환 대상 포착 → 시계열에 의한 마케팅 시점 조율 → 주기 및 채널에 의한 기저 확률 보정이라는 단계적 의사결정 구조를

반영한다. 피로도 및 시계열 축을 통해 종합 분류 성능의 상한을 완성하는 토대가 대폭 제고된 Recall 은 향후 전체 변수군 됨을 실증한다.

통합 시 여타 보조 변수들과 결합하여

<표 4> 최적 알고리즘(XGBoost) 기반 도메인 지식 축별 상대적 증분 변화

Experiment	Feature Count	Δ Precision	Δ Recall	Δ F1-score	Δ F2-score	Δ PR-AUC
Baseline	41	0.4201	0.3077	0.3556	0.3253	0.3182
Baseline + ① 구매/재구매 주기	44	0.4082 (-2.7%)	0.3055 (-0.7%)	0.3495 (-1.6%)	0.3217 (-1.0%)	0.3214 (+1.1%)
Baseline + ② 시계열적 반응	47	0.3273 (-22.1%)	0.4312 (+40.1%)	0.3722 (+4.8%)	0.4052 (+24.7%)	0.3414 (+7.5%)
Baseline + ③ 마케팅 피로도	49	0.3016 (-28.4%)	0.5313 (+72.6%)	0.3844 (+8.1%)	0.4605 (+41.7%)	0.3514 (+10.4%)
Baseline + ④ 마케팅 채널 효과성	46	0.3992 (-4.8%)	0.3052 (-0.8%)	0.3463 (-2.6%)	0.3203 (-1.5%)	0.3182 (+0.2%)

4.5 비즈니스 마케팅 타겟팅 적중력 및 비용 절감 효과

본 절에서는 통계적 평가지표를 넘어, 제안된 4 가지 도메인 지식 축이 실제 마케팅 타겟팅 환경에서 제공하는 비즈니스 실무 효용성인 타겟팅 적중력 및 예산 최적화 효과를 오차 행렬과 상위 타겟팅 규모별 적중 수(Top-K Hits)를 통해

검증하였다. 분석 결과, 마케팅 피로도(③) 및 시계열적 반응(②) 축이 실제 구매자(TP) 포착 규모를 대폭 확대하는 주도적 역할을 수행한 반면, 구매/재구매 주기(①) 및 마케팅 채널 효과성(④) 축은 과도한 타겟팅 확장을 제어하는 보완적 기제로 작동함을 확인하였다. 베이스라인 모형에 각 도메인 지식 축을 개별 추가했을 때의 상세 적중 지표는 <표 5>와 같다.

<표 5> XGBoost 모형 기준 도메인 지식 축별 Top-K 타겟팅 적중 수 및 오차 행렬 상세

Experiment	Top 15k Hits	Top 35k Hits	Top 50k Hits	진짜 구매 (TP)	거짓 정보 (FP)	미포착 (FN)	진짜 비구매 (TN)
Baseline	8,290	11,507	14,276	9,787	13,519	22,050	25,752,924
Baseline + ① 구매/재구매 주기	8,308	11,421	14,345	9,718	14,087	22,119	25,752,356

78Baseline + ② 시계열적 반응	8,411	12,315	15,222	13,708	28,174	18,129	25,738,269
Baseline + ③ 마케팅 피로도	8,308	12,160	15,962	16,890	39,302	14,947	25,727,141
Baseline + ④ 마케팅 채널 효과성	8,256	11,266	14,052	9,701	14,586	22,136	25,751,857

도메인 지식 축별 세부 분석 결과, 마케팅 피로도 축(③)은 실제 구매자(TP) 포착 물량을 확대하고 미포착(FN)에 따른 기회비용을 줄이는 데 가장 유의미하게 기여하였다. 피로도 변수군이 투입되었을 때 진짜 구매자(TP)는 베이스라인(9,787 명) 대비 16,890 명으로 크게 증가하였으며, 오발송 고객(FN)은 22,050 명에서 14,947 명으로 감소하였다. 또한 상위 5 만명 타겟팅 시 가장 많은 15,962 명의 적중 수를 기록하여, 최근의 마케팅 노출 누적도와 반응 패턴이 구매 전환을 유도하는 주요 실무적 지표임을 확인하였다. 시계열적 반응 축(②) 역시 피로도 축과 유사하게 타겟팅 포착 범위를 넓히는 확장적 특성을 보였다. 해당 변수군 추가 시 진짜 구매자(TP)는 13,708 명으로 증가하였으며, Top 35k 구간(12,315 명)과 Top 50k 구간(15,222 명) 모두 베이스라인 대비 향상된 타겟팅 적중 수를 나타냈다. 이는 특정 요일이나 시간대적 맥락이 전환

가능성이 높은 고객군을 추가로 선별하는데 효과적임을 의미한다. 반면 구매/재구매 주기(①)와 마케팅 채널 효과성(④) 축은 타겟팅 규모를 확장하기보다는 기존의 예측 경계면을 보수적으로 유지하는 특성을 보였다. 두 변수군의 경우 진짜 구매자(TP) 수 각각 9,718 명과 9,701 명으로 오차 행렬 지표가 베이스라인 수준과 유사하게 유지되었다. 이는 고객의 장기적 구매 주기나 선호 채널 이력 변수가 단기적 구매 확율을 급격히 증폭시키기보다는, 구매 확률이 모호한 대상을 보수적으로 필터링하여 정밀도를 관리하는 기제로 작동함을 시사한다.

결론적으로 본 실증 결과는 마케팅 실무에서 일반적으로 과거 장기 구매 이력(①)이 가장 중시되던 전통적 관점과 달리, 0.1234%의 극심한 불균형 환경 하에서는 고객의 즉각적인 마케팅 피로도(③)와 시계열적 반응 맥락(②)이

실제 구매 전환을 포착하는 데 더 높은 상대적 효용을 지닐 수 있음을 확인해 준다. 이러한 지식 축들의 상호보완적 결합은 마케터가 가용 예산에 맞추어 진짜 구매자(TP)와 오발송 고객(FP) 사이의 최적 균형을 설정할 수 있는 의사결정 기준을 제공한다.

4.6 주요 파라미터 민감도 및 강건성 검증

본 절에서는 제안된 프레임워크의 학술적 타당성과 실무 적용성을 제고하기 위해 주요 모형 파라미터 및 운영 기준에 대한 민감도 분석(Sensitivity Analysis)을 수행하였다. 분석은 탐색적으로 설정된 채널별 마케팅 피로도 반감기 파라미터(τ) 변동에 따른 모형의 구조적 강건성 평가와

마케팅 가용 예산에 따른 상위 타겟팅 규모(Top-K) 변동 민감도 분석의 두 가지 축으로 구성된다.

마케팅 피로도 반감기 파라미터(τ)를 기준치 대비 $\pm 50\%$ 범위로 조정하며 평가한 결과, 최적 모형의 F1-score 와 PR-AUC 는 각각 0.3783~0.3873, 0.3527~0.3613 의 좁은 구간 내에서 안정적으로 유지되어 높은 구조적 강건성을 나타냈다. 이는 제안된 동태적 피로도 변수가 특정 파라미터 설정값에 과적합되지 않고, 소비자의 노출 감쇠 패턴을 일반화하여 포착하고 있음을 시사한다. 채널별 기준 반감기에 대해 0.50x 부터 1.50x 까지 5 단계의 배율을 적용한 상세 민감도 평가 결과는 <표 6>과 같다.

<표 6> 마케팅 피로도 반감기 파라미터(τ) 변동에 따른 예측 성능 민감도 평가

Half-life Multiplier	SMS τ	Email τ	Push τ	Precision	Recall	F1-score	F2-score	PR-AUC	Δ PR-AUC
0.50x	36h	24h	12h	0.2992	0.5375	0.3845	0.4637	0.3590	0.0056
0.75x	54h	36h	18h	0.3353	0.4576	0.3870	0.4265	0.3613	0.0079
1.00x (Baseline)	72h	48h	24h	0.3042	0.5181	0.3833	0.4542	0.3534	0.0000
1.25x	90h	60h	30h	0.3073	0.4922	0.3783	0.4393	0.3527	-0.0007
1.50x	108h	72h	36h	0.3291	0.4706	0.3873	0.4333	0.3604	0.0070

실험 결과, 반감기 파라미터를 절반으로 축소하거나 1.5배로 확대하여도 PR-AUC 의 최대 편차는 +0.0079 수준에 불과하였으며, F1-score 역시 기준치(0.3833) 대비 유사한 수준을 보였다. 특히 반감기를 비교적 짧게

설정한 조건(0.50 배)에서는 재현율이 0.5375 까지 상승하였고, 반감기를 길게 설정한 조건(0.75 배, 1.50 배)에서는 정밀도가 약 0.33 수준으로 개선되는 상호보완적 트레이드오프가 관찰되었다.

이러한 결과는 제안 모형이 특정 반감기 값에 민감하게 반응하지 않으며, 실무 적용 시 채널별 반감기 설정에 대한 유연한 운영 여지를 제공함을 의미한다.

또한, 원본포 홀드아웃 테스트 세트를 대상으로 상위 타겟팅 규모(K)를 변동시킨 결과, 고적중률 중심의 정밀 타겟팅 전략과

전환 고객 포착 중심의 확장 타겟팅 전략 간의 명확한 실무적 분기점이 도출되었다. 상위 타겟팅 규모에 따른 실제 구매자 포착 수(TP), 적중률(Precision@K\$), 누적 재현율(Cumulative Recall), 및 무작위 발송 대비 향상도 평가 결과는 <표 7>과 같다.

<표 7> XGBoost 모형 기준 도메인 지식 축별 Top-K 타겟팅 적중 수 및 오차 행렬 상세

Top Targeting (K)	Positive Ratio	Captured Buyers (TP)	Precision@K	Cumulative Recall	Random vs. Lift
10,000	0.04%	5,320	53.20%	16.71%	431.1x
20,000	0.08%	9,340	46.70%	29.34%	378.4x
50,000	0.19%	15,580	31.16%	48.94%	252.5x
100,000	0.39%	23,490	23.49%	73.78%	190.3x
200,000	0.78%	30,510	15.26%	95.83%	123.7x

분석 결과, 건당 발송 단가가 상대적으로 높은 채널의 경우 Top 10,000 전략을 적용할 때 53.20%의 정밀도와 431.1 배의 향상도(Lift)를 기록하여 마케팅 예산 낭비를 최소화할 수 있다.

반면 앱 푸시나 이메일 등 한계 발송 비용이 극히 낮은 채널의 경우, 전체 고객의 0.78%에 해당하는 상위 20 만명만을 타겟팅하는 Top 200,000 전략을 통해 전체 구매 전환의 95.83%(30,510 명)를 포착하는 운영이 가능하다. 이는 전체를 대상으로

무차별 발송하던 기존 관행 대비 99.22%의 발송 물량을 절감하면서도 전환 성과의 대부분을 확보할 수 있음을 실증한다. 결과적으로 제안된 프레임워크는 고정된 단일 기준에 국한되지 않고 가용 예산과 채널 환경에 맞추어 마케팅 실행 범위를 최적화할 수 있는 정량적 의사결정 기준을 제공한다.

4.7 모델의 설명력 및 변수 중요도

검증: SHAP 분석

최적 모형인 XGBoost 를 대상으로 SHAP 분석을 수행한 결과, 모형은 단순 고객 참여도 지표에만 편향되지 않고, 기저 활동성 변수와 본 연구가 제안한 동태적

도메인 지식 변수를 다층적으로 결합하여 구매 전환 확률을 산출함이 확인되었다. 전체 예측 집합에 대한 변수 기여도 및 영향력 방향성은 <그림 2>의 SHAP


Summary Plot 에 제시하였으며, 미구매(0)와 구매(1) 분류 시 변수 중요도의 구조적

변화는 <그림 3>의 SHAP Rank Shift 로 도식화하였다.

Knowledge Category	Positive Contribution	Rank	Negative Contribution	Knowledge Category
베이스라인	캠페인 유형 : 기타 거래	1	메시지 수신 : 미정의/기타	베이스라인
마케팅 피로도 패턴	채널별 특정 주제 캠페인 오픈율(30일 내)	2	가입 기간 (첫 구매 경과)	베이스라인
베이스라인	캠페인 지속 시간(평균)	3	선호 시간대 일치도	시계열적 반응 패턴
베이스라인	이메일 계정 : 기타	4	급여일 근접도	시계열적 반응 패턴
베이스라인	캠페인 채널 : 이메일	5	캠페인 유형 : 전체 유저	베이스라인
베이스라인	발송 채널 : 이메일	6	분기 말 근접도	시계열적 반응 패턴
시계열적 반응 패턴	주차 정보	7	이메일 결과 시간	마케팅 피로도 패턴
베이스라인	메시지 수신 : 데스크탑	8	선호 요일 일치도	시계열적 반응 패턴
마케팅 피로도 패턴	마케팅 피로도	9	성공 경로 일치도	마케팅 채널 효과성 패턴
마케팅 채널 효과성 패턴	주제 경과 시간	10	무시 경과 시간	베이스라인
마케팅 채널 효과성 패턴	주제 신선도	11	이메일 계정 : 지메일	베이스라인
베이스라인	메시지 수신 : 스마트폰	12	총 캠페인 수	베이스라인
		13	캠페인 주제 : 할인 정보	베이스라인
		14	최종 클릭 경과 시간(평균)	베이스라인
		15	캠페인 주제 : 기타	베이스라인
		16	마지막 구매 경과일	구매/재구매 주기 패턴
		17	최근 오픈 경과 시간(평균)	베이스라인
		18	캠페인 채널 : 모바일	베이스라인

<그림 2> 구매 예측 설명을 위한 상위 30 위 변수 중요도 및 영향력 방향성 결과

전역적 변수 기여도 분석 결과, 모형 내 변수들의 예측 기여는 세 가지 세부 메커니즘으로 구분되어 작동함을 확인하였다. 첫째, 기저 활동성 및 서비스 맥락 변수의 통제 역할이다. 최상위권에 위치한 “캠페인 유형: 기타 거래”(Rank 1)와 “채널별 특정 주제 캠페인 오픈율(30일 내)”(Rank 2)은 높은 변수값이 양의 SHAP 값과 뚜렷한 양의 상관관계(Corr: +0.67, +0.50)를 형성하였다. 이는 최근 반응 이력이 활발한 고객의 기저 관여도를 대변하는 통제 신호로서 기능한다.




둘째, 시계열적 반응 패턴 변수군의 광범위한 상위권 포진이다. 누적 중요도 75%~90% 구간에 걸쳐 “선호 시간대 일치도”(Rank 9), “급여일 근접도”(Rank 10), “분기 말 근접도”(Rank 12), “주차 정보”(Rank 14), “선호 요일 일치도”(Rank 15) 등 제안된 시점 맥락 변수들이 집중 배치되었다. 이는 기저 활동성이 통제된 상태에서, 실제 구매 행동이 집중적으로 발현되는 최적의 마케팅 타이밍을 판별하는 유의미한 예측 신호로 작동함을 시사한다. 셋째, 마케팅 피로도 패턴 및

감쇠 패턴 변수의 비선형적 영향력이다. “이메일 경과 시간”(Rank 13, Corr: -0.83)과 “푸시 경과 시간”(Rank 18, Corr: -0.87), “마케팅 피로도”(Rank 20) 등은 메시지 수신 직후 발생할 수 있는 일시적 반응 억제 및 시간 경과에 따른 감쇠 효과를 포착하여 모형의 과잉 예측을 보정하는 필터 역할을 수행하였다.

다음으로 미구매 판별과 실제 구매 예측 간의 SHAP 중요도 순위 변동(<그림 3>)을 분석한 결과, 모형은 미구매 대상을 광범위하게 스크리닝하는 단계와 최종

구매 전환을 확정하는 단계에서 5 개 변수군의 역할을 명확히 분업화하여 가중치를 재배치하고 있음이 확인되었다. 미구매 선별 시에는 환경적 베이스라인 및 피로도 변수가 상위권에서 배제 기제로 작동하는 반면, 구매 전환 예측 시에는 구매/재구매 주기 변수와 직접적 상호작용 최근성 변수의 기여도가 급상승하며, 시계열적 반응 변수군은 두 단계 전반에서 안정적인 시점 조율 기능을 수행하였다.



<그림 3> 미구매 vs 구매 예측 시 SHAP 변수 중요도 순위 변동 시각화

“구매/재구매 주기 패턴” 변수군은 잠재 타겟 중 실제 구매 전환을 최종 확정 짓는 핵심 결정 요인으로 기능하였다. 해당 변수군의 대표 변수인 “마지막 구매 경과일”은 미구매 판별 시 27 위에

머물렀으나, 구매 예측 시에는 7 위로 20 계단 대폭 상승하였다. 이는 소비자의 고유한 구매 주기가 비구매 대상을 넓게 탐색하는 초기 단계에서는 영향력이 제한적이지만, 구매 확률의 임계값을 최종적으로 넘어서는 전환 확정

단계에서는 모형의 분류 확률을 결정짓는 가장 직접적인 가중치로 전환됨을 실증한다.

“마케팅 피로도 패턴” 변수군은 기저 관여도 유지와 함께 비구매 대상을 사전에 배제하는 음성 스크리닝 역할을 주로 수행하였다. 장기적 참여도를 대변하는 “채널별 특정 주제 캠페인 오픈율(30 일 내)”은 미구매 2 위, 구매 4 위로 두 클래스 모두에서 최상위권을 유지하여 고객의 기저 활동성을 일관되게 통제하였다. 반면 누적 노출에 따른 “마케팅 피로도” 변수는 미구매 판별 시 20 위에서 구매 예측 시 29 위로 순위가 하강하였다. 이는 피로도 변수가 전환 고객을 특정하는 양의 신호이기보다는, 피로가 누적되어 반응 가능성이 희박한 비구매 대상을 사전에 감점 및 제외하는 1 차 음성 필터로 작용함을 나타낸다.

“시계열적 반응 패턴” 변수군은 특정 클래스에 편향되지 않고 미구매와 구매 예측 전반에서 안정적인 시점 완충 기제로 작동하였다. “선호 시간대 일치도”(9 위 → 10 위), “급여일 근접도”(10 위 → 13 위), “분기 말 근접도”(12 위 → 11 위), “주차 정보”(14 위 → 15 위), “선호 요일 일치도”(15 위 → 18 위) 등 시계열 축의 주요 변수들은 두 클래스 간 순위 변동 폭이 크지 않고 9~18 위권의 중상위권을 지속적으로 유지하였다. 이는

시계열 맥락 정보가 개별 고객의 구매 성향 자체를 급변시키기보다는, 메시지 발송 타이밍의 적합성을 상시적으로 조율하여 예측 확률의 정밀도를 보장하는 역할을 수행함을 보여준다.

“마케팅 채널 효과성 패턴 및 베이스라인” 고관여 변수는 점점 적합도 보조와 직접적 상호작용 신호 포착을 분담하였다. 채널 효과성 축의 “성공 경로 일치도”는 17 위에서 16 위로 중위권을 유지하며 과거 유효 채널 경로에 대한 부합도를 안정적으로 평가하였다. 아울러 “캠페인 유형: 기타 거래”(1 위 유지) 등 정적 인프라 변수가 양 클래스 공통의 구조적 환경을 정의하는 가운데, 베이스라인 행동 지표 중 “최종 클릭 경과 시간(평균)”은 미구매 판별 시 25 위에서 구매 예측 시 9 위로 16 계단 상승하였다. 이는 단순 노출을 넘어 링크 클릭과 같은 고관여 행동의 최근성이 주기 패턴과 유기적으로 결합하여 최종 전환 판단을 강화하는 유의미한 보조 지표로 활용됨을 확인해 준다.

이러한 순위 이동 양상은 제안 모형이 불균형 CRM 환경 하에서 체계적인 다단계 의사결정 프로세스를 학습하였음을 실증한다. 즉, 발송 환경 및 피로도 변수를 통해 비반응 고객을 사전에 스크리닝하는 1 단계, 시계열적 반응 변수를 통해 최적

수신 시점을 지속적으로 보정하는 2 단계, 재구매 주기 및 고관여 상호작용 최근성을 바탕으로 실제 구매 전환 대상자를 최종 확정하는 3 단계의 계층적 분류 메커니즘이 모형 내부에 내재화되었음을 시사한다.

5. 토의 및 한계

5.1 학술적 및 이론적 시사점

본 연구의 실증 분석 결과는 크게 세 가지 거시적 발견으로 요약된다. 첫째, 구매 전환율이 0.1234%에 불과한 극단적 희소 환경에서 도메인 지식 기반의 동태적 상태 변수 주입은 알고리즘 아키텍처 전반의 예측 성능을 보편적으로 개선하였다. 둘째, 변수 절삭 및 SHAP 분석 결과 소비자의 즉각적인 마케팅 피로도와 시계열적 수신 맥락이 전환 고객 포착력을 주도하는 1 차 신호로 작용하고, 전통적 구매 주기는 최종 전환 여부를 확정하는 보완적 가중치로 기능함을 확인하였다. 셋째, 정형 데이터 환경에서는 무조건적인 심층 신경망 고도화보다 도메인 이론에 기반한 데이터 중심의 귀납적 편향 주입이 모형의 분류 효율성과 실무적 설명력을 동시에 제고하는 유효한 전략임을 실증하였다.

이러한 발견은 전통적 CRM 및 소비자 행동 이론에 중요한 학술적 확장을 제공한다. 기존의 RFM 모형이나 BTYD

계열의 확률 모형들은 장기간 집계된 과거 거래 이력을 중심으로 고객의 기저 성향을 정적으로 프로파일링하는 데 집중해 왔다. 이로 인해 다채널 디지털 마케팅 환경에서 메시지 수신 직후 실시간으로 변동하는 소비자의 인지적 상태와 상황적 맥락을 모형 내에 내생화하는 데 구조적 한계를 지녔다. 본 연구는 소비자 습관화 이론과 정보 처리 이론을 실시간 로그 기반의 지수 감쇠 피로도 모델로 조작화함으로써, 고객의 인지적 자원 고갈과 회복 메커니즘을 예측 모형 내에 성공적으로 구현하였다. 특히 메시지 수신 후 일정 기간의 휴식 간격이 주어졌을 때 전환 확률이 비선형적으로 회복되는 현상은, 마케팅 자극의 효과가 단순 노출 빈도의 총량이 아니라 인지적 피로도의 완충 주기에 의해 규정된다는 이론적 가설을 실증적으로 뒷받침한다.

나아가 상황 의존적 선호 및 캘린더 효과 문헌과 관련하여, 소비자의 내재된 구매 욕구는 정적으로 머무르지 않고 급여일이나 분기 말과 같은 경제적 맥락, 개인의 활동 시간대와 같은 시간적 신호와 결합할 때 비로소 행동으로 발현된다는 점을 규명하였다. 이는 과거 구매 이력(Who) 중심의 전통적 마케팅 프레임워크를 수신 시점 역동성(When)과 피로도 조율(How often) 중심의 동태적

행동 모델로 진화시키는 이론적 근거를 제공한다.

5.2 방법론적 함의

본 연구의 실증 결과는 정형 데이터 영역에서 모형 구조의 복잡성 추구보다 데이터 표현력의 보강이 선행되어야 한다는 데이터 중심 인공지능(Data-Centric AI)의 핵심 명제를 지지한다. 극도로 불균형한 CRM 로그 환경에서 트리 기반 앙상블 모형이 복잡한 심층 신경망 및 정형 특화 딥러닝 대비 일관된 성능 우위를 나타낸 원인은 귀납적 편향의 구조적 적합성에서 기인한다. 정형 데이터 특유의 불연속적이고 계단식인 결정 경계를 학습하는 데 있어, 연속적 미분 가능 함수에 기반한 신경망 근사보다 트리의 축 정렬 분할 방식이 본질적으로 우수한 학습 효율성을 제공함을 재확인하였다.

특히 본 연구가 제안한 마케팅 이론 기반의 파생변수는 복잡한 비선형적 시계열 상호작용을 정형화된 수학적 신호로 사전 변환하여 모형에 주입함으로써, 트리 모형의 분할 효율을 극대화하였다. 이는 신경망 아키텍처의 파라미터 증대에 리소스를 집중하기보다, 도메인 지식을 활용하여 특성 공간의 정보 이득을 구조화하는 방식이 예측 정확도와

연산 효율성 측면에서 우수한 한계 효용을 지님을 시사한다. 아울러 TreeSHAP 과의 결합을 통해 도메인 변수군이 수행하는 계층적 3 단계 의사결정 구조(음성 스크리닝, 시점 맥락 조율, 최종 구매 확정)를 정량적으로 규명함으로써, 블랙박스 모형의 한계를 극복하고 모델 출력값의 신뢰성을 입증하는 설명 가능한 인공지능(XAI) 방법론의 실효성을 확인하였다.

5.3 실무적 함의

본 연구는 일선 마케팅 실무자 및 이커머스 플랫폼 운영진에게 단순한 점수 합산식 타겟팅 관행을 탈피하고, 다차원 동태적 상태를 반영한 지능형 마케팅 오케스트레이션 도구로의 패러다임 전환을 제안한다.

실무 현장에서 관행적으로 이루어지던 대규모 무차별 일괄 발송 방식은 단기적 매출 증대 효과에 비해 고객 피로도 누적, 수신 거부, 채널 발송 비용 낭비라는 구조적 비효율을 초래해 왔다. 본 연구의 결과는 마케터가 가용 예산과 채널별 발송 단가에 맞추어 운영 임계값을 동적으로 조율할 수 있는 정량적 실행 기준을 제시한다. 건당 비용이 높은 SMS 채널의 경우 상위 10,000 명 수준의 극소수 정밀 타겟팅을 적용하여 53.20%에 달하는

고적중률(무작위 대비 Lift 약 431 배)을 확보함으로써 예산 누수를 통제할 수 있다. 반면 한계 비용이 극히 낮은 앱 푸시나 이메일 채널의 경우, 상위 20 만명(전체의 0.78%)을 선별하는 확장 타겟팅을 통해 전체 전환 고객의 95.83%를 포착하는 동시에 기존 대비 99.22%의 발송 물량을 절감할 수 있다.

이러한 접근법은 마케터에게 직관적인 3 단계 실행 가이드라인을 제공한다. 1 단계로 마케팅 피로도 변수를 활용하여 최근 과도한 자극에 노출된 비반응 고객을 사전에 필터링하고, 2 단계로 시계열적 반응 지표를 통해 고객별 최적 수신 타이밍(요일, 시간대, 급여 주기)에 맞추어 발송 시점을 조율하며, 3 단계로 재구매 주기 도래 여부와 선호 콘텐츠의 신선도를 결합하여 최종 메시지를 전달하는 체계적 운영 거버넌스를 수립할 수 있다.

5.4 연구의 한계점 및 향후 과제

본 연구는 다양한 학술적, 실무적 시사점에도 불구하고 다음과 같은 한계점을 지니며, 이는 향후 연구를 통해 보완될 필요가 있다.

첫째, 관측 데이터 기반의 분석으로 인한 순수 인과추론의 제약이다. 본 연구는 실제 이커머스 로그 데이터를 활용하여 도메인 지식 변수와 구매 전환 간의 통계적

연관성 및 예측 기여도를 규명하였으나, 이는 반사실적 처치 효과를 완벽히 통제한 순수 인과관계를 의미하지는 않는다. SHAP 분석에서 나타난 변수 중요도 역시 모형의 예측 확률 형성에 대한 수학적 기여분일 뿐 직접적인 인과 메커니즘으로 단정하기 어렵다. 향후 연구에서는 무작위 배정 기반의 현장 A/B 테스트나 성향점수 매칭, 이중차분법 등의 준실험 설계를 결합하여 도메인 변수의 순수 처치 효과를 인과적으로 검증할 필요가 있다.

둘째, 단일 플랫폼 데이터셋에 기반한 분석에 따른 일반화의 한계이다. 본 연구는 약 1 억 7,200 만 건의 방대한 다채널 로그를 분석하여 데이터의 신뢰성을 확보하였으나, 특정 종합 이커머스 플랫폼의 기록에 국한되어 있다. 정기 구독형 서비스나 고관여 내구재 플랫폼 등 비즈니스 모델 및 상품 관여도 차이에 따라 채널별 피로도 반감기나 재구매 주기의 영향력이 다르게 나타날 가능성이 존재한다. 향후 연구에서는 다양한 산업군 및 다국적 이커머스 데이터를 활용한 교차 검증이 요구된다.

셋째, 고정된 탐색적 파라미터 설정의 문제이다. 본 연구의 민감도 분석을 통해 피로도 반감기 파라미터(τ)가 $\pm 50\%$ 변동하더라도 모형 성능이 안정적으로 유지됨을 확인하였으나, 초기 기준

반감기는 실무적 가이드라인에 기반한 탐색적 설정치에 해당한다. 고객 개개인의 인지적 수용 한계와 채널별 피로도 누적 속도는 개인의 성향에 따라 이질적일 수 있다. 따라서 향후 연구에서는 고정된 채널별 반감기 설정을 넘어, 개별 사용자의 누적 반응 로그로부터 개인화된 최적 반감기를 동적으로 학습하는 적응형 파라미터 추정 알고리즘으로의 확장이 이루어져야 할 것이다.

마지막으로, 모델 효율성의 정량적 측정 문제이다. 본 연구는 딥러닝 대비 트리 기반 경량 모델이 연산 리소스 측면에서 효율적임을 논하였으나, 실제 CPU와 GPU 간의 구체적인 연산 시간 비교나 에너지 소비량 및 탄소 배출량에 대한 정량적 측정치는 제시하지 못했다. 경량화 알고리즘의 실무적 효율성을 명확히 하기 위해서는 실제 운영 환경에서의 하드웨어 자원 점유율에 대한 정량적 비교 분석이 수반되어야 할 것이다.

6. 결론

본 연구는 데이터의 질적 표현력이 모델의 구조적 복잡성을 능가할 수 있는가라는 데이터 중심 인공지능의 핵심 질문에서 출발하여, 극단적 불균형을 지닌 전자상거래 고객관계관리 환경에서 도메인 지식 기반의 동태적 예측 프레임워크를

제안하고 실증하였다. 2 개년에 걸친 1 억 7,200 만 건의 다채널 메시징 로그와 구매 전환율 0.1234%인 원분포 홀드아웃 테스트 세트를 기반으로 총 9 종의 머신러닝, 심층 신경망, 정형 특화 딥러닝 알고리즘을 비교 검증하였다. 실증 분석 결과, 마케팅 이론을 4 대 동태적 파생변수군으로 조작화하여 귀납적 편향으로 주입한 접근법은 비교 대상 알고리즘 전반의 PR-AUC 및 F1-score 를 일관되게 향상시켰다. 특히 복잡한 심층 신경망 계열 대비 경량화된 트리 기반 앙상블 모형인 XGBoost 가 정형 데이터의 불연속적 경계면 학습에서 가장 우수한 종합 분류 성능을 달성함을 확인하였다. 이는 데이터의 희소성과 고객 행동의 이질성이 지배적인 비즈니스 분석 환경에서 맹목적인 심층 아키텍처 확장보다 도메인 이론에 기반한 데이터 표현력의 구조적 보강이 예측 성능의 상한을 결정짓는 핵심 요인임을 시사한다.

본 연구의 실증 결과와 해석이 제공하는 핵심 학술적 발견은 세 가지로 종합된다. 첫째, 데이터 중심 인공지능 방법론의 실효성을 입증하였다. 추상적 마케팅 이론을 지수 감쇠 피로도, 캘린더 근접도, 재구매 위험률 함수 등의 동태적 수학 신호로 변환하여 모델에 주입함으로써, 사전 지식이 없는 딥러닝의 순수 표현

학습이 포착하기 어려운 유의미한 정보 이득을 구조적으로 제공하였다. 이는 초거대 모델 중심의 인공지능 환경에서도 연구자 및 실무자의 도메인 이해도가 예측 모형의 성능을 극대화하는 본질적 자산임을 재확인해 준다. 둘째, 정적 프로파일링에서 실시간 동태적 상태 제어로의 마케팅 패러다임 전환이다. 변수 절삭 및 SHAP 순위 변동 분석을 통해, 고객의 단기 구매 전환을 좌우하는 1 차 예측 신호는 과거의 정적 인구통계학적 속성이나 단순 장기 누적 이력이 아니라 최근의 누적 피로도와 시계열적 수신 맥락임을 규명하였다. 모델은 피로도를 통한 비반응 고객 선제 배제, 시계열 맥락을 통한 수신 적기 조율, 재구매 주기를 통한 최종 전환 확정이라는 다단계 계층적 의사결정 구조를 스스로 학습하였다. 셋째, 지속 가능한 고효율 적정 기술의 가치를 제시하였다. 고비용 GPU 연산 인프라를 요구하는 심층 신경망 대비, 도메인 변수를 장착한 경량 트리 모델은 우수한 성능과 빠른 추론 속도를 동시에 제공하여 실제 산업 현장에서의 운영 비용을 최소화할 수 있는 현실적 대안이 됨을 입증하였다.

본 연구는 마케팅 도메인 이론과 최신 데이터 과학 방법론의 융합을 통해, 예측 성능과 설명 가능성, 그리고 실무적 비용

효율성을 동시에 달성할 수 있는 이론 기반 비즈니스 애널리틱스의 실행 가능성을 실증하였다. 실무 마케팅 현장에서 본 프레임워크는 고정된 일괄 발송 관행을 탈피하고, 채널 단가와 가용 예산에 따라 최적의 운영 임계값을 유연하게 설정할 수 있는 정량적 의사결정 도구로 기능한다. 상위 타겟팅 규모 분석에서 확인되었듯이, 건당 비용이 높은 채널에서는 상위 0.04% 수준의 정밀 타겟팅으로 무작위 대비 약 431 배의 적중률 향상을 도모하고, 한계 비용이 낮은 채널에서는 상위 0.78% 선별만으로 전체 구매 전환의 95.83%를 포착하며 발송 물량을 99.22% 절감하는 최적화 거버넌스를 구축할 수 있다.

궁극적으로 인공지능과 비즈니스 의사결정의 융합은 모형의 규모를 무한히 키우는 것이 아니라, 인간의 축적된 도메인 지식과 기계의 패턴 학습 역량을 유기적으로 결합하여 가장 효율적인 문제 해결 경로를 도출하는 데서 완성된다. 본 연구가 제시한 데이터 중심의 귀납적 편향 주입 프레임워크가 향후 다양한 비즈니스 도메인과 정책 의사결정 영역으로 확장되어, 학술적 엄밀성과 산업적 실용성을 모두 갖춘 지속 가능한 인공지능 연구의 유의미한 이정표로 활용되기를 기대한다.

참고문헌

- Akter, J., Roy, A., Rahman, S., Mohona, S., & Ara, J. (2025). "Artificial intelligence-driven customer lifetime value (CLV) forecasting: Integrating RFM analysis with machine learning for strategic customer retention". *Journal of Computer Science and Technology Studies*, 7(1), 249-257.
- Althoff, T., Horvitz, E., White, R. W., & Zeitzer, J. (2017). "Harnessing the web for population-scale physiological sensing: A case study of sleep and performance". Proceedings of the 26th international conference on World Wide Web, Perth, Australia.
- Anderl, E., Becker, I., Von Wangenheim, F., & Schumann, J. H. (2016). "Mapping the customer journey: Lessons learned from graph-based online attribution modeling". *International journal of research in marketing*, 33(3), 457-474.
- Arik, S. Ö., & Pfister, T. (2021). "Tabnet: Attentive interpretable tabular learning". Proceedings of the AAAI conference on artificial intelligence,
- Attari, V., & Arroyave, R. (2025). "Decoding non-linearity and complexity: Deep tabular learning approaches for materials science". *Digital Discovery*, 4(10), 2765-2780.
- Beyazit, E., Kozaczuk, J., Li, B., Wallace, V., & Fadlallah, B. (2023). "An inductive bias for tabular deep learning". *Advances in neural information processing systems*, 36, 43108-43135.
- Chae, I., Bruno, H. A., & Feinberg, F. M. (2019). "Wearout or weariness? Measuring potential negative consequences of online ad volume and placement on website visits". *Journal of marketing research*, 56(1), 57-75.
- Du, M., Hammerschmidt, C. A., Varisteas, G., State, R., Brorsson, M., & Zhang, Z. (2019). "time series modelling of market price in real-time bidding". ESANN,
- Fader, P. S., Hardie, B. G., & Lee, K. L. (2005). "RFM and CLV: Using iso-value curves for customer base analysis". *Journal of marketing research*, 42(4), 415-430.
- Farjon, G., & Bar-Hillel, A. (2022). "Sparse Hierarchical Table Ensemble—A Deep Learning Alternative for Tabular Data". *IEEE access*, 10, 75376-75384.
- Gorishniy, Y., Kotelnikov, A., & Babenko, A. (2024). "Tabm: Advancing tabular deep learning with parameter-efficient ensembling". *arXiv preprint arXiv:2410.24210*.
- Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). "Why do tree-based models still outperform deep learning on typical tabular data?". *Advances in neural information processing systems*, 35, 507-520.
- Harris, P., Pol, H., & Van Der Veen, G. (2020). Customer journey: From practice to theory. In *The Routledge companion to strategic marketing* (pp. 67-90). Routledge.
- Huang, X., Khetan, A., Cvitkovic, M., & Karnin, Z. (2020). "Tabtransformer: Tabular data modeling using contextual embeddings". *arXiv preprint arXiv:2012.06678*.
- Jia, R., Li, R., Yu, M., & Wang, S. (2017). "E-commerce purchase prediction approach by user behavior data". 2017 international conference on computer, information and telecommunication systems (CITS), Dalian, Liaoning, China.

- Karpatne, A., Atluri, G., Faghmous, J. H., Steinbach, M., Banerjee, A., Ganguly, A., Shekhar, S., Samatova, N., & Kumar, V. (2017). "Theory-guided data science: A new paradigm for scientific discovery from data". *IEEE Transactions on knowledge and data engineering*, 29(10), 2318-2331.
- Koren, Y. (2009). "Collaborative filtering with temporal dynamics". Proceedings of the 15th ACM SIGKDD international conference on Knowledge discovery and data mining, Paris, France.
- Lambrecht, A., & Tucker, C. (2013). "When does retargeting work? Information specificity in online advertising". *Journal of marketing research*, 50(5), 561-576.
- Lemon, K. N., & Verhoef, P. C. (2016). "Understanding customer experience throughout the customer journey". *Journal of marketing*, 80(6), 69-96.
- Lindskog, W., & Prehofer, C. (2023). "A federated learning benchmark on tabular data: Comparing tree-based models and neural networks". 2023 Eighth International Conference on Fog and Mobile Edge Computing (FMEC), Tartu, Estonia.
- Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., & Lee, S. I. (2020). "From Local Explanations to Global Understanding with Explainable AI for Trees". *Nat Mach Intell*, 2(1), 56-67. <https://doi.org/10.1038/s42256-019-0138-9>
- Lundberg, S. M., & Lee, S.-I. (2017). "A unified approach to interpreting model predictions". *Advances in neural information processing systems*, 30.
- Olafsson, A., & Pagel, M. (2018). "The liquid hand-to-mouth: Evidence from personal finance management software". *The Review of Financial Studies*, 31(11), 4398-4446.
- Schmittlein, D. C., Morrison, D. G., & Colombo, R. (1987). "Counting your customers: Who-are they and what will they do next?". *Management Science*, 33(1), 1-24.
- Shannon, C. E. (1948). "A mathematical theory of communication". *The Bell system technical journal*, 27(3), 379-423.
- Shin, J., Kim, W., Lee, J., Park, J., & Ock, C. Y. (2022). "Controlling Weight Update Probability of Sparse Features in Machine Learning". 2022 14th International Conference on Knowledge and Systems Engineering (KSE), Nha Trang, Vietnam.
- Sun, C., Shrivastava, A., Singh, S., & Gupta, A. (2017). "Revisiting unreasonable effectiveness of data in deep learning era". Proceedings of the IEEE international conference on computer vision, Venice, Italy.
- Thabtah, F., Hammoud, S., Kamalov, F., & Gonsalves, A. (2020). "Data imbalance in classification: Experimental evaluation". *Information Sciences*, 513, 429-441.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). "Attention is all you need". *Advances in neural information processing systems*, 30.

- Verbeke, W., Dejaeger, K., Martens, D., Hur, J., & Baesens, B. (2012). "New insights into churn prediction in the telecommunication sector: A profit driven data mining approach". *European journal of operational research*, 218(1), 211-229.
- Wathieu, L. (2004). "Consumer habituation". *Management Science*, 50(5), 587-596.
- Zha, D., Bhat, Z. P., Lai, K.-H., Yang, F., Jiang, Z., Zhong, S., & Hu, X. (2025). "Data-centric artificial intelligence: A survey". *ACM Computing Surveys*, 57(5), 1-42.
- Ziegler, C.-N., McNee, S. M., Konstan, J. A., & Lausen, G. (2005). "Improving recommendation lists through topic diversification". Proceedings of the 14th international conference on World Wide Web, Chiba, Japan.

Appendix

<부록 1> 구매 전환 여부에 따른 베이스라인 및 도메인 지식 파생변수 간 차이 검정

Group	Feature	Val.	Non-purchased	Purchased	Statistics
베이스라인	캠페인 지속 시간(평균)	-	5.44 ± 50.45	20.48 ± 7.92	$T=-184.08, p<0.001$
	메시지 수신: 미정의/기타	0.00	53,118,072 (3.87%)	292,400 (17.22%)	$\chi^2=4709.65, p<0.001$
		1.00	1,321,091,580 (96.13%)	1,405,584 (82.78%)	
	발송 채널: 모바일 푸시	0.00	880,319,908 (64.06%)	1,642,600 (96.74%)	$\chi^2=4574.03, p<0.001$
		1.00	493,889,744 (35.94%)	55,384 (3.26%)	
	발송 채널: 이메일	0.00	494,353,628 (35.97%)	55,384 (3.26%)	$\chi^2=4581.60, p<0.001$
		1.00	879,856,024 (64.03%)	1,642,600 (96.74%)	
	캠페인 주제: 할인 정보	0.00	120,971,900 (8.80%)	1,405,412 (82.77%)	$\chi^2=66561.25, p<0.001$
		1.00	1,253,237,752 (91.20%)	292,572 (17.23%)	
	캠페인 주제: 기타	0.00	1,256,409,776 (91.43%)	298,248 (17.56%)	$\chi^2=67972.34, p<0.001$
		1.00	117,799,876 (8.57%)	1,399,736 (82.44%)	
	메시지 수신: 스마트폰	0.00	1,364,012,116 (99.26%)	1,557,976 (91.75%)	$\chi^2=7434.54, p<0.001$
		1.00	10,197,536 (0.74%)	140,008 (8.25%)	
	메시지 클릭 여부	0.00	1,364,585,220 (99.30%)	1,417,624 (83.49%)	$\chi^2=34465.90, p<0.001$
		1.00	9,624,432 (0.70%)	280,360 (16.51%)	
	메시지 오픈 여부	0.00	1,246,391,464 (90.70%)	1,252,676 (73.77%)	$\chi^2=3339.06, p<0.001$
		1.00	127,818,188 (9.30%)	445,308 (26.23%)	
	캠페인 채널: 모바일	0.00	889,842,516 (64.75%)	1,642,600 (96.74%)	$\chi^2=4420.48, p<0.001$
		1.00	484,367,136 (35.25%)	55,384 (3.26%)	
	캠페인 채널: 이메일	0.00	553,559,124 (40.28%)	73,788 (4.35%)	$\chi^2=5293.64, p<0.001$
		1.00	820,650,528 (59.72%)	1,624,196 (95.65%)	
	캠페인 유형: 기타 거래	0.00	1,347,222,680 (98.04%)	316,652 (18.65%)	$\chi^2=307695.49, p<0.001$
		1.00	26,986,972 (1.96%)	1,381,332 (81.35%)	
	캠페인 유형: 전체 유저	0.00	96,166,060 (7.00%)	1,399,736 (82.44%)	$\chi^2=85156.18, p<0.001$
		1.00	1,278,043,592 (93.00%)	298,248 (17.56%)	
	최종 클릭 경과 시간(평균)	-	4185.34 ± 395.93	3521.90 ± 1632.00	$T=40.39, p<0.001$
	채널 메시지 유형: 거래성 발송	0.00	1,346,481,016 (97.98%)	316,652 (18.65%)	$\chi^2=299613.34, p<0.001$
		1.00	27,728,636 (2.02%)	1,381,332 (81.35%)	
	채널 메시지 유형: 전체 유저 발송	0.00	96,907,724 (7.05%)	1,399,736 (82.44%)	$\chi^2=84441.83, p<0.001$
		1.00	1,277,301,928 (92.95%)	298,248 (17.56%)	
	푸시 경과 시간	-	589.88 ± 1506.69	244.54 ± 897.33	$T=38.17, p<0.001$
	메시지 수신: 패블릿	0.00	1,373,425,676 (99.94%)	1,682,160 (99.07%)	$\chi^2=1284.03, p<0.001$
		1.00	783,976 (0.06%)	15,824 (0.93%)	
	이메일 계정: Mail.ru	0.00	933,516,240 (67.93%)	896,980 (52.83%)	$\chi^2=1031.65, p<0.001$
		1.00	440,693,412 (32.07%)	801,004 (47.17%)	
	총 구매 횟수	-	0.00 ± 0.11	0.40 ± 1.38	$T=-28.41, p<0.001$
	메시지 수신: 데스크탑	0.00	1,332,408,664 (96.96%)	1,566,748 (92.27%)	$\chi^2=731.51, p<0.001$
		1.00	41,800,988 (3.04%)	131,236 (7.73%)	
	최종 오픈 경과 시간(평균)	-	2404.79 ± 981.90	2049.81 ± 1389.38	$T=25.38, p<0.001$
	이메일 계정: 기타	0.00	637,672,628 (46.40%)	983,152 (57.90%)	$\chi^2=523.66, p<0.001$
		1.00	736,537,024 (53.60%)	714,832 (42.10%)	
	총 메시지 수신 수	-	0.96 ± 1.55	1.55 ± 2.73	$T=-21.54, p<0.001$
	총 캠페인 수	-	0.93 ± 1.40	1.26 ± 1.79	$T=-18.62, p<0.001$
	메시지 수신: 태블릿	0.00	1,373,874,080 (99.98%)	1,692,652 (99.69%)	$\chi^2=322.25, p<0.001$
		1.00	335,572 (0.02%)	5,332 (0.31%)	
	캠페인 채널: 멀티채널	0.00	1,305,030,564 (94.97%)	1,679,580 (98.92%)	$\chi^2=321.30, p<0.001$
		1.00	69,179,088 (5.03%)	18,404 (1.08%)	
	채널 메시지 유형: 특정 유저행동 발송	0.00	1,305,030,564 (94.97%)	1,679,580 (98.92%)	$\chi^2=321.30, p<0.001$
		1.00	69,179,088 (5.03%)	18,404 (1.08%)	
	캠페인 유형: 특정 유저행동	0.00	1,305,030,564 (94.97%)	1,679,580 (98.92%)	$\chi^2=321.30, p<0.001$
		1.00	69,179,088 (5.03%)	18,404 (1.08%)	
	가입 기간(첫 구매 경과)	-	417.24 ± 1484.70	724.89 ± 2236.08	$T=-13.67, p<0.001$
	불만 접수 경과 시간(평균)	-	0.13 ± 31.41	0.00 ± 0.00	$T=12.03, p<0.001$
	이메일 계정: 지메일	0.00	1,177,230,436 (85.67%)	1,515,836 (89.27%)	$\chi^2=104.18, p<0.001$
		1.00	196,979,216 (14.33%)	182,148 (10.73%)	
		0.00	1,374,098,540 (99.99%)	1,697,124 (99.95%)	

구매/재구매 주기 패턴	캠페인 주제: 리뷰 요청	1.00	111,112 (0.01%)	860 (0.05%)	$\chi^2=17.03, p<0.001$
	캠페인 주제: 연관 상품 추천	0.00	1,373,085,116 (99.92%)	1,694,716 (99.81%)	$\chi^2=13.41, p<0.001$
		1.00	1,124,536 (0.08%)	3,268 (0.19%)	
	구독 취소 경과 시간(평균)	-	7232.53 ± 99.83	7226.40 ± 214.20	$T=2.84, p=0.00$
	메시지 구독 취소 여부	0.00	1,373,628,808 (99.96%)	1,696,608 (99.92%)	$\chi^2=2.65, p=0.10$
		1.00	580,844 (0.04%)	1,376 (0.08%)	
	발송 채널: 웹 푸시	0.00	1,373,758,668 (99.97%)	1,697,984 (100.00%)	$\chi^2=2.32, p=0.13$
		1.00	450,984 (0.03%)	0 (0.00%)	
	캠페인 주제: 이벤트	0.00	1,373,798,056 (99.97%)	1,697,984 (100.00%)	$\chi^2=2.04, p=0.15$
		1.00	411,596 (0.03%)	0 (0.00%)	
	캠페인 주제: 생일 축하	0.00	1,372,684,872 (99.89%)	1,696,436 (99.91%)	$\chi^2=0.19, p=0.66$
		1.00	1,524,780 (0.11%)	1,548 (0.09%)	
	캠페인 채널: SMS	0.00	1,374,196,752 (100.00%)	1,697,984 (100.00%)	$\chi^2=0.00, p=1.00$
		1.00	12,900 (0.00%)	0 (0.00%)	
	마지막 구매 경과일	-	364.52 ± 11.22	305.98 ± 129.04	$T=45.08, p<0.001$
	구매 후 불응기	-	0.00 ± 0.01	0.09 ± 0.26	$T=-35.22, p<0.001$
	재구매 준비도	-	0.00 ± 0.01	0.00 ± 0.05	$T=-4.56, p<0.001$
시계열적 반응 패턴	주말 여부	0.00	1,295,207,472 (94.25%)	1,333,688 (78.55%)	$\chi^2=4471.55, p<0.001$
		1.00	79,002,180 (5.75%)	364,296 (21.45%)	
	선호 요일 일치도	-0.97	54,762,736 (3.99%)	185,072 (10.90%)	$\chi^2=6423.87, p<0.001$
		-0.78	24,239,444 (1.76%)	179,224 (10.56%)	
		-0.43	398,359,568 (28.99%)	294,980 (17.37%)	
		0.00	195,071,220 (14.20%)	210,872 (12.42%)	
		0.43	121,870,772 (8.87%)	241,488 (14.22%)	
		0.78	212,535,584 (15.47%)	234,092 (13.79%)	
		0.97	367,370,328 (26.73%)	352,256 (20.75%)	
		1.00	93,052,172 (6.77%)	96,148 (5.66%)	
	급여일 근접도	0.05	57,449,032 (4.18%)	60,716 (3.58%)	$\chi^2=471.37, p<0.001$
		0.07	36,944,912 (2.69%)	54,524 (3.21%)	
		0.10	137,530,856 (10.01%)	141,384 (8.33%)	
		0.14	164,658,008 (11.98%)	166,840 (9.83%)	
		0.19	167,992,916 (12.22%)	184,040 (10.84%)	
		0.26	172,135,536 (12.53%)	280,704 (16.53%)	
		0.37	213,863,596 (15.56%)	233,232 (13.74%)	
		0.51	158,217,984 (11.51%)	278,124 (16.38%)	
		0.72	172,364,640 (12.54%)	202,272 (11.91%)	
		1.00	93,052,172 (6.77%)	96,148 (5.66%)	
	주차 정보	1.00	311,767,200 (22.69%)	397,836 (23.43%)	$\chi^2=198.54, p<0.001$
		2.00	314,790,100 (22.91%)	457,692 (26.96%)	
		3.00	302,529,080 (22.01%)	306,504 (18.05%)	
		4.00	327,408,708 (23.83%)	362,920 (21.37%)	
		5.00	117,714,564 (8.57%)	173,032 (10.19%)	
	분기 말 근접도	-	0.08 ± 0.21	0.06 ± 0.19	$T=8.37, p<0.001$
	선호 시간대 일치도	-	0.23 ± 0.67	0.26 ± 0.70	$T=-3.49, p<0.001$
마케팅 피로도 패턴	유저 오픈율(30 일)	-	0.03 ± 0.15	0.17 ± 0.37	$T=-40.32, p<0.001$
	유저 클릭율(30 일)	-	0.00 ± 0.04	0.12 ± 0.31	$T=-38.62, p<0.001$
	유저 오픈 횟수(30 일)	-	0.03 ± 0.18	0.31 ± 0.86	$T=-32.84, p<0.001$
	마케팅 피로도	-	0.01 ± 0.06	0.07 ± 0.22	$T=-30.09, p<0.001$
	이메일 경과 시간	-	1084.59 ± 2071.62	761.29 ± 1605.05	$T=19.99, p<0.001$
	발송 간격 표준편차	-	0.12 ± 4.06	3.27 ± 20.06	$T=-15.58, p<0.001$
	채널별 특정 주제 캠페인 오픈율(30 일)	-	0.19 ± 0.04	0.18 ± 0.04	$T=15.33, p<0.001$
	마지막 접촉 경과 시간	-	178.87 ± 619.24	125.37 ± 458.91	$T=11.57, p<0.001$
마케팅 채널 효과성 패턴	주제 노출 수(7 일)	0.00	411,596 (0.03%)	0 (0.00%)	$\chi^2=68053.13, p<0.001$
		1.00	1,524,780 (0.11%)	1,548 (0.09%)	
		2.00	111,112 (0.01%)	860 (0.05%)	
		3.00	1,124,536 (0.08%)	3,268 (0.19%)	
		4.00	117,799,876 (8.57%)	1,399,736 (82.44%)	
		5.00	1,253,237,752 (91.20%)	292,572 (17.23%)	
	성공 캠페인 유사도	0.00	1,370,206,008 (99.71%)	1,388,556 (81.78%)	$\chi^2=312364.18, p<0.001$
		0.20	2,905,080 (0.21%)	16,856 (0.99%)	
		0.50	115,240 (0.01%)	688 (0.04%)	
		1.00	983,324 (0.07%)	291,884 (17.19%)	
	주제 경과 시간	-	2380.17 ± 1685.01	1842.70 ± 1508.20	$T=35.38, p<0.001$
	주제 신선도	-	0.01 ± 0.06	0.07 ± 0.21	$T=-28.75, p<0.001$
	성공 경로 일치도	-	0.30 ± 0.41	0.23 ± 0.34	$T=18.02, p<0.001$

<부록 2> 모델 별 하이퍼파라미터 탐색범위 및 최적값 요약

파라미터	탐색범위	최적값	파라미터	탐색범위	최적값
Random Forest			XGBoost		
n estimators	100 ~ 200 (step=50)	200	n estimators	100 ~ 600 (step=50)	600
learning rate	0.001 ~ 0.3 (log)	0.0588	learning rate	0.001 ~ 0.3 (log)	0.0367
max depth	8 ~ 16	16	max depth	3 ~ 10	10
min samples split	2 ~ 10	2	min child weight	1 ~ 10	2
min samples leaf	1 ~ 5	8	subsample	0.6 ~ 0.9	0.7297
-	-	-	colsample bytree	0.85 ~ 1.0	0.9967
-	-	-	gamma	0.1 ~ 5.0	3.9601
-	-	-	reg alpha	1e-3 ~ 10 (log)	0.7237
-	-	-	reg lambda	1e-3 ~ 10 (log)	0.0018
MLP			CNN		
n layers	1 ~ 3	3	conv filters	32 ~ 256	128
-	-	-	kernel size	2 ~ 5	3
-	-	-	pool size	2 ~ 3	3
-	-	-	num conv layers	1 ~ 2	1
dense units	64 ~ 128 (step=32)	64	dense units	32 ~ 256	192
dropout rate	0.1 ~ 0.4	0.208	dropout rate	0.1 ~ 0.4	0.24
l2	1e-6 ~ 1e-2	4.87E-03	l2	1e-6 ~ 1e-2	1.62E-05
learning rate	1e-4 ~ 1e-2 (log)	0.0086	learning rate	1e-5 ~ 1e-3	0.0085
batch size	16/32/64/128	128	batch size	32/64/128	128
RNN			LSTM		
num layers	1 ~ 2	2	num lstm layers	1 ~ 2	2
rnn units1	32 ~ 256	224	lstm units 1	32 ~ 256	96
rnn units2	16 ~ 128	128	lstm units 2	32 ~ 256	112
dense units	16 ~ 256	96	dense units	16 ~ 64	48
dropout rate	0.1 ~ 0.4	0.3461	dropout rate	0.1 ~ 0.4	0.453
l2	1e-6 ~ 1e-2	3.20E-03	l2	1e-5 ~ 1e-2	7.43E-04
learning rate	1e-5 ~ 1e-2	1.21E-05	learning rate	1e-5 ~ 1e-3	3.18E-04
batch size	32/64/128	32	batch size	32/64/128	128
CNN-LSTM			RNN-LSTM		
conv filters	16 ~ 128	48	-	-	-
kernel size	2 ~ 5	4	-	-	-
pool size	2 ~ 4	4	lstm units1	32 ~ 256	256
lstm units	32 ~ 256	256	lstm units2	16 ~ 128	64
dense units	16 ~ 64	16	dense units	16 ~ 64	64
dropout rate	0.1 ~ 0.4	0.1156	dropout rate	0.1 ~ 0.4	0.4873
l2	1e-5 ~ 1e-2	3.23E-05	l2	1e-5 ~ 1e-2	7.33E-04
learning rate	1e-5 ~ 1e-3	5.71E-04	learning rate	1e-5 ~ 1e-3	1.77E-04
batch size	32/64/128	128	batch size	32/64/128	32
TabNet					
n d	16 ~ 48 (step=8)	16			
n steps	3 ~ 5	4			
gamma	1.0 ~ 1.5	1.14322			
lambda sparse	1e-4 ~ 1e-3 (log)	0.00023952			
lr	1e-3 ~ 1e-2 (log)	0.00492911			
mask type	sparsemax / entmax	entmax			
batch size	2048 / 4096	2048			
virtual batch size	128 / 256	128			