

최소 CRM 환경에서 도메인 지식 기반 데이터 중심 AI 구매 전환 예측 프레임워크(A Data-Centric AI Framework for Purchase Conversion Prediction via Domain Knowledge- Driven Feature Engineering in Imbalanced CRM Environments)

본 연구는 극단적인 클래스 불균형(전환율 0.1234%)을 지닌 전자상거래 고객관계관리(CRM) 환경에서, 모형의 구조적 복잡성보다 데이터 표현력의 질적 보강을 우선시하는 데이터 중심 인공지능(Data-Centric AI) 기반의 도메인 지식 특성 공학 프레임워크를 제안하고 실증하였다. 전통적 고객 분석의 정적 모델링 한계를 극복하기 위해, 소비자 습관화, 상황 의존적 선호, 고객 생애 가치, 정보 엔트로피 이론을 4 대 동태적 상태 변수군(구매 및 재구매 주기, 시계열적 반응, 마케팅 피로도, 마케팅 채널 효과성)으로 조작화하여 모형에 귀납적 편향으로 주입하였다. 2 개년에 걸친 1억 7,200 만 건의 다채널 메시징 로그와 원분포 홀드아웃 테스트 세트를 바탕으로 총 9 종의 머신러닝, 심층 신경망, 정형 딥러닝 알고리즘을 비교 검증하였다. 실증 분석 결과, 도메인 지식이 통합된 트리 기반 앙상블 모형인 XGBoost 가 정형 및 시계열 특화 딥러닝(TabNet, LSTM 등)을 제치고 가장 우수한 분류 성능(F1-score 0.3806, PR-AUC 0.3620)을 기록하였으며, 베이스라인 대비 재현율(Recall)을 30.74%에서 52.30%로 70.1% 대폭 향상시켰다. 변수 절삭 및 SHAP 기반 설명 가능성 분석에서는 마케팅 피로도와 시계열적 반응 축이 비구매 고객을 배제하고 수신 적기를 조율하는 1 차 신호로 작용하며, 재구매 주기와 고관여 상호작용 최근성이 최종 구매 전환을 결정 짓는 3 단계 계층적 의사결정 구조를 학습함을 규명하였다. 아울러 상위 타겟팅 규모 분석 결과, 상위 0.78% 선별만으로 전체 구매 전환의 95.83%를 포착하고 발송 물량을 99.22% 절감하는 실무적 비용 효율성을 입증하였다. 본 연구는 최소 CRM 정형 데이터 환경에서 맹목적인 심층 아키텍처 확장보다 도메인 지식을 반영한 경량화 모형이 예측 성능, 설명력, 운영 경제성 측면에서 우수한 대안임을 입증하고 동태적 마케팅 오케스트레이션을 위한 정량적 의사결정 기준을 제공한다는 점에서 학술적 및 실무적 의의를 지닌다.

주제어: 데이터 중심 AI, 구매 전환 예측, 도메인 지식 특성 공학, 귀납적 편향, 트리 기반 앙상블, 설명가능한 인공지능, 고객관계관리

This study proposes and empirically validates a Data-Centric AI framework driven by domain-knowledge feature engineering for e-commerce Customer Relationship Management (CRM) under extreme class imbalance (a conversion rate of 0.1234%). To overcome the limitations of static customer profiling, we operationalized classical marketing theories including consumer habituation, context-dependent preferences, customer lifetime value, and information entropy into four dynamic state feature groups: repurchase cycle patterns, temporal response patterns, marketing fatigue patterns, and channel effectiveness patterns. These features were injected as an inductive bias into nine diverse predictive algorithms, spanning traditional machine learning, deep neural networks, and specialized tabular deep learning. Using a large-scale real-world dataset comprising 172 million multichannel messaging logs over two years and a holdout test, empirical results demonstrated that a domain-enhanced lightweight tree ensemble (XGBoost) consistently outperformed deep learning architectures (such as TabNet and LSTM) in tabular data modeling. Specifically, XGBoost achieved the highest overall classification performance (F1-score: 0.3806, PR-AUC: 0.3620), increasing the recall from 30.74% to 52.30% (+70.1%) compared to the baseline. Feature ablation and SHAP analyses revealed a hierarchical three-step decision mechanism: marketing fatigue and temporal dynamics act as primary filters for negative screening and timing moderation, whereas the repurchase cycle and high-engagement click recency finalize conversion decisions. Furthermore, targeting sensitivity analysis demonstrated practical cost-efficiency; targeting only the top 0.78% of users captured 95.83% of total conversions while reducing blast message volume by 99.22%. This study underscores that in sparse tabular CRM environments, incorporating structured domain knowledge into lightweight tree ensembles provides superior predictive accuracy, explainability, and operational efficiency over blind model scaling, offering quantitative guidelines for dynamic marketing orchestration.

Keywords: Data-Centric AI, Purchase Conversion Prediction, Domain-Knowledge Feature Engineering, Inductive Bias, Tree-based Ensemble, Explainable AI, Customer Relationship Management

1. 서론

오늘날의 고객은 이메일을 열어보고, 며칠 뒤 모바일 푸시 알림을 확인하며, SMS를 수신한 뒤에 비로소 결제 버튼을 누른다. 이처럼 산발적으로 흩어진 접점이 누적되어 하나의 복잡한 고객 여정(Customer Journey)이 완성된다[18]. 기업 입장에서 이 파편화된 기록을 연결하여 누가 구매할지 예측하고, 한정된 마케팅 예산을 어디에 투입할지 결정하는 것은 수익성과 직결되는 지속 가능성을 위한 핵심 과제다. 그럼에도 불구하고 많은 기업 실무에서는 여전히 마지막 접점에만 기여도를 부여하거나, 임의 가중치를 부여하는 단순 휴리스틱 모델에 의존하고 있어, 최종 구매에 이르기까지 고객이 거쳐온 선행 접점들의 기여도를 과소평가하고, 구매 의사결정에 수반되는 동태적 정황 신호를 미처 포착하지 못하는 한계를 갖는다.

기업들은 대규모의 로그 데이터가 고객 행동을 완벽하게 설명해 줄 것이라는 데이터의 풍요를 기대하지만, 실제 분석 환경에서는 심각한 정보의 희소성 문제에 직면한다[20]. 일반적인 이커머스 환경에서 구매 전환율은 2~3% 수준에 불과하며, 이는 전체 데이터의 97% 이상이 구매와 직접적 관련이 없는 노이즈(Noise)이거나 단순 탐색 행동임을 의미한다.

이러한 데이터의 희소성은 기계학습 모델[33], 특히 최근 각광받는 딥러닝(Deep Learning) 모델의 학습을 저해하는 주요 요인으로 작용한다. 학계와 산업계에서는 이미지 인식이나 자연어 처리(NLP) 분야에서 트랜스포머(Transformer)와 같은 딥러닝 아키텍처가 거둔 우수한 성과를 바탕으로[36], 시계열 마케팅 데이터에도 Long Short-Term Memory(LSTM)이나 Recurrent Neural Network(RNN)을 적용하려는 시도가 주류를 이루고 있다[11]. 하지만 딥러닝의 높은 성과는 대개 데이터가 풍부하고 품질이 정제된 실험적 환경에서 도출된 결과다[34]. 반면 실제 기업의 고객 관계 관리(CRM) 데이터는 고객의 구매 행동이 드문드문 발생하는 희소성이 높고, 이벤트 간의 시간 간격이 불규칙하며, 온라인과 오프라인 기록이 혼재되어 있다. 이러한 희소한 데이터 환경에서는 수많은 파라미터를 가진 복잡한 딥러닝 구조가 이론만큼의 성능 우위를 발휘하지 못할 가능성이 높다[16, 26]. 데이터의 밀도가 낮은 상황에서 무조건적인 고비용 모델 도입은 연산 비용과 마케팅 운영 비용 측면에서 비효율적일 수 있다는 것이다[14].

또한 2024 년과 2025 년에 발표된 다수의 대규모 벤치마크 연구들은 정형 데이터(Tabular Data) 영역에서 딥러닝의 우월성에 대해 의문을 제기하고 있다. 특히 정형 데이터의 불연속적 속성과 비선형적 경계로 인해, 딥러닝의 매끄러운 함수

근사보다는 트리 모델의 분할 방식이 오히려 더 적합한 귀납적 편향을 제공할 수 있다 [7, 16].

본 연구가 제안하는 “지식 기반 특성 공학”은 단순한 데이터 전처리를 넘어, 데이터 중심 AI 관점에서 모델에 명시적인 “귀납적 편향(Inductive Bias)”을 주입하는 방법론적 과정이다 [39]. 전환율 0.12% 수준의 극도로 희소한 CRM 데이터 환경에서, 순수 데이터 기반 딥러닝 모델을 백지상태에서 원시 로그의 고차원 패턴을 추론해야 하므로 극심한 학습 저해를 겪는다. 특히 정형 데이터 특유의 불연속적 속성과 비선형적 경계는 딥러닝의 매끄러운 연속 함수 근사 방식과 구조적 불일치를 일으킨다 [21].

본 연구는 이러한 한계를 극복하기 위해 검증된 마케팅 이론을 수학적 감쇠 함수 및 확률 밀도 함수 형태의 동적 상태 변수로 조작화한다. 이는 복잡한 시계열 구조를 경량 모델이 즉시 분할할 수 있는 정보 이득 높은 신호로 사전 변환하여 제약 조건으로 부여하는 것이다. 이를 통해 백지상태의 백그라운드 탐색 부담을 줄이고, 경량 트리 모델이 희소한 정형 데이터 환경에서도 높은 예측 정확도와 연산 효율성을 달성할 수 있도록 유도한다.

전통적인 CRM 문헌에서 활용된 Recency, Frequency, Monetary(RFM) 모형이나 확률 기반의 고객 생애 가치(CLV) 이론은 주로

과거의 집계된 데이터를 바탕으로 한 정적 모델링에 의존해 왔다. 따라서 다중 접점 환경에서 실시간으로 급변하는 고객의 동태적 상태, 즉 “마케팅 피로도 패턴”나 “시계열 반응 패턴”을 모형 내에 내생화하는 데에는 이론적, 방법론적 공백이 존재했다[1, 38].

본 연구는 추상적인 마케팅 이론을 예측 모형이 실시간으로 처리할 수 있는 동적 상태 변수로 조작화함으로써, 마케팅 이론을 실증적으로 확장하고자 하며, 구체적인 연구 질문은 다음과 같다.

- **RQ1.** [이론적 지식의 가치] 정적인 인구통계학적 정보나 과거 구매 이력 중심 변수에 마케팅 이론 기반의 “동적 상태 변수(마케팅 피로도, 시계열적 반응 등)”를 결합하는 것이 고객의 구매 의사결정 메커니즘을 설명하고 예측하는 데 어떠한 추가적인 기여를 하는가?
- **RQ2.** [설명 가능성과 메커니즘] 4 가지 마케팅 도메인 지식 축 중 구매 전환의 핵심 예측 신호로 작동하는 요인은 무엇이며, 블랙박스 모델 대비 이는 실무자에게 어떠한 해석 가능한 마케팅 전략의 근거를 제공하는가?
- **RQ3.** [모델 적합성과 자원 효율성] 희소성이 매우 높은 실제 디지털 마케팅 환경에서, 마케팅 이론이 귀납적 편향으로 주입된 경량화 트리

모델은 딥러닝 모델 대비 예측
정확도와 마케팅 자원 배분의
효율성을 어떻게 개선하는가?

본 연구의 기여는 다음과 같다. 첫째, 기존 연구들이 고객 행동 이론을 단순한 서술적 배경이나 사후 해석의 도구로만 활용한 것과 달리, 본 연구는 추상적인 마케팅 이론을 머신러닝 모델이 학습 가능한 구체적인 동태적 파생변수로 조작화하는 체계적인 프레임워크를 제안한다. 둘째, 단순히 누가 구매할 것인지를 맞추는 블랙박스 예측을 넘어, SHAP(SHapley Additive exPlanations) 분석을 통해 개별 변수가 구매 예측 확률에 미치는 상대적 기여도를 정량화하였다. 특히 마케팅 피로도와 구매/재구매 준비도가 구매 예측에 미치는 비선형적 기여도를 시각화함으로써, 실무자가 직관적으로 이해하고 마케팅 액션을 참고할 수 있는 데이터 기반의 단서를 제공한다. 셋째, 최근 학계의 정형 데이터에서의 딥러닝과 머신러닝 경쟁 논쟁에 기여하여, 구매 전환율이 극도로 낮고(0.1234%) 희소성이 높은 실제 CRM 데이터 환경에서는 복잡한 딥러닝의 표현 학습보다 잘 설계된 도메인 특성을 장착한 경량 모델이 예측 성능과 효율성 면에서 우월한 대안이 될 수 있음을 실증적으로 규명한다.

본 논문의 2 장에서는 관련 선행 연구를 고찰하고 본 연구의 지식 기반 변수 설계 근거를 제시한다. 3 장에서는 연구 실험 과정에서 사용된 데이터와 분석 알고리즘, 검증 방향을 상세하게 소개하고, 4 장에서는 각 실험 결과와 해석을 다룬다. 마지막으로 5 장 토의에서 연구의 이론적 및 실무적 시사점과 한계를 논의한 후, 6 장에서 연구 결과를 요약하며 마무리한다.

2. 문헌연구

본 연구는 첫째 고객 생애 가치 및 행동 이론의 진화, 둘째 정형 데이터 환경에서의 딥러닝과 트리 기반 모델 간의 성능 논쟁, 셋째 도메인 지식을 활용한 특성 공학의 이론적 타당성, 넷째 설명 가능한 인공지능의 필요성을 중심으로 선행 연구를 고찰한다.

2.1 고객 생애 가치 및 행동 이론의 진화

고객 가치를 평가하는 고전적 프레임워크는 RFM 모형이다. 선행 연구들은 RFM 지표가 미래 고객 수익성과 유의미한 상관관계를 지님을 실증하였다. 그러나 단순한 집계 방식의 RFM 모형은 고객의 이탈(Churn) 시점을 명시적으로 파악하기 어려운 비계약적 환경에서 고객 행동을 정밀하게 설명하는 데 한계가

존재하였다. 이를 보완하기 위해 Pareto/NBD 모형과 Schmittlein, Morrison [31] 이를 개선한 BG/NBD 모형을 제안되며 Buy Til You Die (BTYD) 프레임워크가 확립되었다 Fader, Hardie [13]. 이들 모형은 고객의 구매 이력을 확률 과정(Stochastic Process)으로 구조화하여 잠재적인 이탈 확률과 잔존 기간을 추정하였다.

최근 연구들은 고객 생애 가치(CLV) 추정의 정밀도를 제고하기 위해 기계학습 기법과의 융합을 시도하고 있다. 고객의 웹 브라우징 세션 로그를 임베딩(Embedding) 기반의 벡터로 변환하여 거래 가치를 예측하는 방법론 등이 제안되며 전통적 확률 모형의 한계를 보완하고 있다[9]. 다만 이러한 접근법은 모형 구조의 복잡성 증대에 주로 집중되어 있어, 마케팅 도메인 지식을 명시적으로 결합하는 시도는 상대적으로 제한적이다. 본 연구는 이러한 선행 연구의 한계를 보완하기 위해 구매/재구매 주기 패턴 관점에서 현재 시점이 고객 고유의 평균 재구매 주기에 도달한 정도를 확률 밀도 함수로 정량화한 “재구매 준비도” 및 “구매 후 불응기” 지표를 조작적으로 정의하여 활용한다.

소비자의 반응은 물리적 시간의 경과와 마케팅 자극의 강도에 따라 비선형적으로 변화한다. 선행 연구는 사용자의 선호가 고정되지 않고 시간에 따라 변동한다는 점을 규명하며 시점 역동성 모델링의

중요성을 제시하였다 Koren [22]. 또한, 추천 시스템 분야에서도 협업 필터링(Collaborative Filtering) 모델에 시간 의존적 편향을 반영함으로써 예측 정확도를 유의미하게 개선한 바 있다.

이커머스 환경에서는 특정 요일이나 급여일 전후로 구매 확률이 변동하는 캘린더 효과가 주요 예측 변수로 다루어지며, 특정 시점에 소비자의 가치분 소득과 지출 성향이 일시적으로 변동함이 실증되었다[29]. 이는 본 연구에서 제안하는 급여일 근접도 및 분기말 근접도 변수의 이론적 타당성을 뒷받침한다. 아울러 인간의 생체 리듬이 인지적 반응에 미치는 영향을 규명한 연구[2]를 마케팅 맥락에 적용하면, 고객의 주 활동 시간대와 일치하는 시점에 메시지를 전달할 때 정보 수용성과 반응 확률이 제고될 수 있음을 시사한다. 본 연구의 시계열적 반응 패턴 축은 이러한 이론적 배경을 바탕으로 현재 발송 시점과 고객의 과거 선호 시점 간 코사인 거리를 산출하는 조작적 정의를 적용하였다.

한편, 정보 처리 이론과 습관화 이론에 따르면, 반복적인 마케팅 자극은 소비자의 주의 집중을 감소시키고 반응 역치를 높인다. 이는 마케팅 피로도로 개념화되며, 과도한 메시지 노출이 클릭률의 감소를 초래하는 역 U 자형 관계를 형성함을 시사한다[8]. 본 연구는 이러한 원리를

적용하여 빈번한 메시지 수신에 고객의 반응성을 저하시키는 예측 신호로 작용할 수 있음에 주목한다.

추천 시스템 연구에서는 피로도 개념을 정보 필터링의 맥락으로 확장하여, 추천 목록 내 항목 간 유사도가 지나치게 높을 경우 사용자 만족도가 저하됨을 한계 효용 체감의 법칙으로 설명하였다 Ziegler, McNee [41]. 해당 연구가 공간적 차원의 유사성에 따른 효용 감소를 다루었다면, 본 연구는 마케팅 피로도 패턴 측을 통해 이를 시간적 차원으로 확장하여 동일 채널을 통한 반복적 자극 노출이 누적되는 피로도 신호를 지수 감쇠 모델로 조작화하였다.

콘텐츠 신규성의 중요성은 정보 이론과 새로움 신호 연구에 기반한다. 정보 엔트로피 개념에 따르면, 예측 가능한 메시지는 정보량이 낮아 수신자에게 전달하는 가치가 제한적이다 Shannon [32]. 마케팅 맥락에서 동일한 주제나 제안의 반복적 노출은 정보의 한계 효용 감소로 이어지며, 이는 주제의 다양화를 통해 완화될 수 있다 Ziegler, McNee [41]. 또한 옴니채널 환경에서 고객 여정은 고도로 비선형적인 양상을 보인다[25]. 그래프 기반 마코프 모델(Markov Graph Model)을 활용하여 광고 채널 간 기여도를 정량화한 연구 Anderl, Becker [4]에서 규명한 경로의존성, 즉 동일 채널이라도 선행 접점의 구성에 따라 반응 기여도가 달라진다는

결과는 본 연구의 마케팅 채널 효과성 패턴 측에서 제안하는 “주제 신선도” 및 “성공 경로 일치도” 변수의 조작적 근거를 제공한다.

2.2 지식 기반 특성 공학을 통한 이론의 귀납적 편향 주입 연구

최근 연구들은 도메인 지식을 모형의 구조적 제약이나 학습 과정의 귀납적 편향으로 명시적으로 주입하려는 시도를 이어가고 있다. RFM 이론을 Pareto/NBD 확률 모형과 연계함으로써, 관찰된 구매 이력 데이터를 잠재적 행동 성향의 충분 통계량으로 변환한 연구가 대표적이다 Fader, Hardie [13]. 또한, 소셜 네트워크 구조와 과거 구매 이력을 결합하여 영향력 점수를 도출하고 Kumar, Rajan [23], 이를 추천 시스템에 반영하여 예측 정확도를 개선한 접근법은 사회적 영향력 이론을 네트워크 지표로 조작화하여 모형에 주입한 사례에 해당한다.

Lambrecht and Tucker 는 리타겟팅 광고의 빈도가 과도할 경우 전환율이 감소하는 역 U 자형 관계를 실증하여 피로도 현상의 실증적 근거를 제시하였다 Lambrecht and Tucker [24]. 다만 해당 연구는 거시적 집계 수준의 분석에 초점을 두고 있어, 개별 고객 수준에서 실시간 피로도를 추적하는

동태적 조작화 메커니즘을 제시하지는 못하였다. 전자상거래 분야에서는 대규모 언어 모델을 활용해 상품 설명 텍스트로부터 마케팅 특성을 추출하고 이를 수요 예측에 활용하는 방법론이 제안되었으나[40], 생성된 특성의 명시적 해석 가능성과 마케팅 이론 간 직접적 매핑 구조를 확보하기 어렵다는 한계가 있다.

따라서,본 연구는 복잡한 심층 신경망 구조에만 의존하기보다, 마케팅 도메인 지식을 4 가지 정형화된 동태적 파생변수로 조작화하여 모형에 귀납적 편향을 주입함으로써 예측 효율성과 설명 가능성을 동시에 확보하는 접근법을 취한다. 세부적인 귀납적 편향 주입 메커니즘과 수식과 매핑은 아래 <표 2>에 제시하였다.

2.3 정형 데이터 분석에서의 알고리즘 논쟁

정형 데이터 영역에서 심층 신경망이 과연 전통적인 트리 기반 앙상블 모델을 능가할 수 있는가에 대한 논의는 주요한 연구 주제 중 하나이다[7, 15, 16]. 이미지(Convolutional Neural Network, CNN) 및 자연어(Transformer) 처리 분야에서 딥러닝이 거둔 성과에 힘입어, 마케팅 분야에서도 고객 행동 로그를 시계열로

간주하고 LSTM, TabNet, TabTransformer 등 정형 및 시계열 특화 딥러닝 아키텍처를 적용하는 연구가 시도되었다[5, 10, 19]. 이러한 연구들은 수작업 특징 추출 없이 원시 데이터로부터 고차원 잠재 표현을 학습하는 End-to-End 학습의 장점을 강조한다[15]. 그러나 정형 데이터 환경에서 딥러닝 모형은 하이퍼파라미터 튜닝과 데이터 정제 수준에 매우 민감하며, 연산 비용 대비 성능 효율성이 트리 기반 모델에 미치지 못하는 경우가 다수 보고되고 있다[6].

Verbeke et al.은 로지스틱 회귀, 의사결정나무, 서포트 벡터 머신 등 다양한 분류 알고리즘을 비교하여 앙상블(Ensemble) 기법이 단일 모델 대비 우수한 성능을 보임을 실증하였다 Verbeke, Dejaeger [37]. 이후 XGBoost, LightGBM 등 그래디언트 부스팅 계열 알고리즘이 정형 데이터 분류 문제의 실무적 표준으로 자리 잡았다. 나아가 Grinsztajn et al.은 45 개의 정형 데이터셋을 대상으로 수행한 벤치마크 실험을 통해, 정형 데이터의 불연속적 결정 경계를 학습하는데 있어 트리 기반 모델이 ResNet 이나 Transformer 계열 딥러닝 모델보다 일관되게 우수한 성능을 나타냄을 규명하였다 Grinsztajn, Oyallon [16]. 이러한 실증적 증거는 본 연구가 회소 CRM 데이터 환경에서 트리 기반 앙상블 모델을 주요 기준 모형으로 선정한 이론적 근거가 된다.

본 연구는 이러한 학술적 논의를 반영하여, 복잡한 신경망 구조의 고도화에 의존하기보다 데이터 희소성을 완화할 수 있도록 도메인 지식 기반 파생변수를 통해 모형에 유효한 귀납적 편향을 주입하는 데이터 중심 접근법을 적용한다.

2.4 설명가능한 AI

예측 모형의 분류 성능 제고와 더불어 모형의 예측 근거를 실무자가 해석하고 의사결정에 반영할 수 있는 설명 가능성의 확보가 중요한 과제로 부각되고 있다. 글로벌 규제 환경의 변화로 인해 인공지능 모형의 투명성과 설명 가능성은 모형 도입의 핵심 요건으로 자리 잡았다[12, 17]. 복잡한 심층 신경망은 내부 작동 원리를 직접 파악하기 어려운 블랙박스 특성을 지닌다. 반면 트리 기반 앙상블 모형은 SHAP 기법과 결합될 때 협조적 게임 이론(Cooperative Game Theory)에 기반하여 각 변수가 개별 예측 확률에 기여한 정도를 공리적으로 분해할 수 있다[27, 28]. 이는 특정 도메인 요인이 개별 고객의 구매 예측 확률에 미친 기여도를 정량적으로 제시함으로써 모형 출력에 대한 해석 가능성을 제고한다.

LIME(Local Interpretable Model-agnostic Explanations)은 국소 영역에서 대리 선형 모형을 근사하여 사후 설명을 생성하는

기법이다 Ribeiro, Singh [30]. LIME 은 모형 불특정(Model-agnostic) 특성을 지녀 다양한 모형에 적용 가능하지만, 국소 근사 과정의 데이터 샘플링 방식에 따라 반복 실행 시 설명의 일관성이 저하될 수 있는 한계가 있다[3]. 이에 본 연구는 공리적 안정성을 확보한 SHAP 기법을 중심으로 모형을 해석한다.

트리 기반 모형과 SHAP 의 결합은 높은 계산 효율성과 설명력을 제공한다. TreeSHAP 알고리즘은 트리 앙상블 모형에 대해 정확한 Shapley Value 를 다항 시간 내에 산출하며[27], 개별 관측치 수준에서 예측값을 변수별 기여도로 엄밀하게 분해할 수 있도록 지원한다. 본 연구는 해당 기법을 활용하여, 최종 예측 모형 내에서 변수군별 상대적 영향력을 검증하고, 제안된 도메인 지식 파생변수들이 기존 베이스라인 변수 대비 발휘하는 차별적 예측 기여도를 정량적으로 비교 분석한다.

3. 데이터 및 방법론

3.1 데이터 수집 및 특성

본 연구는 대규모 전자상거래 환경의 실제 로그 데이터를 분석하기 위해 Kaggle 에 공개된 REES46 의 “E-commerce multichannel direct messaging 2021–2023” 데이터셋을 분석 대상으로 선정하였다.

해당 데이터는 2021년부터 2023년까지 2개년에 걸쳐 중형 전자상거래 플랫폼에서 수집된 고객관계관리(CRM) 기반의 다채널 메시징 이력으로, 실제 이커머스 환경에서 발생한 익명화된 마케팅 메시징 및 고객 반응 기록 로그로 구성되어 있다. 구체적으로 본 데이터셋은 약 185만 명의 고객을 대상으로 집행된 총 1,907개 마케팅 캠페인과 이에 따른 1억 7,200만 건의 메시지 발송 및 반응 이력을 포함한다.

분석에 활용된 데이터는 고객의 메시지 수신 및 반응 로그, 캠페인 속성, 고객 속성, 외부 시점 정보로 구성된 4개의 관계형 테이블로 이루어져 있으며 <표 1>, 캠페인 유형은 고객 프로파일 및 프로모션과 직접적인 연관성을 지닌 마케팅 캠페인으로 한정하고 단순 거래 진행 알림 등 운영성 메시지는 분석 대상에서 제외하였다. 고객은 이메일, 모바일 푸시, SMS 등 다양한 채널을 통해 시간 경과에 따라 복합적인 자극에 노출되며, 이러한 이력은 최종 구매 전환 및 이탈 여부와 연계되어 기록되어 있다. 특히 채널별 침해성과 인지적 회복 속도를 고려하여 최근 노출 빈도와 최종 노출 후 경과 시간을 결합한 복합 감쇠 함수를 적용하고 채널별 반감기 파라미터를 차등화하였다. 최종 타겟 변수인 구매 전환율은 약 0.1234% 수준으로 극단적인 클래스 불균형을 나타내며, 메시지, 캠페인,

고객, 시점 정보가 상이한 식별자로 분리되어 있어 개별 고객의 시간 흐름에 따른 상호작용 여정을 단일 시퀀스 형태로 재구성하는 전처리 과정을 수행하였다. 본 데이터셋은 특정 플랫폼의 로그인이나 다수의 상품 카테고리를 아우르고 있으며, 메시지 수신, 오픈, 클릭, 구매로 이어지는 전형적인 마케팅 깔때기 구조와 롱테일(Long-tail) 반응 분포를 충실히 반영하고 있어 일반적인 전자상거래 CRM 환경으로의 연구 결과 확장이 가능할 것으로 판단된다.

<표 1> 데이터테이블 주요 변수 구성 및 속성 설명

관계형 테이블	세부 속성 및 설명
메시지 전송 및 반응 로그 (Interaction Logs)	- 속성: 발송 시각(Timestamp), 채널(Channel), 플랫폼, 메시지 유형, 이메일 제공자 - 반응: Open, Click, Purchase 등 고객의 단계별 행동 데이터
캠페인 메타 정보 (Campaign Metadata)	- 속성: 캠페인 유형(Bulk/Trigger/Transactional), 주제(Topic), 마케팅 채널 - 설명: 마케팅 전략 및 운영 기간 등 공급자 측면의 의도(Intent) 정보
고객 관계 속성 (Customer Attributes)	- 속성: 고객 식별자(User ID), 최초 구매일(First Purchase Date) - 설명: 고객의 라이프사이클(Lifecycle) 단계 및 충성도를 추정하는 기준 정보
외부 시점 정보 (Temporal Context)	- 속성: 공휴일 여부, 요일, 월 정보 - 설명: 계절성(Seasonality) 및 사회적 이벤트가 소비에 미치는 외부 효과 정보

3.2 도메인 지식 기반 파생변수
프레임워크

<표 2> 마케팅 이론 기반 메커니즘
파생변수화 및 수식 매핑 프레임워크

도메인 지식 및 이론적 역할	문헌상 이론적 정의 및 기반 마케팅/행동 이론	본 연구의 조작적 정의 (메커니즘 파생변수화 및 수식)
① 구매/재구매 주기 (기저 구매 성향 및 잠재적 재구매 욕구 포착)	• 이론적 정의: 구매 직후 심리적 만족으로 인한 잠재적 냉각기와 일정 기간 경과 후 소비 주기 재진입에 따른 잠재적 재구매 욕구 변동 상태 • 기반 이론: (1) 고객 생애 가치(CLV), (2) BTYD 모형 (Pareto/NBD, BG/NBD), (3) 행동경제학 냉각기 효과	• 재구매 준비도: 과거 구매 간격 분포 기반 개인별 구매 사이클 단계 계산 $h(t) = \exp\left(-\frac{1}{2}\left(\frac{\text{마지막 구매 경과일} - \mu}{\sigma}\right)^2\right)$ • 구매 후 불응기: 구매 직후 냉각기 및 재구매 임계시점 확률 밀도 지수 계산 $r(t) = 1 - \exp\left(-\frac{t}{\tau}\right)$
② 시계열적 반응 (내재된 구매 욕구가 실제 행동으로 증폭되는 타이밍 조절)	• 이론적 정의: 고정된 선호가 아닌, 시간의 흐름, 요일, 시간대별 인지 리듬, 경제적 여유 주기 등에 따라 고객 반응 성향이 변동하는 현상 • 기반 이론: (1) 상황 의존적 선호, (2) 유통 관리 캘린더 효과 (가처분 소득 변동), (3) 생체 리듬과 인지 성과	• 선호 시간대 일치도: 원형 좌표계 기반 개인별 선호 시간대 일치도 계산 $d_{norm} = \frac{(1 - \cos(\theta_{curr} - \bar{\theta}))}{2}$ • 경제적 캘린더 효과: 급여일/분기말 근접도 가우시안 범프 지수 기반 계산 $bump(t) = \exp\left(-\frac{(t - t_p)^2}{\sigma^2}\right)$
③ 마케팅 피로도 (과도한 노출 필터링 및 메시지 수신 직후 발생가능한 일시적 예측 확률 감소 현상 포착)	• 이론적 정의: 반복적 광고 자극 노출로 인해 소비자의 인지적 과부하, 주의력 저하 및 자극 회피 심리 상태 • 기반 이론: (1) 정보 처리 이론 및 소비자 습관화 이론, (2) 광고 마모 효과 (Wearout/Weariness), (3) 한계 효용 체감 법칙	• 누적 마케팅 피로도: 반복 자극으로 인한 인지적 자원 고갈 및 회복 과정을 채널별 반감기 파라미터를 적용하여, 최근 메시지들의 시간 경과에 따른 누적 지수 감쇠 합 계산 $F(t) = \sum_{c \in C} \exp\left(-\frac{\Delta t_c(t)}{\tau_c}\right)$ • 고객 비활성 상태여부: 채널 별 마지막 메시지 수신 시점으로부터 임계치 초과 여부로 계산

④ 마케팅 채널 효과성 (모호한 대상을 배제하고 전환 정밀도(Precision) 최적화)	• 이론적 정의: 동일 메시지 반복에 따른 신선도 저하 및 설득 경로상 선행 접점과의 구조적 적합성에 따른 반응 효과 하강 현상 • 기반 이론: (1) 정보 이론 (엔트로피/신규성), (2) AIDA/깔때기 모형, (3) 옴니채널 경로 의존성	• 콘텐츠 주제 신선도: 노출 빈도와 경과 시간을 결합한 복합 감쇠 지수 계산 $N_{topic(t)} = \exp\left(-\frac{N_{td}}{\kappa}\right) \cdot \left(1 - \exp\left(-\frac{\Delta t}{\tau}\right)\right)$ • 성공 구매 경로와의 유사도 산출: 구매 발생 직전의 채널 흐름 기반 유사도 계산 $A_{path} = \frac{ P_{current} \cap P_{success} }{ P_{current} \cup P_{success} }$
---	---	---

선행연구에서 고찰한 마케팅 이론들은 소비자 행동 변화를 설명하는 이론적 기반을 제공하지만, 개념적 수준에 머무를 경우 기계학습 알고리즘이 직접 연산할 수 있는 특성으로 반영되기 어렵다. 이에 본 연구는 이론적 개념과 실제 데이터 연산 방식 간의 간극을 해소하고자 실시간 로그 데이터를 기반으로 4 대 도메인 지식 축에 대한 조작적 정의를 정립하였다. <표 2>는 본 연구에서 도출한 4 대 도메인 지식 축, 기반 이론, 이론적 및 조작적 정의, 산출 수식을 체계적으로 종합하여 제시한다.

첫째, 구매 및 재구매 주기 패턴 측을 고객 생애 가치 이론을 바탕으로 고객별 구매 주기의 규칙성을 정량화한다. 특히 행동경제학의 냉각기 효과(Cooling-off Effect)를 반영하여 구매 직후 추가 구매 확률이 감소했다가 일정 주기 경과 후 점진적으로 회복되는 기저 성향을 모델링하였다. 이를 위해 개별 고객의 과거

구매 간격 분포를 기반으로 현재 시점이 고객 고유의 재구매 사이클상 어느 단계에 위치하는지를 확률 밀도 함수 및 위험률 함수를 통해 산출하였다.

둘째, 시계열적 반응 패턴 측은 소비자행동론의 상황 의존적 선호(Context-dependent Preference) 및 유통 관리의 캘린더 효과(Calendar Effect)에 근거하여 시간적 및 경제적 맥락을 포착한다. 원형 통계(Circular Statistics) 기법을 활용하여 고객별 과거 선호 시간대 및 요일과의 일치도를 코사인 거리 기반으로 계산하고, 급여일 및 분기 말 등 가처분 소득 변동 시점에 대한 근접도를 모델링하여 마케팅 수용도의 동태적 변화를 측정하였다.

셋째, 마케팅 피로도 패턴 측은 광고 마모 효과(Advertising Wear-out)와 소비자 습관화(Habituation) 이론에 기반한다. 반복적인 마케팅 자극으로 인한 인지적 자원 고갈과 회복 과정을 지수 감쇠 모델로 조작화하여, 채널별 침해성에 따른

누적 피로도 지수를 실시간으로 추적하도록 설계하였다.

넷째, 마케팅 채널 효과성 패턴 측은 정보 이론의 엔트로피(Entropy) 개념과 고객 여정의 경로 의존성(Path Dependency)을 반영한다. 특정 주제에 대한 노출 빈도와 경과 시간을 결합하여 콘텐츠의 주제 신선도를 정량화하고, 과거 구매 전환에 기여한 유효 채널 경로와 현재 고객 여정 간의 경로 유사도를 산출하여 전환 가능성을 평가하도록 구성하였다.

3.3 데이터 전처리 및 데이터셋 구축

본 연구는 실제 마케팅 실무 환경의 조건을 온전히 반영하고 데이터 누수(Data Leakage) 및 선견 편향(Look-ahead Bias)을 엄격히 통제하기 위해 데이터 전처리 및 분할 프로토콜을 수립하였다. 먼저 구매 전환율이 약 0.1234%에 불과한 원본 데이터의 극단적인 클래스 불균형 분포를 인위적으로 왜곡하지 않고 그대로 유지하였다. 가상 샘플링을 통한 인위적 데이터 보정은 모형 배포 시 거짓 양성(False Positive)의 급증을 초래할 수 있으므로, 1 억 7,200 만 건의 원천 로그 분포를 보존한 상태에서 층화 무작위 분할(Stratified Random Split)을 적용하여 학습 데이터 70%, 검증 데이터 15%,

테스트 데이터 15%의 비율로 분할하였다 Thabtah, Hammoud [35]. 아울러 학습 과정에서는 비용 민감 학습(Cost-sensitive Learning) 방식을 적용하여 소수 클래스인 구매 전환에 대한 오분류 페널티를 차등 부여함으로써 기저 데이터 분포의 변형 없이 소수 클래스의 식별력을 제고하였다.

또한 데이터 누수를 원천 차단하기 위해 모든 결측치 대체 및 스케일링 등의 전처리 통계량은 오직 학습 데이터셋에서만 산출 및 고정되었으며, 검증 및 테스트 세트에는 학습 세트의 기준을 동일하게 적용하였다. 나아가 관계형 테이블을 결합하여 개별 고객의 시계열적 행동 여정을 재구성함에 있어, 모든 파생변수의 산출 범위는 예측 기준 시점 직전까지 관측된 과거 데이터로 엄격히 제한하여 미래 시점의 정보가 입력 변수에 혼입되는 현상을 방지하였다.

3.4 예측 알고리즘 실험 설계 및 평가

본 연구는 도메인 지식 주입 프레임워크의 유효성을 다각도로 검증하기 위해 전통적인 머신러닝 모델부터 최신 딥러닝 아키텍처에 이르는 총 9 종의 분류 알고리즘을 비교 평가하였다. 정형 데이터 분석에서 우수한 일반화 성능이 입증된 트리 기반 앙상블 계열로는 Random

Forest 와 XGBoost 를 선정하였다. 이들 모형은 설계된 동태적 도메인 변수가 고객의 시계열적 행동 구조를 정형 신호로 요약하는 효율성을 평가하는 주요 기준 모형으로 기능한다. 아울러 심층 신경망의 효율성을 종합적으로 비교하기 위해 전역적 상호작용 학습에 적합한 MLP, 국소적 패턴 추출을 위한 CNN, 순차적 시계열 정보 처리에 강점을 지닌 RNN 과 LSTM 등 단일 신경망 구조를 구축하였으며, 이들의 구조적 장점을 결합한 하이브리드 모델인 CNN-LSTM 과 RNN-LSTM 을 함께 구성하였다. 추가적으로 정형 데이터 처리에 특화된

최신 딥러닝 모델인 TabNet 을 실험군에 포함하였다.

평가 지표의 경우 구매 전환 클래스의 극단적인 희소성을 감안하여 통상적인 분류 문제에서 활용되는 정확도(Accuracy) 및 ROC-AUC 외에, 소수 클래스의 포착력과 비즈니스 적중 효율성을 객관적으로 평가할 수 있는 PR-AUC(Precision-Recall AUC)와 재현율에 가중치를 부여하는 F2-score 및 F1-score 를 핵심 평가지표로 설정하였다.

4. 실증 분석 결과



<그림 1> 제안하는 방법론의 프레임워크

4.1 하이퍼파라미터 최적화 및 검증 프로토콜

본 연구는 극단적인 클래스 불균형(0.1234%) 환경에서 예측 모형의 일반화 성능을 확보하고 데이터 누수(Data Leakage)를 방지하기 위해 5-Fold 교차검증과 PR-AUC 목적함수 기반의 Optuna 베이지안 최적화 파이프라인을 구축하였다. 전체 데이터셋은 학습, 검증, 테스트 세트로 엄격히 분할하였으며, 학습 단계에서는 특정 데이터 분할에 따른 과적합을 방지하고 시간적 선후 관계 왜곡을 통제하기 위해 5-Fold Stratified Cross-Validation 을 적용하였다.

각 알고리즘의 최적 하이퍼파라미터 탐색에는 탐색 효율성과 수렴 속도가 우수한 Optuna 기반의 Bayesian Optimization 기법을 활용하였다. 탐색 공간은 각 모형의 아키텍처 특성을 반영하여 개별 정의되었으며, 데이터 스케일러(Scaler) 및 분류 임계값(Threshold)을 포함한 구체적인 파라미터 탐색 범위와 도출된 최적값은 <부록 2>에 수록하였다. 모든 하이퍼파라미터 최적화는 희소 데이터 평가에 적합하도록 검증 세트의 PR-AUC 를 최대화하는 방향으로 수행되었다. 아울러 조기 종료(Early Stopping)와 프루닝(Pruning) 기법을 병행하여 비효율적인 연산을 배제하고 모형의 일반화 성능을 안정적으로 확보하였다.

4.2 도메인 지식 기반 파생변수의 기술통계 및 타당성 검증

단변량 집단 간 차이 검정(t -test 및 χ^2 test) 분석 결과, 본 연구에서 제안한 4 대 도메인 지식 기반 동태적 파생변수군 전체가 구매 여부(Purchased vs. Non-purchased)에 따라 통계적으로 유의미한 차이($p < 0.001$)를 나타내어 변수 구축의 개념적 타당성과 집단 판별력을 확인하였다. 변수군별 세부 기술통계 및 가설 검정 결과는 <부록 1>에 제시하였으며, 도메인 지식 축별 주요 통계적 특성은 다음과 같다.

첫째, “구매/재구매 주기 패턴” 변수군은 소비 주기 도래에 따른 집단 간 행동 차이를 유의미하게 포착하였다. 구매 집단의 마지막 구매 경과일은 평균 305.98 ± 129.04 일로 비구매 집단(364.52 ± 11.22 일)에 비해 통계적으로 유의미하게 짧게 관찰되었다. 또한 행동경제학적 냉각기 효과를 반영한 “구매 후 불응기”와 위험률 함수 기반의 “재구매 준비도” 역시 구매 집단에서 유의미하게 높은 평균값을 나타내어, 개인별 재구매 사이클의 임계점에 도달한 고객군을 식별하는 데 기여함을 확인하였다.

둘째, “시계열적 반응 패턴” 변수군은 구매 의사결정이 발현되는 외부 맥락적 접점의 유의미한 차이를 식별하였다. 주말

여부 교차분석 결과, 구매 전환 접점의 21.45%가 주말에 집중된 반면 비구매 접점은 5.75%에 그쳐 뚜렷한 주말 집중 효과를 나타냈다($p < 0.001$). 아울러 “선호 요일 일치도” 및 “급여일 근접도” 역시 두 집단 간 분포 차이가 유의미하게 형성되어, 주기적 가치분 소득 변동과 개인의 활동 리듬이 구매 전환 예측의 유효한 정황 신호로 기능함을 확인하였다.

셋째, “마케팅 피로도 패턴” 변수군은 능동적 참여도와 피로도 누적 간의 상호작용 신호를 명확히 구분하였다. 구매 집단은 최근 30 일간의 유저 오픈율($t = 40.32$, $p < 0.001$) 및 클릭률($t = 38.62$, $p < 0.001$)에서 비구매 집단 대비 현저히 높은 반응성을 보였다. 반면 이메일 경과 시간 분석에서는 구매 집단의 평균 경과 시간이 761.29 ± 1605.05 분으로 비구매 집단(1084.59 ± 071.62 분)보다 유의미하게 짧게 나타나, 적절한 휴식 간격 이후 자극에 노출되었을 때 전환 가능성이 제고되는 동태적 피로도 완화 패턴을 실증하였다.

넷째, “마케팅 채널 효과성 패턴” 변수군은 메시지 콘텐츠의 신선도와 성공 접점 경로의 유의성을 통계적으로 증명하였다. “주제 신선도”($p < 0.001$)와 “성공 캠페인 유사도”($p < 0.001$) 모두 구매 집단에서 통계적으로 높게 형성되었다. 이는 과거 유효했던 설득 경로와의 부합도 및 신규 콘텐츠의 전달 여부가 타겟팅 정밀도를 보정하는 유용한 도메인 지식 신호임을 시사한다.

4.3 회소 CRM 정형 데이터에서의 알고리즘별 예측 성능 비교

본 절에서는 구매 전환율이 0.1234%인 회소 CRM 홀드아웃 테스트 세트 환경에서 총 9 종의 머신러닝, 심층 신경망 및 정형 딥러닝 알고리즘의 예측 성능을 비교 검증하였다. 베이스라인 변수와 전체 도메인 지식이 통합된 변수 투입 시 알고리즘별 개별 및 군집 평균 평가 결과는 <표 3>과 같다.

<표 3> 원분포 홀드아웃 테스트 세트(0.1234%)에서의 알고리즘별 성능 평가 및 증분 비교

Algorithm	Precision		Recall		F1-score		F2-score		PR-AUC	
	Base	Total	Base	Total	Base	Total	Base	Total	Base	Total
XGB	0.4199	0.2991 (-28.8%)	0.3074	0.5230 (70.1%)	0.3550	0.3806 (7.2%)	0.3248	0.4549 (40.0%)	0.3177	0.3620 (13.9%)
RF	0.2371	0.3041 (28.3%)	0.6456	0.4819 (-25.4%)	0.3468	0.3729 (7.5%)	0.4802	0.4315 (-10.1%)	0.2887	0.3382 (17.1%)
MLP	0.2561	0.2602 (1.6%)	0.4144	0.4635 (11.9%)	0.3165	0.3333 (5.3%)	0.3688	0.4009 (8.7%)	0.2675	0.3072 (14.8%)
CNN	0.2680	0.2392 (-10.8%)	0.3290	0.3549 (7.9%)	0.2954	0.2858 (-3.3%)	0.3147	0.3236 (2.8%)	0.2302	0.2546 (10.6%)

RNN	0.2381	0.2598 (9.1%)	0.4695	0.4965 (5.8%)	0.3159	0.3411 (8.0%)	0.3931	0.4200 (6.8%)	0.2629	0.3195 (21.5%)
LSTM	0.2163	0.2514 (16.2%)	0.6035	0.5084 (-15.8%)	0.3185	0.3364 (5.6%)	0.4444	0.4221 (-5.0%)	0.2688	0.3166 (17.8%)
CNN-LSTM	0.2083	0.2393 (14.9%)	0.6272	0.4155 (-33.8%)	0.3127	0.3037 (-2.9%)	0.4473	0.3621 (-19.0%)	0.2648	0.2647 (-0.0%)
RNN-LSTM	0.2519	0.2983 (18.4%)	0.4290	0.4149 (-3.3%)	0.3174	0.3470 (9.3%)	0.3761	0.3848 (2.3%)	0.2661	0.3176 (19.4%)
TabNet	0.2806	0.2690 (-4.1%)	0.3960	0.4781 (20.7%)	0.3285	0.3443 (4.8%)	0.3659	0.4138 (13.1%)	0.2826	0.3182 (12.6%)
ML Average	0.3285	0.3016 (-8.2%)	0.4765	0.5025 (5.4%)	0.3509	0.3768 (7.4%)	0.4025	0.4432 (10.1%)	0.3032	0.3501 (15.5%)
DL Average	0.2456	0.2596 (5.7%)	0.4669	0.4474 (-4.2%)	0.3150	0.3273 (3.9%)	0.3872	0.3896 (0.6%)	0.2633	0.2997 (13.9%)

알고리즘의 비교 조건 중 가장 높은 수치를 기록하였다.

실험 결과, 도메인 지식 파생 변수가 통합되었을 때 머신러닝 및 딥러닝 군집 평균 전체에서 PR-AUC 가 각각 +15.5%, +13.9% 상승하였으며, 핵심 종합 평가지표인 F1-score 역시 각각 +7.4%, +3.9% 향상되었다. 이는 마케팅 도메인 지식을 동태적 상태 변수로 조작화하여 주입하는 접근법이 알고리즘 구조와 무관하게 예측 성능을 보편적으로 개선할 수 있음을 시사한다.

최적 예측 모형으로 선정된 XGBoost 는 도메인 지식 결합 후 베이스라인 대비 Recall 이 30.74%에서 52.30%로 대폭 증가(70.1%)하여 구매 전환 고객의 과반을 성공적으로 포착하였다. XGBoost 는 높은 정밀도(41.99%)에 비해 소수 클래스를 보수적으로 예측하여 실제 구매자의 약 70%를 미포착하는 한계가 존재했으나, 도메인 지식을 투입함으로써 잠재적 구매 신호를 효과적으로 포착하였다. 그 결과 F1-score, F2-score, PR-AUC 모두 전체 9 개

아울러 정형 데이터 특유의 불연속적 결정 경계를 학습함에 있어 트리 기반 앙상블 모형이 심층 신경망 계열 대비 일관된 성능 우위를 보였다. 도메인 지식 투입 후 ML 군의 평균 F1-score 및 PR-AUC 는 DL 군의 평균 수치를 유의미하게 상회하였다. 특히 정형 데이터 처리에 특화된 최신 아키텍처인 TabNet 이나 RNN-LSTM 역시 도메인 지식 주입 시 성과 개선을 보였으나, 트리 기반 모형인 XGBoost 및 Random Forest 의 F1 수치에는 미치지 못하였다.

단일 지표 간 트레이드오프 관점에서 도메인 지식 주입은 모형별 예측 불균형을 재조정(Rebalancing)하는 역할을 수행하였다. Random Forest 의 경우 베이스라인에서 64.56%의 높은 재현율을 보였으나 정밀도가 23.71% 수준으로 거짓 양성(False Positive)이 빈번히 발생하였다. 반면 도메인 지식 통합을 통해 정밀도를 30.41%로 제고(28.3% 상승)하며 노이즈를 효과적으로

필터링하였으며, 결과적으로 정밀도와 재현율의 균형을 나타내는 F1-score 는 +7.5% 상승하였다. 결론적으로 구매 전환율 0.1234%의 희소 CRM 데이터 환경에서는 사전 지식이 없는 딥러닝의 표현 학습에 의존하기보다, 잘 설계된 마케팅 도메인 변수를 반영한 트리 기반 앙상블 모형을 활용하는 것이 예측 정확도 및 종합 분류 효율성(F1/F2/PR-AUC) 측면에서 가장 유용한 대안임을 실증한다.

4.4 도메인 지식 축별 세부 영향력 분석

XGBoost 모형을 대상으로 수행한 변수 절삭 실험 결과, 마케팅 피로도(③) 축과 시계열적 반응(②) 축이 재현율(Recall)과 종합 분류 효율성(F1, F2, PR-AUC) 제고를 주도하는 핵심 예측 신호임이 확인되었다. 반면, 구매/재구매 주기(①) 축과 마케팅 채널 효과성(④) 축은 단독 투입 시 단기 전환 포착보다는 경계면 재조정을 통한 보조적 스크리닝 역할을 수행하는 것으로 나타났다. 베이스라인 대비 4 가지 도메인 지식 축의 개별 추가에 따른 상세 성과 및 증분 변화율은 <표 4>와 같다.

도메인 지식 축별 세부 기여도를 살펴보면, 마케팅 피로도 축(③)은 단일 변수 그룹 중 가장 큰 폭의 성능 개선을 견인하였다. 베이스라인 대비 Recall 이

72.58% 증가하였으며, 이에 따라 F1-score(+8.11%), F2-score(+41.66%), PR-AUC(+10.40%) 모두 최고 개선 폭을 기록하였다. 이는 최근 노출 강도, 수신 간격, 반응 감쇠율 등의 지표가 고객의 즉각적 전환 의도를 식별하는 1 순위 단기 신호로 작용함을 보여준다.

시계열적 반응 축(②)은 피로도 축 다음으로 높은 예측 기여도를 나타냈다. Recall 이 40.07% 상승함에 따라 F2-score(+24.70%) 및 PR-AUC(+7.47%)의 유의미한 성과 개선이 확인되었다. 이는 요일, 시간대, 특정 급여 주기 등 시간적 맥락 정보가 잠재적 구매 욕구가 실제 행동으로 구현되는 최적의 마케팅 타이밍을 조율하는 요인으로 기능함을 의미한다.

구매/재구매 주기 축(①)과 마케팅 채널 효과성 축(④)은 단독 추가 시 정밀도와 재현율 간의 소폭 조정 양상을 보였다. 두 축 모두 단독 투입 시에는 Recall 과 F1-score 에서 미세한 감소가 관찰되었으나, PR-AUC 에서는 각각 +1.08% 및 +0.21%의 소폭 상승을 보였다. 이는 단기적 구매 자극 신호(②, ③)와 달리, 주기 및 채널 변수는 기저 성향을 보정하고 예측 경계면을 정합화하는 보조적 스크리닝 기제로 작동함을 시사한다.

결론적으로 도메인 지식의 단독 반영 결과는 피로도에 의한 1 차 전환 대상 포착

→ 시계열에 의한 마케팅 시점 조율 → 통합 시 여타 보조 변수들과 결합하여
 주기 및 채널에 의한 기저 확률 종합 분류 성능의 상한을 완성하는 토대가
 보정이라는 단계적 의사결정 구조를 됴를 실증한다.
 반영한다. 피로도 및 시계열 축을 통해
 대폭 제고된 Recall 은 향후 전체 변수군

<표 4> 최적 알고리즘(XGBoost) 기반 도메인 지식 축별 상대적 증분 변화

Experiment	Feature Count	Δ Precision	Δ Recall	Δ F1-score	Δ F2-score	Δ PR-AUC
Baseline	41	0.4201	0.3077	0.3556	0.3253	0.3182
Baseline + ① 구매/재구매 주기	44	0.4082 (-2.7%)	0.3055 (-0.7%)	0.3495 (-1.6%)	0.3217 (-1.0%)	0.3214 (+1.1%)
Baseline + ② 시계열적 반응	47	0.3273 (-22.1%)	0.4312 (+40.1%)	0.3722 (+4.8%)	0.4052 (+24.7%)	0.3414 (+7.5%)
Baseline + ③ 마케팅 피로도	49	0.3016 (-28.4%)	0.5313 (+72.6%)	0.3844 (+8.1%)	0.4605 (+41.7%)	0.3514 (+10.4%)
Baseline + ④ 마케팅 채널 효과성	46	0.3992 (-4.8%)	0.3052 (-0.8%)	0.3463 (-2.6%)	0.3203 (-1.5%)	0.3182 (+0.2%)

4.5 비즈니스 마케팅 타겟팅 적중력 및 비용 절감 효과

본 절에서는 통계적 평가지표를 넘어,
 제안된 4 가지 도메인 지식 축이 실제
 마케팅 타겟팅 환경에서 제공하는
 비즈니스 실무 효용성인 타겟팅 적중력 및
 예산 최적화 효과를 오차 행렬과 상위
 타겟팅 규모별 적중 수(Top-K Hits)를 통해

검증하였다. 분석 결과, 마케팅 피로도(③)
 및 시계열적 반응(②) 축이 실제 구매자(TP)
 포착 규모를 대폭 확대하는 주도적 역할을
 수행한 반면, 구매/재구매 주기(①) 및
 마케팅 채널 효과성(④) 축은 과도한
 타겟팅 확장을 제어하는 보완적 기제로
 작동함을 확인하였다. 베이스라인 모형에
 각 도메인 지식 축을 개별 추가했을 때의
 상세 적중 지표는 <표 5>와 같다.

<표 5> XGBoost 모형 기준 도메인 지식 축별 Top-K 타겟팅 적중 수 및 오차 행렬 상세

Experiment	Top 15k Hits	Top 35k Hits	Top 50k Hits	진짜 구매 (TP)	거짓 정보 (FP)	미포착 (FN)	진짜 비구매 (TN)
Baseline	8,290	11,507	14,276	9,787	13,519	22,050	25,752,924
Baseline + ① 구매/재구매 주기	8,308	11,421	14,345	9,718	14,087	22,119	25,752,356
Baseline	8,411	12,315	15,222	13,708	28,174	18,129	25,738,269

+ ② 시계열적 반응							
Baseline + ③ 마케팅 피로도	8,308	12,160	15,962	16,890	39,302	14,947	25,727,141
Baseline + ④ 마케팅 채널 효과성	8,256	11,266	14,052	9,701	14,586	22,136	25,751,857

도메인 지식 축별 세부 분석 결과, 마케팅 피로도 축(③)은 실제 구매자(TP) 포착 물량을 확대하고 미포착(FN)에 따른 기회비용을 줄이는 데 가장 유의미하게 기여하였다. 피로도 변수군이 투입되었을 때 진짜 구매자(TP)는 베이스라인(9,787 명) 대비 16,890 명으로 크게 증가하였으며, 오발송 고객(FN)은 22,050 명에서 14,947 명으로 감소하였다. 또한 상위 5 만명 타겟팅 시 가장 많은 15,962 명의 적중 수를 기록하여, 최근의 마케팅 노출 누적도와 반응 패턴이 구매 전환을 유도하는 주요 실무적 지표임을 확인하였다. 시계열적 반응 축(②) 역시 피로도 축과 유사하게 타겟팅 포착 범위를 넓히는 확장적 특성을 보였다. 해당 변수군 추가 시 진짜 구매자(TP)는 13,708 명으로 증가하였으며, Top 35k 구간(12,315 명)과 Top 50k 구간(15,222 명) 모두 베이스라인 대비 향상된 타겟팅 적중 수를 나타냈다. 이는 특정 요일이나 시간대적 맥락이 전환 가능성이 높은 고객군을 추가로 선별하는데 효과적임을 의미한다. 반면 구매/재구매 주기(①)와 마케팅 채널 효과성(④) 축은 타겟팅 규모를 확장하기보다는 기존의 예측 경계면을

보수적으로 유지하는 특성을 보였다. 두 변수군의 경우 진짜 구매자(TP) 수 각각 9,718 명과 9,701 명으로 오차 행렬 지표가 베이스라인 수준과 유사하게 유지되었다. 이는 고객의 장기적 구매 주기나 선호 채널 이력 변수가 단기적 구매 확율을 급격히 증폭시키기보다는, 구매 확률이 모호한 대상을 보수적으로 필터링하여 정밀도를 관리하는 기제로 작동함을 시사한다.

결론적으로 본 실증 결과는 마케팅 실무에서 일반적으로 과거 장기 구매 이력(①)이 가장 중시되던 전통적 관점과 달리, 0.1234%의 극심한 불균형 환경 하에서는 고객의 즉각적인 마케팅 피로도(③)와 시계열적 반응 맥락(②)이 실제 구매 전환을 포착하는 데 더 높은 상대적 효용을 지닐 수 있음을 확인해 준다. 이러한 지식 축들의 상호보완적 결합은 마케터가 가용 예산에 맞추어 진짜 구매자(TP)와 오발송 고객(FN) 사이의 최적 균형을 설정할 수 있는 의사결정 기준을 제공한다.

4.6 주요 파라미터 민감도 및 강건성 검증

본 절에서는 제안된 프레임워크의 학술적 타당성과 실무 적용성을 제고하기 위해 주요 모형 파라미터 및 운영 기준에 대한 민감도 분석(Sensitivity Analysis)을 수행하였다. 분석은 탐색적으로 설정된 채널별 마케팅 피로도 반감기 파라미터(τ) 변동에 따른 모형의 구조적 강건성 평가와 마케팅 가용 예산에 따른 상위 타겟팅 규모(Top-K) 변동 민감도 분석의 두 가지 축으로 구성된다.

마케팅 피로도 반감기 파라미터(τ)를 기준치 대비 $\pm 50\%$ 범위로 조정하며 평가한 결과, 최적 모형의 F1-score 와 PR-AUC 는 각각 0.3783~0.3873, 0.3527~0.3613 의 좁은 구간 내에서 안정적으로 유지되어 높은 구조적 강건성을 나타냈다. 이는 제안된 동태적 피로도 변수가 특정 파라미터 설정값에 과적합되지 않고, 소비자의 노출 감쇠 패턴을 일반화하여 포착하고 있음을 시사한다. 채널별 기준 반감기에 대해 0.50x 부터 1.50x 까지 5 단계의 배율을 적용한 상세 민감도 평가 결과는 <표 6>과 같다.

<표 6> 마케팅 피로도 반감기 파라미터(τ) 변동에 따른 예측 성능 민감도 평가

Half-life Multiplier	SMS τ	Email τ	Push τ	Precision	Recall	F1-score	F2-score	PR-AUC	Δ PR-AUC
0.50x	36h	24h	12h	0.2992	0.5375	0.3845	0.4637	0.3590	0.0056
0.75x	54h	36h	18h	0.3353	0.4576	0.3870	0.4265	0.3613	0.0079
1.00x (Baseline)	72h	48h	24h	0.3042	0.5181	0.3833	0.4542	0.3534	0.0000
1.25x	90h	60h	30h	0.3073	0.4922	0.3783	0.4393	0.3527	-0.0007
1.50x	108h	72h	36h	0.3291	0.4706	0.3873	0.4333	0.3604	0.0070

실험 결과, 반감기 파라미터를 절반으로 축소하거나 1.5배로 확대하여도 PR-AUC 의 최대 편차는 +0.0079 수준에 불과하였으며, F1-score 역시 기준치(0.3833) 대비 유사한 수준을 보였다. 특히 반감기를 비교적 짧게 설정한 조건(0.50 배)에서는 재현율이 0.5375 까지 상승하였고, 반감기를 길게 설정한 조건(0.75 배, 1.50 배)에서는 정밀도가 약 0.33 수준으로 개선되는 상호보완적 트레이드오프가 관찰되었다.

이러한 결과는 제안 모형이 특정 반감기 값에 민감하게 반응하지 않으며, 실무 적용 시 채널별 반감기 설정에 대한 유연한 운영 여지를 제공함을 의미한다.

또한, 원분포 홀드아웃 테스트 세트를 대상으로 상위 타겟팅 규모(K)를 변동시킨 결과, 고적중률 중심의 정밀 타겟팅 전략과 전환 고객 포착 중심의 확장 타겟팅 전략 간의 명확한 실무적 분기점이 도출되었다. 상위 타겟팅 규모에 따른 실제 구매자

포착 수(TP), 적중률(Precision@\$K\$), 누적 재현율(Cumulative Recall), 및 무작위 발송 대비 향상도 평가 결과는 <표 7>과 같다.

<표 7> XGBoost 모형 기준 도메인 지식 축별 Top-K 타겟팅 적중 수 및 오차 행렬 상세

Top Targeting (K)	Positive Ratio	Captured Buyers (TP)	Precision@K	Cumulative Recall	Random vs. Lift
10,000	0.04%	5,320	53.20%	16.71%	431.1x
20,000	0.08%	9,340	46.70%	29.34%	378.4x
50,000	0.19%	15,580	31.16%	48.94%	252.5x
100,000	0.39%	23,490	23.49%	73.78%	190.3x
200,000	0.78%	30,510	15.26%	95.83%	123.7x

분석 결과, 건당 발송 단가가 상대적으로 높은 채널의 경우 Top 10,000 전략을 적용할 때 53.20%의 정밀도와 431.1 배의 향상도(Lift)를 기록하여 마케팅 예산 낭비를 최소화할 수 있다.

반면 앱 푸시나 이메일 등 한계 발송 비용이 극히 낮은 채널의 경우, 전체 고객의 0.78%에 해당하는 상위 20 만명만을 타겟팅하는 Top 200,000 전략을 통해 전체 구매 전환의 95.83%(30,510 명)를 포착하는 운영이 가능하다. 이는 전체를 대상으로 무차별 발송하던 기존 관행 대비 99.22%의

최적 모형인 XGBoost 를 대상으로 SHAP 분석을 수행한 결과, 모형은 단순 고객 참여도 지표에만 편향되지 않고, 기저 활동성 변수와 본 연구가 제안한 동태적 도메인 지식 변수를 다층적으로 결합하여 구매 전환 확률을 산출함이 확인되었다. 전체 예측 집합에 대한 변수 기여도 및


발송 물량을 절감하면서도 전환 성과의 대부분을 확보할 수 있음을 실증한다. 결과적으로 제안된 프레임워크는 고정된 단일 기준에 국한되지 않고 가용 예산과 채널 환경에 맞추어 마케팅 실행 범위를 최적화할 수 있는 정량적 의사결정 기준을 제공한다.

4.7 모델의 설명력 및 변수 중요도

검증: SHAP 분석

영향력 방향성은 <그림 2>의 SHAP Summary Plot 에 제시하였으며, 미구매(0)와 구매(1) 분류 시 변수 중요도의 구조적 변화는 <그림 3>의 SHAP Rank Shift 로 도식화하였다.

Knowledge Category	Positive Contribuiton	Rank	Negative Contribuiton	Knowledge Category
베이스라인	캠페인 유형 : 기타 거래	1	메시지 수신 : 미청의/기타	베이스라인
마케팅 피로도 패턴	채널별 특정 주제 캠페인 오픈율(30일 내)	2	가입 기간 (첫 구매 경과)	베이스라인
베이스라인	캠페인 지속 시간(평균)	3	선호 시간대 일치도	시계열적 반응 패턴
베이스라인	이메일 계정 : 기타	4	급여일 근접도	시계열적 반응 패턴
베이스라인	캠페인 채널 : 이메일	5	캠페인 유형 : 전체 유저	베이스라인
베이스라인	발송 채널 : 이메일	6	분기 말 근접도	시계열적 반응 패턴
시계열적 반응 패턴	주차 정보	7	이메일 경과 시간	마케팅 피로도 패턴
베이스라인	메시지 수신 : 데스크탑	8	선호 요일 일치도	시계열적 반응 패턴
마케팅 피로도 패턴	마케팅 피로도	9	성공 경로 일치도	마케팅 채널 효과성 패턴
마케팅 채널 효과성 패턴	주제 경과 시간	10	푸시 경과 시간	베이스라인
마케팅 채널 효과성 패턴	주제 신선도	11	이메일 계정 : 지메일	베이스라인
베이스라인	메시지 수신 : 스마트폰	12	총 캠페인 수	베이스라인
		13	캠페인 주제 : 할인 정보	베이스라인
		14	최종 클릭 경과 시간(평균)	베이스라인
		15	캠페인 주제 : 기타	베이스라인
		16	마지막 구매 경과일	구매/재구매 주기 패턴
		17	최근 오픈 경과 시간(평균)	베이스라인
		18	캠페인 채널 : 모바일	베이스라인



<그림 2> 구매 예측 설명을 위한 상위 30 위 변수 중요도 및 영향력 방향성 결과


전역적 변수 기여도 분석 결과, 모형 내 변수들의 예측 기여는 세 가지 세부 메커니즘으로 구분되어 작동함을 확인하였다. 첫째, 기저 활동성 및 서비스 맥락 변수의 통제 역할이다. 최상위권에 위치한 “캠페인 유형: 기타 거래”(Rank 1)와 “채널별 특정 주제 캠페인 오픈율(30일 내)”(Rank 2)은 높은 변수값이 양의 SHAP 값과 뚜렷한 양의 상관관계(Corr: +0.67, +0.50)를 형성하였다. 이는 최근 반응 이력이 활발한 고객의 기저 관여도를 대변하는 통제 신호로서 기능한다.

둘째, 시계열적 반응 패턴 변수군의 광범위한 상위권 포진이다. 누적 중요도 75%~90% 구간에 걸쳐 “선호 시간대 일치도”(Rank 9), “급여일 근접도”(Rank 10),

“분기 말 근접도”(Rank 12), “주차 정보”(Rank 14), “선호 요일 일치도”(Rank 15) 등 제안된 시점 맥락 변수들이 집중 배치되었다. 이는 기저 활동성이 통제된 상태에서, 실제 구매 행동이 집중적으로 발현되는 최적의 마케팅 타이밍을 판별하는 유의미한 예측 신호로 작동함을 시사한다. 셋째, 마케팅 피로도 패턴 및 감쇠 패턴 변수의 비선형적 영향력이다. “이메일 경과 시간”(Rank 13, Corr: -0.83)과 “푸시 경과 시간”(Rank 18, Corr: -0.87), “마케팅 피로도”(Rank 20) 등은 메시지 수신 직후 발생할 수 있는 일시적 반응 억제 및 시간 경과에 따른 감쇠 효과를 포착하여 모형의 과잉 예측을 보정하는 필터 역할을 수행하였다.

다음으로 미구매 판별과 실제 구매 예측 간의 SHAP 중요도 순위 변동(<그림 3>)을 분석한 결과, 모형은 비구매 대상을 광범위하게 스크리닝하는 단계와 최종 구매 전환을 확정하는 단계에서 5 개 변수군의 역할을 명확히 분업화하여 가중치를 재배치하고 있음이 확인되었다. 미구매 선별 시에는 환경적 베이스라인 및

피로도 변수가 상위권에서 배제 기제로 작동하는 반면, 구매 전환 예측 시에는 구매/재구매 주기 변수와 직접적 상호작용 최근성 변수의 기여도가 급상승하며, 시계열적 반응 변수군은 두 단계 전반에서 안정적인 시점 조율 기능을 수행하였다.



<그림 3> 미구매 vs 구매 예측 시 SHAP 변수 중요도 순위 변동 시각화

“구매/재구매 주기 패턴” 변수군은 잠재 타겟 중 실제 구매 전환을 최종 확정 짓는 핵심 결정 요인으로 기능하였다. 해당 변수군의 대표 변수인 “마지막 구매 경과일”은 미구매 판별 시 27 위에 머물렀으나, 구매 예측 시에는 7 위로 20 계단 대폭 상승하였다. 이는 소비자의 고유한 구매 주기가 비구매 대상을 넓게 탐색하는 초기 단계에서는 영향력이 제한적이지만, 구매 확률의 임계값을 최종적으로 넘어서는 전환 확정 단계에서는 모형의 분류 확률을 결정짓는 가장 직접적인 가중치로 전환됨을 실증한다.

“마케팅 피로도 패턴” 변수군은 기저 관여도 유지와 함께 비구매 대상을 사전에 배제하는 음성 스크리닝 역할을 주로 수행하였다. 장기적 참여도를 대변하는 “채널별 특정 주제 캠페인 오픈율(30 일 내)”은 미구매 2 위, 구매 4 위로 두 클래스 모두에서 최상위권을 유지하여 고객의 기저 활동성을 일관되게 통제하였다. 반면 누적 노출에 따른 “마케팅 피로도” 변수는 미구매 판별 시 20 위에서 구매 예측 시 29 위로 순위가 하강하였다. 이는 피로도 변수가 전환 고객을 특징하는 양의 신호이기보다는, 피로가 누적되어 반응 가능성이 희박한 비구매 대상을 사전에

감점 및 제외하는 1 차 음성 필터로 작용함을 나타낸다.

“시계열적 반응 패턴” 변수군은 특정 클래스에 편향되지 않고 미구매와 구매 예측 전반에서 안정적인 시점 완충 기제로 작동하였다. “선호 시간대 일치도”(9 위 → 10 위), “급여일 근접도”(10 위 → 13 위), “분기 말 근접도”(12 위 → 11 위), “주차 정보”(14 위 → 15 위), “선호 요일 일치도”(15 위 → 18 위) 등 시계열 축의 주요 변수들은 두 클래스 간 순위 변동 폭이 크지 않고 9~18 위권의 중상위권을 지속적으로 유지하였다. 이는 시계열 맥락 정보가 개별 고객의 구매 성향 자체를 급변시키기보다는, 메시지 발송 타이밍의 적합성을 상시적으로 조율하여 예측 확률의 정밀도를 보정하는 역할을 수행함을 보여준다.

“마케팅 채널 효과성 패턴 및 베이스라인” 고관여 변수는 점점 적합도 보조와 직접적 상호작용 신호 포착을 분담하였다. 채널 효과성 축의 “성공 경로 일치도”는 17 위에서 16 위로 중위권을 유지하며 과거 유효 채널 경로에 대한 부합도를 안정적으로 평가하였다. 아울러 “캠페인 유형: 기타 거래”(1 위 유지) 등 정적 인프라 변수가 양 클래스 공통의 구조적 환경을 정의하는 가운데, 베이스라인 행동 지표 중 “최종 클릭 경과 시간(평균)”은 미구매 판별 시 25 위에서 구매 예측 시 9 위로 16 계단 상승하였다.

이는 단순 노출을 넘어 링크 클릭과 같은
고관여 행동의 최근성이 주기 패턴과
유기적으로 결합하여 최종 전환 판단을
강화하는 유의미한 보조 지표로 활용됨을
확인해 준다.

이러한 순위 이동 양상은 제안 모형이
불균형 CRM 환경 하에서 체계적인 다단계
의사결정 프로세스를 학습하였음을
실증한다. 즉, 발송 환경 및 피로도 변수를
통해 비반응 고객을 사전에 스크리닝하는
1 단계, 시계열적 반응 변수를 통해 최적
수신 시점을 지속적으로 보정하는 2 단계,
재구매 주기 및 고관여 상호작용 최근성을
바탕으로 실제 구매 전환 대상자를 최종
확정하는 3 단계의 계층적 분류 메커니즘이
모형 내부에 내재화되었음을 시사한다.

5. 토의 및 한계

5.1 학술적 및 이론적 시사점

본 연구의 실증 분석 결과는 크게 세
가지 거시적 발견으로 요약된다. 첫째,
구매 전환율이 0.1234%에 불과한 극단적
희소 환경에서 도메인 지식 기반의 동태적
상태 변수 주입은 알고리즘 아키텍처
전반의 예측 성능을 보편적으로
개선하였다. 둘째, 변수 절삭 및 SHAP
분석 결과 소비자의 즉각적인 마케팅
피로도와 시계열적 수신 맥락이 전환 고객
포착력을 주도하는 1 차 신호로 작용하고,

전통적 구매 주기는 최종 전환 여부를
확정하는 보완적 가중치로 기능함을
확인하였다. 셋째, 정형 데이터 환경에서는
무조건적인 심층 신경망 고도화보다
도메인 이론에 기반한 데이터 중심의
귀납적 편향 주입이 모형의 분류 효율성과
실무적 설명력을 동시에 제고하는 유효한
전략임을 실증하였다.

이러한 발견은 전통적 CRM 및 소비자
행동 이론에 중요한 학술적 확장을
제공한다. 기존의 RFM 모형이나 BTYD
계열의 확률 모형들은 장기간 집계된 과거
거래 이력을 중심으로 고객의 기저 성향을
정적으로 프로파일링하는 데 집중해 왔다.
이로 인해 다채널 디지털 마케팅 환경에서
메시지 수신 직후 실시간으로 변동하는
소비자의 인지적 상태와 상황적 맥락을
모형 내에 내생화하는 데 구조적 한계를
지녔다. 본 연구는 소비자 습관화 이론과
정보 처리 이론을 실시간 로그 기반의
지수 감쇠 피로도 모델로 조작화함으로써,
고객의 인지적 자원 고갈과 회복
메커니즘을 예측 모형 내에 성공적으로
구현하였다. 특히 메시지 수신 후 일정
기간의 휴식 간격이 주어졌을 때 전환
확률이 비선형적으로 회복되는 현상은,
마케팅 자극의 효과가 단순 노출 빈도의
총량이 아니라 인지적 피로도의 완충
주기에 의해 규정된다는 이론적 가설을
실증적으로 뒷받침한다.

나아가 상황 의존적 선호 및 캘린더 효과 문헌과 관련하여, 소비자의 내재된 구매 욕구는 정적으로 머무르지 않고 급여일이나 분기 말과 같은 경제적 맥락, 개인의 활동 시간대와 같은 시간적 신호와 결합할 때 비로소 행동으로 발현된다는 점을 규명하였다. 이는 과거 구매 이력(Who) 중심의 전통적 마케팅 프레임워크를 수신 시점 역동성(When)과 피로도 조율(How often) 중심의 동태적 행동 모델로 진화시키는 이론적 근거를 제공한다.

5.2 방법론적 함의

본 연구의 실증 결과는 정형 데이터 영역에서 모형 구조의 복잡성 추구보다 데이터 표현력의 보강이 선행되어야 한다는 데이터 중심 인공지능(Data-Centric AI)의 핵심 명제를 지지한다. 극도로 불균형한 CRM 로그 환경에서 트리 기반 앙상블 모형이 복잡한 심층 신경망 및 정형 특화 딥러닝 대비 일관된 성능 우위를 나타낸 원인은 귀납적 편향의 구조적 적합성에서 기인한다. 정형 데이터 특유의 불연속적이고 계단식인 결정 경계를 학습하는 데 있어, 연속적 미분 가능 함수에 기반한 신경망 근사보다 트리의 축 정렬 분할 방식이 본질적으로 우수한 학습 효율성을 제공함을 재확인하였다.

특히 본 연구가 제안한 마케팅 이론 기반의 파생변수는 복잡한 비선형적 시계열 상호작용을 정형화된 수학적 신호로 사전 변환하여 모형에 주입함으로써, 트리 모형의 분할 효율을 극대화하였다. 이는 신경망 아키텍처의 파라미터 증대에 리소스를 집중하기보다, 도메인 지식을 활용하여 특성 공간의 정보 이득을 구조화하는 방식이 예측 정확도와 연산 효율성 측면에서 우수한 한계 효용을 지님을 시사한다. 아울러 TreeSHAP 과의 결합을 통해 도메인 변수군이 수행하는 계층적 3 단계 의사결정 구조(음성 스크리닝, 시점 맥락 조율, 최종 구매 확정)를 정량적으로 규명함으로써, 블랙박스 모형의 한계를 극복하고 모델 출력값의 신뢰성을 입증하는 설명 가능한 인공지능(XAI) 방법론의 실효성을 확인하였다.

5.3 실무적 함의

본 연구는 일선 마케팅 실무자 및 이커머스 플랫폼 운영진에게 단순한 점수 합산식 타겟팅 관행을 탈피하고, 다차원 동태적 상태를 반영한 지능형 마케팅 오케스트레이션 도구로의 패러다임 전환을 제안한다.

실무 현장에서 관행적으로 이루어지던 대규모 무차별 일괄 발송 방식은 단기적

매출 증대 효과에 비해 고객 피로도 누적, 수신 거부, 채널 발송 비용 낭비라는 구조적 비효율을 초래해 왔다. 본 연구의 결과는 마케터가 가용 예산과 채널별 발송 단가에 맞추어 운영 임계값을 동적으로 조율할 수 있는 정량적 실행 기준을 제시한다. 건당 비용이 높은 SMS 채널의 경우 상위 10,000 명 수준의 극소수 정밀 타겟팅을 적용하여 53.20%에 달하는 고적중률(무작위 대비 Lift 약 431 배)을 확보함으로써 예산 누수를 통제할 수 있다. 반면 한계 비용이 극히 낮은 앱 푸시나 이메일 채널의 경우, 상위 20 만명(전체의 0.78%)을 선별하는 확장 타겟팅을 통해 전체 전환 고객의 95.83%를 포착하는 동시에 기존 대비 99.22%의 발송 물량을 절감할 수 있다.

이러한 접근법은 마케터에게 직관적인 3 단계 실행 가이드라인을 제공한다. 1 단계로 마케팅 피로도 변수를 활용하여 최근 과도한 자극에 노출된 비반응 고객을 사전에 필터링하고, 2 단계로 시계열적 반응 지표를 통해 고객별 최적 수신 타이밍(요일, 시간대, 급여 주기)에 맞추어 발송 시점을 조율하며, 3 단계로 재구매 주기 도래 여부와 선호 콘텐츠의 신선도를 결합하여 최종 메시지를 전달하는 체계적 운영 거버넌스를 수립할 수 있다.

5.4 연구의 한계점 및 향후 과제

본 연구는 다양한 학술적, 실무적 시사점에도 불구하고 다음과 같은 한계점을 지니며, 이는 향후 연구를 통해 보완될 필요가 있다.

첫째, 관측 데이터 기반의 분석으로 인한 순수 인과추론의 제약이다. 본 연구는 실제 이커머스 로그 데이터를 활용하여 도메인 지식 변수와 구매 전환 간의 통계적 연관성 및 예측 기여도를 규명하였으나, 이는 반사실적 처치 효과를 완벽히 통제한 순수 인과관계를 의미하지는 않는다. SHAP 분석에서 나타난 변수 중요도 역시 모형의 예측 확률 형성에 대한 수학적 기여분일 뿐 직접적인 인과 메커니즘으로 단정하기 어렵다. 향후 연구에서는 무작위 배정 기반의 현장 A/B 테스트나 성향점수 매칭, 이중차분법 등의 준실험 설계를 결합하여 도메인 변수의 순수 처치 효과를 인과적으로 검증할 필요가 있다.

둘째, 단일 플랫폼 데이터셋에 기반한 분석에 따른 일반화의 한계이다. 본 연구는 약 1 억 7,200 만 건의 방대한 다채널 로그를 분석하여 데이터의 신뢰성을 확보하였으나, 특정 종합 이커머스 플랫폼의 기록에 국한되어 있다. 정기 구독형 서비스나 고관여 내구재 플랫폼 등 비즈니스 모델 및 상품 관여도 차이에 따라 채널별 피로도 반감기나 재구매 주기의 영향력이 다르게 나타날 가능성이 존재한다. 향후 연구에서는 다양한 산업군

및 다국적 이커머스 데이터를 활용한 교차 검증이 요구된다.

셋째, 고정된 탐색적 파라미터 설정의 문제이다. 본 연구의 민감도 분석을 통해 피로도 반감기 파라미터(τ)가 $\pm 50\%$ 변동하더라도 모형 성능이 안정적으로 유지됨을 확인하였으나, 초기 기준 반감기는 실무적 가이드라인에 기반한 탐색적 설정치에 해당한다. 고객 개개인의 인지적 수용 한계와 채널별 피로도 누적 속도는 개인의 성향에 따라 이질적일 수 있다. 따라서 향후 연구에서는 고정된 채널별 반감기 설정을 넘어, 개별 사용자의 누적 반응 로그로부터 개인화된 최적 반감기를 동적으로 학습하는 적응형 파라미터 추정 알고리즘으로의 확장이 이루어져야 할 것이다.

마지막으로, 모델 효율성의 정량적 측정 문제이다. 본 연구는 딥러닝 대비 트리 기반 경량 모델이 연산 리소스 측면에서 효율적임을 논하였으나, 실제 CPU 와 GPU 간의 구체적인 연산 시간 비교나 에너지 소비량 및 탄소 배출량에 대한 정량적 측정치는 제시하지 못했다. 경량화 알고리즘의 실무적 효율성을 명확히 하기 위해서는 실제 운영 환경에서의 하드웨어 자원 점유율에 대한 정량적 비교 분석이 수반되어야 할 것이다.

6. 결론

본 연구는 데이터의 질적 표현력이 모델의 구조적 복잡성을 증가할 수 있는가라는 데이터 중심 인공지능의 핵심 질문에서 출발하여, 극단적 불균형을 지닌 전자상거래 고객관계관리 환경에서 도메인 지식 기반의 동태적 예측 프레임워크를 제안하고 실증하였다. 2 개년에 걸친 1 억 7,200 만 건의 다채널 메시징 로그와 구매 전환율 0.1234%인 원분포 홀드아웃 테스트 세트를 기반으로 총 9 종의 머신러닝, 심층 신경망, 정형 특화 딥러닝 알고리즘을 비교 검증하였다. 실증 분석 결과, 마케팅 이론을 4 대 동태적 파생변수군으로 조작화하여 귀납적 편향으로 주입한 접근법은 비교 대상 알고리즘 전반의 PR-AUC 및 F1-score 를 일관되게 향상시켰다. 특히 복잡한 심층 신경망 계열 대비 경량화된 트리 기반 앙상블 모형인 XGBoost 가 정형 데이터의 불연속적 경계면 학습에서 가장 우수한 종합 분류 성능을 달성함을 확인하였다. 이는 데이터의 희소성과 고객 행동의 이질성이 지배적인 비즈니스 분석 환경에서 맹목적인 심층 아키텍처 확장보다 도메인 이론에 기반한 데이터 표현력의 구조적 보강이 예측 성능의 상한을 결정짓는 핵심 요인임을 시사한다.

본 연구의 실증 결과와 해석이 제공하는 핵심 학술적 발견은 세 가지로 종합된다.

첫째, 데이터 중심 인공지능 방법론의 실효성을 입증하였다. 추상적 마케팅 이론을 지수 감쇠 피로도, 캘린더 근접도, 재구매 위험률 함수 등의 동태적 수학 신호로 변환하여 모델에 주입함으로써, 사전 지식이 없는 딥러닝의 순수 표현 학습이 포착하기 어려운 유의미한 정보 이득을 구조적으로 제공하였다. 이는 초거대 모델 중심의 인공지능 환경에서도 연구자 및 실무자의 도메인 이해도가 예측 모형의 성능을 극대화하는 본질적 자산임을 재확인해 준다. 둘째, 정적 프로파일링에서 실시간 동태적 상태 제어로의 마케팅 패러다임 전환이다. 변수 절삭 및 SHAP 순위 변동 분석을 통해, 고객의 단기 구매 전환을 좌우하는 1 차 예측 신호는 과거의 정적 인구통계학적 속성이나 단순 장기 누적 이력이 아니라 최근의 누적 피로도와 시계열적 수신 맥락임을 규명하였다. 모델은 피로도를 통한 비반응 고객 선제 배제, 시계열 맥락을 통한 수신 적기 조율, 재구매 주기를 통한 최종 전환 확정이라는 다단계 계층적 의사결정 구조를 스스로 학습하였다. 셋째, 지속 가능한 고효율 적정 기술의 가치를 제시하였다. 고비용 GPU 연산 인프라를 요구하는 심층 신경망 대비, 도메인 변수를 장악한 경량 트리 모델은 우수한 성능과 빠른 추론 속도를 동시에 제공하여 실제 산업 현장에서의

운영 비용을 최소화할 수 있는 현실적 대안이 됨을 입증하였다.

본 연구는 마케팅 도메인 이론과 최신 데이터 과학 방법론의 융합을 통해, 예측 성능과 설명 가능성, 그리고 실무적 비용 효율성을 동시에 달성할 수 있는 이론 기반 비즈니스 애널리틱스의 실행 가능성을 실증하였다. 실무 마케팅 현장에서 본 프레임워크는 고정된 일괄 발송 관행을 탈피하고, 채널 단가와 가용 예산에 따라 최적의 운영 임계값을 유연하게 설정할 수 있는 정량적 의사결정 도구로 기능한다. 상위 타겟팅 규모 분석에서 확인되었듯이, 건당 비용이 높은 채널에서는 상위 0.04% 수준의 정밀 타겟팅으로 무작위 대비 약 431 배의 적중률 향상을 도모하고, 한계 비용이 낮은 채널에서는 상위 0.78% 선별만으로 전체 구매 전환의 95.83%를 포착하며 발송 물량을 99.22% 절감하는 최적화 거버넌스를 구축할 수 있다.

궁극적으로 인공지능과 비즈니스 의사결정의 융합은 모형의 규모를 무한히 키우는 것이 아니라, 인간의 축적된 도메인 지식과 기계의 패턴 학습 역량을 유기적으로 결합하여 가장 효율적인 문제 해결 경로를 도출하는 데서 완성된다. 본 연구가 제시한 데이터 중심의 귀납적 편향 주입 프레임워크가 향후 다양한 비즈니스 도메인과 정책 의사결정 영역으로

확장되어, 학술적 엄밀성과 산업적
실용성을 모두 갖춘 지속 가능한 인공지능
연구의 유의미한 이정표로 활용되기를
기대한다.

참고문헌

- [1] Akter, J., Roy, A., Rahman, S., Mohona, S., and Ara, J. (2025), "Artificial intelligence-driven customer lifetime value (CLV) forecasting: Integrating RFM analysis with machine learning for strategic customer retention," *Journal of Computer Science and Technology Studies*, 7(1), 249-257.
- [2] Althoff, T., Horvitz, E., White, R.W., and Zeitzer, J. *Harnessing the web for population-scale physiological sensing: A case study of sleep and performance*. in *Proceedings of the 26th international conference on World Wide Web*. 2017. Perth, Australia: IW3C2.
- [3] Alvarez-Melis, D., and Jaakkola, T.S. (2018), "On the robustness of interpretability methods," arXiv preprint arXiv:1806.08049.
- [4] Anderl, E., Becker, I., Von Wangenheim, F., and Schumann, J.H. (2016), "Mapping the customer journey: Lessons learned from graph-based online attribution modeling," *International journal of research in marketing*, 33(3), 457-474.
- [5] Arik, S.Ö., and Pfister, T. *Tabnet: Attentive interpretable tabular learning*. in *Proceedings of the AAAI conference on artificial intelligence*. 2021. AAAI Press.
- [6] Attari, V., and Arroyave, R. (2025), "Decoding non-linearity and complexity: Deep tabular learning approaches for materials science," *Digital Discovery*, 4(10), 2765-2780.
- [7] Beyazit, E., Kozaczuk, J., Li, B., Wallace, V., and Fadlallah, B. (2023), "An inductive bias for tabular deep learning," *Advances in Neural Information Processing Systems*, 36, 43108-43135.
- [8] Chae, I., Bruno, H.A., and Feinberg, F.M. (2019), "Wearout or weariness? Measuring potential negative consequences of online ad volume and placement on website visits," *Journal of Marketing Research*, 56(1), 57-75.
- [9] Chamberlain, B.P., Cardoso, A., Liu, C.B., Pagliari, R., and Deisenroth, M.P. *Customer lifetime value prediction using embeddings*. in *Proceedings of the 23rd ACM SIGKDD international conference on knowledge discovery and data mining*. 2017. Halifax, NS, Canada: ACM
- [10] Chen, Q., Zhao, H., Li, W., Huang, P., and Ou, W. *Behavior sequence transformer for e-commerce recommendation in alibaba*. in *Proceedings of the 1st international workshop on deep learning practice for high-dimensional sparse data*. 2019.
- [11] Du, M., Hammerschmidt, C.A., Varisteas, G., State, R., Brorsson, M., and Zhang, Z. *time series modelling of market price in real-time bidding*. in *ESANN*. 2019.
- [12] EU (2024), "Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence," *Official Journal of the European Union*, 2024/1689.
- [13] Fader, P.S., Hardie, B.G., and Lee, K.L. (2005), "RFM and CLV: Using iso-value curves for customer base analysis," *Journal of marketing research*, 42(4), 415-430.
- [14] Farjon, G., and Bar-Hillel, A. (2022), "Sparse Hierarchical Table Ensemble—A Deep Learning Alternative for Tabular Data," *IEEE Access*, 10, 75376-75384.
- [15] Gorishniy, Y., Kotelnikov, A., and Babenko, A. (2024), "Tabm: Advancing tabular deep learning with parameter-efficient ensembling," arXiv preprint arXiv:2410.24210.

- [16] Grinsztajn, L., Oyallon, E., and Varoquaux, G. (2022), "Why do tree-based models still outperform deep learning on typical tabular data?," *Advances in neural information processing systems*, 35, 507-520.
- [17] Hacker, P. (2024), "Sustainable AI regulation," *Common Market Law Review*, 61(2).
- [18] Harris, P., Pol, H., and Van Der Veen, G., *Customer journey: From practice to theory*, in *The Routledge companion to strategic marketing*. 2020, Routledge. p. 67-90.
- [19] Huang, X., Khetan, A., Cvitkovic, M., and Karnin, Z. (2020), "Tabtransformer: Tabular data modeling using contextual embeddings," *arXiv preprint arXiv:2012.06678*.
- [20] Jia, R., Li, R., Yu, M., and Wang, S. *E-commerce purchase prediction approach by user behavior data*. in *2017 international conference on computer, information and telecommunication systems (CITS)*. 2017. Dalian, Liaoning, China: IEEE.
- [21] Karpatne, A., Atluri, G., Faghmous, J.H., Steinbach, M., Banerjee, A., Ganguly, A., Shekhar, S., Samatova, N., and Kumar, V. (2017), "Theory-guided data science: A new paradigm for scientific discovery from data," *IEEE Transactions on knowledge and data engineering*, 29(10), 2318-2331.
- [22] Koren, Y. *Collaborative filtering with temporal dynamics*. in *Proceedings of the 15th ACM SIGKDD international conference on Knowledge discovery and data mining*. 2009. Paris, France: ACM.
- [23] Kumar, V., Rajan, B., Venkatesan, R., and Lecinski, J. (2019), "Understanding the role of artificial intelligence in personalized engagement marketing," *California management review*, 61(4), 135-155.
- [24] Lambrecht, A., and Tucker, C. (2013), "When does retargeting work? Information specificity in online advertising," *Journal of Marketing research*, 50(5), 561-576.
- [25] Lemon, K.N., and Verhoef, P.C. (2016), "Understanding customer experience throughout the customer journey," *Journal of marketing*, 80(6), 69-96.
- [26] Lindskog, W., and Prehofer, C. *A federated learning benchmark on tabular data: Comparing tree-based models and neural networks*. in *2023 Eighth International Conference on Fog and Mobile Edge Computing (FMEC)*. 2023. Tartu, Estonia: IEEE.
- [27] Lundberg, S.M., Erion, G., Chen, H., DeGrave, A., Prutkin, J.M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., and Lee, S.I. (2020), "From Local Explanations to Global Understanding with Explainable AI for Trees," *Nat Mach Intell*, 2(1), 56-67.
- [28] Lundberg, S.M., and Lee, S.-I. (2017), "A unified approach to interpreting model predictions," *Advances in neural information processing systems*, 30.
- [29] Olafsson, A., and Pagel, M. (2018), "The liquid hand-to-mouth: Evidence from personal finance management software," *The Review of Financial Studies*, 31(11), 4398-4446.
- [30] Ribeiro, M.T., Singh, S., and Guestrin, C. *"Why should i trust you?": Explaining the predictions of any classifier*. in *Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining*. 2016. San Francisco, CA: ACM.
- [31] Schmittlein, D.C., Morrison, D.G., and Colombo, R. (1987), "Counting your customers: Who-are they and what will they do next?," *Management science*, 33(1), 1-24.
- [32] Shannon, C.E. (1948), "A mathematical theory of communication," *The Bell system technical journal*, 27(3), 379-423.

- [33] Shin, J., Kim, W., Lee, J., Park, J., and Ock, C.Y. *Controlling Weight Update Probability of Sparse Features in Machine Learning*. in *2022 14th International Conference on Knowledge and Systems Engineering (KSE)*. 2022. Nha Trang, Vietnam: IEEE.
- [34] Sun, C., Shrivastava, A., Singh, S., and Gupta, A. *Revisiting unreasonable effectiveness of data in deep learning era*. in *Proceedings of the IEEE international conference on computer vision*. 2017. Venice, Italy: IEEE.
- [35] Thabtah, F., Hammoud, S., Kamalov, F., and Gonsalves, A. (2020), "Data imbalance in classification: Experimental evaluation," *Information Sciences*, 513, 429-441.
- [36] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł., and Polosukhin, I. (2017), "Attention is all you need," *Advances in neural information processing systems*, 30.
- [37] Verbeke, W., Dejaeger, K., Martens, D., Hur, J., and Baesens, B. (2012), "New insights into churn prediction in the telecommunication sector: A profit driven data mining approach," *European journal of operational research*, 218(1), 211-229.
- [38] Wathieu, L. (2004), "Consumer habituation," *Management Science*, 50(5), 587-596.
- [39] Zha, D., Bhat, Z.P., Lai, K.-H., Yang, F., Jiang, Z., Zhong, S., and Hu, X. (2025), "Data-centric artificial intelligence: A survey," *ACM Computing Surveys*, 57(5), 1-42.
- [40] Zhang, H., Arvin, C., Efimov, D., Mahoney, M.W., Perrault-Joncas, D., Ramasubramanian, S., Wilson, A.G., and Wolff, M. (2024), "Llmforecaster: Improving seasonal event forecasts with unstructured textual data," *arXiv preprint arXiv:2412.02525*.
- [41] Ziegler, C.-N., McNee, S.M., Konstan, J.A., and Lausen, G. *Improving recommendation lists through topic diversification*. in *Proceedings of the 14th international conference on World Wide Web*. 2005. Chiba, Japan: ACM.

Appendix

<부록 1> 구매 전환 여부에 따른 베이스라인 및 도메인 지식 파생변수 간 차이 검정

Group	Feature	Val.	Non-purchased	Purchased	Statistics
베이스라인	캠페인 지속 시간(평균)	-	5.44 ± 50.45	20.48 ± 7.92	$T=-184.08, p<0.001$
	메시지 수신:	0.00	53,118,072 (3.87%)	292,400 (17.22%)	$\chi^2=4709.65, p<0.001$
	미정의/기타	1.00	1,321,091,580 (96.13%)	1,405,584 (82.78%)	
	발송 채널: 모바일 푸시	0.00	880,319,908 (64.06%)	1,642,600 (96.74%)	$\chi^2=4574.03, p<0.001$
		1.00	493,889,744 (35.94%)	55,384 (3.26%)	
	발송 채널: 이메일	0.00	494,353,628 (35.97%)	55,384 (3.26%)	$\chi^2=4581.60, p<0.001$
		1.00	879,856,024 (64.03%)	1,642,600 (96.74%)	
	캠페인 주제: 할인 정보	0.00	120,971,900 (8.80%)	1,405,412 (82.77%)	$\chi^2=66561.25, p<0.001$
		1.00	1,253,237,752 (91.20%)	292,572 (17.23%)	
	캠페인 주제: 기타	0.00	1,256,409,776 (91.43%)	298,248 (17.56%)	$\chi^2=67972.34, p<0.001$
		1.00	117,799,876 (8.57%)	1,399,736 (82.44%)	
	메시지 수신: 스마트폰	0.00	1,364,012,116 (99.26%)	1,557,976 (91.75%)	$\chi^2=7434.54, p<0.001$
		1.00	10,197,536 (0.74%)	140,008 (8.25%)	
	메시지 클릭 여부	0.00	1,364,585,220 (99.30%)	1,417,624 (83.49%)	$\chi^2=34465.90, p<0.001$
		1.00	9,624,432 (0.70%)	280,360 (16.51%)	
	메시지 오픈 여부	0.00	1,246,391,464 (90.70%)	1,252,676 (73.77%)	$\chi^2=3339.06, p<0.001$
		1.00	127,818,188 (9.30%)	445,308 (26.23%)	
	캠페인 채널: 모바일	0.00	889,842,516 (64.75%)	1,642,600 (96.74%)	$\chi^2=4420.48, p<0.001$
		1.00	484,367,136 (35.25%)	55,384 (3.26%)	
	캠페인 채널: 이메일	0.00	553,559,124 (40.28%)	73,788 (4.35%)	$\chi^2=5293.64, p<0.001$
		1.00	820,650,528 (59.72%)	1,624,196 (95.65%)	
	캠페인 유형: 기타 거래	0.00	1,347,222,680 (98.04%)	316,652 (18.65%)	$\chi^2=307695.49, p<0.001$
		1.00	26,986,972 (1.96%)	1,381,332 (81.35%)	
	캠페인 유형: 전체 유저	0.00	96,166,060 (7.00%)	1,399,736 (82.44%)	$\chi^2=85156.18, p<0.001$
		1.00	1,278,043,592 (93.00%)	298,248 (17.56%)	
	최종 클릭 경과 시간(평균)	-	4185.34 ± 395.93	3521.90 ± 1632.00	$T=40.39, p<0.001$
	채널 메세지 유형: 거래성 발송	0.00	1,346,481,016 (97.98%)	316,652 (18.65%)	$\chi^2=299613.34, p<0.001$
		1.00	27,728,636 (2.02%)	1,381,332 (81.35%)	
	채널 메세지 유형: 전체 유저 발송	0.00	96,907,724 (7.05%)	1,399,736 (82.44%)	$\chi^2=84441.83, p<0.001$
		1.00	1,277,301,928 (92.95%)	298,248 (17.56%)	
	푸시 경과 시간	-	589.88 ± 1506.69	244.54 ± 897.33	$T=38.17, p<0.001$
	메시지 수신: 페이스북	0.00	1,373,425,676 (99.94%)	1,682,160 (99.07%)	$\chi^2=1284.03, p<0.001$
		1.00	783,976 (0.06%)	15,824 (0.93%)	
	이메일 계정: Mail.ru	0.00	933,516,240 (67.93%)	896,980 (52.83%)	$\chi^2=1031.65, p<0.001$
		1.00	440,693,412 (32.07%)	801,004 (47.17%)	
	총 구매 횟수	-	0.00 ± 0.11	0.40 ± 1.38	$T=-28.41, p<0.001$
	메시지 수신: 데스크탑	0.00	1,332,408,664 (96.96%)	1,566,748 (92.27%)	$\chi^2=731.51, p<0.001$
		1.00	41,800,988 (3.04%)	131,236 (7.73%)	
	최종 오픈 경과 시간(평균)	-	2404.79 ± 981.90	2049.81 ± 1389.38	$T=25.38, p<0.001$
	이메일 계정: 기타	0.00	637,672,628 (46.40%)	983,152 (57.90%)	$\chi^2=523.66, p<0.001$
		1.00	736,537,024 (53.60%)	714,832 (42.10%)	
	총 메시지 수신 수	-	0.96 ± 1.55	1.55 ± 2.73	$T=-21.54, p<0.001$
	총 캠페인 수	-	0.93 ± 1.40	1.26 ± 1.79	$T=-18.62, p<0.001$
	메시지 수신: 태블릿	0.00	1,373,874,080 (99.98%)	1,692,652 (99.69%)	$\chi^2=322.25, p<0.001$
		1.00	335,572 (0.02%)	5,332 (0.31%)	
	캠페인 채널: 멀티채널	0.00	1,305,030,564 (94.97%)	1,679,580 (98.92%)	$\chi^2=321.30, p<0.001$
		1.00	69,179,088 (5.03%)	18,404 (1.08%)	
	채널 메세지 유형: 특정 유저행동 발송	0.00	1,305,030,564 (94.97%)	1,679,580 (98.92%)	$\chi^2=321.30, p<0.001$
		1.00	69,179,088 (5.03%)	18,404 (1.08%)	
	캠페인 유형: 특정 유저행동	0.00	1,305,030,564 (94.97%)	1,679,580 (98.92%)	$\chi^2=321.30, p<0.001$
		1.00	69,179,088 (5.03%)	18,404 (1.08%)	
	가입 기간(첫 구매 경과)	-	417.24 ± 1484.70	724.89 ± 2236.08	$T=-13.67, p<0.001$
	불만 접수 경과 시간(평균)	-	0.13 ± 31.41	0.00 ± 0.00	$T=12.03, p<0.001$
	이메일 계정: 지메일	0.00	1,177,230,436 (85.67%)	1,515,836 (89.27%)	$\chi^2=104.18, p<0.001$
		1.00	196,979,216 (14.33%)	182,148 (10.73%)	
	캠페인 주제: 리뷰 요청	0.00	1,374,098,540 (99.99%)	1,697,124 (99.95%)	$\chi^2=17.03, p<0.001$
		1.00	111,112 (0.01%)	860 (0.05%)	
		0.00	1,373,085,116 (99.92%)	1,694,716 (99.81%)	

	캠페인 주제: 연관 상품 추천	1.00	1,124,536 (0.08%)	3,268 (0.19%)	$\chi^2=13.41, p<0.001$
	구독 취소 경과 시간(평균)	-	7232.53 ± 99.83	7226.40 ± 214.20	$T=2.84, p=0.00$
	메시지 구독 취소 여부	0.00	1,373,628,808 (99.96%)	1,696,608 (99.92%)	$\chi^2=2.65, p=0.10$
		1.00	580,844 (0.04%)	1,376 (0.08%)	
	발송 채널: 웹 푸시	0.00	1,373,758,668 (99.97%)	1,697,984 (100.00%)	$\chi^2=2.32, p=0.13$
		1.00	450,984 (0.03%)	0 (0.00%)	
	캠페인 주제: 이벤트	0.00	1,373,798,056 (99.97%)	1,697,984 (100.00%)	$\chi^2=2.04, p=0.15$
		1.00	411,596 (0.03%)	0 (0.00%)	
	캠페인 주제: 생일 축하	0.00	1,372,684,872 (99.89%)	1,696,436 (99.91%)	$\chi^2=0.19, p=0.66$
		1.00	1,524,780 (0.11%)	1,548 (0.09%)	
	캠페인 채널: SMS	0.00	1,374,196,752 (100.00%)	1,697,984 (100.00%)	$\chi^2=0.00, p=1.00$
		1.00	12,900 (0.00%)	0 (0.00%)	
구매/재구매 주기 패턴	마지막 구매 경과일	-	364.52 ± 11.22	305.98 ± 129.04	$T=45.08, p<0.001$
	구매 후 불응기	-	0.00 ± 0.01	0.09 ± 0.26	$T=-35.22, p<0.001$
	재구매 준비도	-	0.00 ± 0.01	0.00 ± 0.05	$T=-4.56, p<0.001$
시계열적 반응 패턴	주말 여부	0.00	1,295,207,472 (94.25%)	1,333,688 (78.55%)	$\chi^2=4471.55, p<0.001$
		1.00	79,002,180 (5.75%)	364,296 (21.45%)	
	선호 요일 일치도	-0.97	54,762,736 (3.99%)	185,072 (10.90%)	$\chi^2=6423.87, p<0.001$
		-0.78	24,239,444 (1.76%)	179,224 (10.56%)	
		-0.43	398,359,568 (28.99%)	294,980 (17.37%)	
		0.00	195,071,220 (14.20%)	210,872 (12.42%)	
		0.43	121,870,772 (8.87%)	241,488 (14.22%)	
		0.78	212,535,584 (15.47%)	234,092 (13.79%)	
		0.97	367,370,328 (26.73%)	352,256 (20.75%)	
	급여일 근접도	0.05	57,449,032 (4.18%)	60,716 (3.58%)	$\chi^2=471.37, p<0.001$
		0.07	36,944,912 (2.69%)	54,524 (3.21%)	
		0.10	137,530,856 (10.01%)	141,384 (8.33%)	
		0.14	164,658,008 (11.98%)	166,840 (9.83%)	
		0.19	167,992,916 (12.22%)	184,040 (10.84%)	
		0.26	172,135,536 (12.53%)	280,704 (16.53%)	
		0.37	213,863,596 (15.56%)	233,232 (13.74%)	
		0.51	158,217,984 (11.51%)	278,124 (16.38%)	
		0.72	172,364,640 (12.54%)	202,272 (11.91%)	
		1.00	93,052,172 (6.77%)	96,148 (5.66%)	
	주차 정보	1.00	311,767,200 (22.69%)	397,836 (23.43%)	$\chi^2=198.54, p<0.001$
		2.00	314,790,100 (22.91%)	457,692 (26.96%)	
		3.00	302,529,080 (22.01%)	306,504 (18.05%)	
		4.00	327,408,708 (23.83%)	362,920 (21.37%)	
		5.00	117,714,564 (8.57%)	173,032 (10.19%)	
	분기 말 근접도	-	0.08 ± 0.21	0.06 ± 0.19	$T=8.37, p<0.001$
	선호 시간대 일치도	-	0.23 ± 0.67	0.26 ± 0.70	$T=-3.49, p<0.001$
마케팅 피로도 패턴	유저 오픈율(30 일)	-	0.03 ± 0.15	0.17 ± 0.37	$T=-40.32, p<0.001$
	유저 클릭율(30 일)	-	0.00 ± 0.04	0.12 ± 0.31	$T=-38.62, p<0.001$
	유저 오픈 횟수(30 일)	-	0.03 ± 0.18	0.31 ± 0.86	$T=-32.84, p<0.001$
	마케팅 피로도	-	0.01 ± 0.06	0.07 ± 0.22	$T=-30.09, p<0.001$
	이메일 경과 시간	-	1084.59 ± 2071.62	761.29 ± 1605.05	$T=19.99, p<0.001$
	발송 간격 표준편차	-	0.12 ± 4.06	3.27 ± 20.06	$T=-15.58, p<0.001$
	채널별 특정 주제 캠페인 오픈율(30 일)	-	0.19 ± 0.04	0.18 ± 0.04	$T=15.33, p<0.001$
	마지막 접촉 경과 시간	-	178.87 ± 619.24	125.37 ± 458.91	$T=11.57, p<0.001$
마케팅 채널 효과성 패턴	주제 노출 수(7 일)	0.00	411,596 (0.03%)	0 (0.00%)	$\chi^2=68053.13, p<0.001$
		1.00	1,524,780 (0.11%)	1,548 (0.09%)	
		2.00	111,112 (0.01%)	860 (0.05%)	
		3.00	1,124,536 (0.08%)	3,268 (0.19%)	
		4.00	117,799,876 (8.57%)	1,399,736 (82.44%)	
		5.00	1,253,237,752 (91.20%)	292,572 (17.23%)	
	성공 캠페인 유사도	0.00	1,370,206,008 (99.71%)	1,388,556 (81.78%)	$\chi^2=312364.18, p<0.001$
		0.20	2,905,080 (0.21%)	16,856 (0.99%)	
		0.50	115,240 (0.01%)	688 (0.04%)	
		1.00	983,324 (0.07%)	291,884 (17.19%)	
	주제 경과 시간	-	2380.17 ± 1685.01	1842.70 ± 1508.20	$T=35.38, p<0.001$
	주제 신선도	-	0.01 ± 0.06	0.07 ± 0.21	$T=-28.75, p<0.001$
	성공 경로 일치도	-	0.30 ± 0.41	0.23 ± 0.34	$T=18.02, p<0.001$

<부록 2> 모델 별 하이퍼파라미터 탐색범위 및 최적값 요약

파라미터	탐색범위	최적값	파라미터	탐색범위	최적값
------	------	-----	------	------	-----

Random Forest			XGBoost		
n_estimators	100 ~ 200 (step=50)	200	n_estimators	100 ~ 600 (step=50)	600
learning_rate	0.001 ~ 0.3 (log)	0.0588	learning_rate	0.001 ~ 0.3 (log)	0.0367
max_depth	8 ~ 16	16	max_depth	3 ~ 10	10
min_samples_split	2 ~ 10	2	min_child_weight	1 ~ 10	2
min_samples_leaf	1 ~ 5	8	subsample	0.6 ~ 0.9	0.7297
-	-	-	colsample_bytree	0.85 ~ 1.0	0.9967
-	-	-	gamma	0.1 ~ 5.0	3.9601
-	-	-	reg_alpha	1e-3 ~ 10 (log)	0.7237
-	-	-	reg_lambda	1e-3 ~ 10 (log)	0.0018
MLP			CNN		
n_layers	1 ~ 3	3	conv_filters	32 ~ 256	128
-	-	-	kernel_size	2 ~ 5	3
-	-	-	pool_size	2 ~ 3	3
-	-	-	num_conv_layers	1 ~ 2	1
dense_units	64 ~ 128 (step=32)	64	dense_units	32 ~ 256	192
dropout_rate	0.1 ~ 0.4	0.208	dropout_rate	0.1 ~ 0.4	0.24
l2	1e-6 ~ 1e-2	4.87E-03	l2	1e-6 ~ 1e-2	1.62E-05
learning_rate	1e-4 ~ 1e-2 (log)	0.0086	learning_rate	1e-5 ~ 1e-3	0.0085
batch_size	16/32/64/128	128	batch_size	32/64/128	128
RNN			LSTM		
num_layers	1 ~ 2	2	num_lstm_layers	1 ~ 2	2
rnn_units1	32 ~ 256	224	lstm_units_1	32 ~ 256	96
rnn_units2	16 ~ 128	128	lstm_units_2	32 ~ 256	112
dense_units	16 ~ 256	96	dense_units	16 ~ 64	48
dropout_rate	0.1 ~ 0.4	0.3461	dropout_rate	0.1 ~ 0.4	0.453
l2	1e-6 ~ 1e-2	3.20E-03	l2	1e-5 ~ 1e-2	7.43E-04
learning_rate	1e-5 ~ 1e-2	1.21E-05	learning_rate	1e-5 ~ 1e-3	3.18E-04
batch_size	32/64/128	32	batch_size	32/64/128	128
CNN-LSTM			RNN-LSTM		
conv_filters	16 ~ 128	48	-	-	-
kernel_size	2 ~ 5	4	-	-	-
pool_size	2 ~ 4	4	lstm_units1	32 ~ 256	256
lstm_units	32 ~ 256	256	lstm_units2	16 ~ 128	64
dense_units	16 ~ 64	16	dense_units	16 ~ 64	64
dropout_rate	0.1 ~ 0.4	0.1156	dropout_rate	0.1 ~ 0.4	0.4873
l2	1e-5 ~ 1e-2	3.23E-05	l2	1e-5 ~ 1e-2	7.33E-04
learning_rate	1e-5 ~ 1e-3	5.71E-04	learning_rate	1e-5 ~ 1e-3	1.77E-04
batch_size	32/64/128	128	batch_size	32/64/128	32
TabNet					
n_d	16 ~ 48 (step=8)	16			
n_steps	3 ~ 5	4			
gamma	1.0 ~ 1.5	1.14322			
lambda_sparse	1e-4 ~ 1e-3 (log)	0.00023952			
lr	1e-3 ~ 1e-2 (log)	0.00492911			
mask_type	sparsemax / entmax	entmax			
batch_size	2048 / 4096	2048			
virtual_batch_size	128 / 256	128			